

2020 CUMCM C 题—初始分析报告

MathModel Team

2026 年 7 月 26 日

1 问题重述

某银行需对中小微企业进行信贷决策：评估信贷风险、决定是否放贷、确定贷款额度和利率。数据包括 123 家有信贷记录企业（附件 1，含信誉评级和违约标签）和 302 家无信贷记录企业（附件 2，仅有发票数据），以及利率与客户流失率的关系数据（附件 3）。

三个子问题：

1. 对 123 家企业量化信贷风险，在年度信贷总额固定时给出信贷策略。
2. 对 302 家企业量化信贷风险，在年度总额 1 亿元时给出信贷策略。
3. 考虑突发事件（如新冠疫情）的差异化影响，给出信贷调整策略。

2 子问题拆解

2.1 子问题 1：有标签企业的风险评估（附件 1）

输入：123 家企业的进项/销项发票数据、信誉评级（A/B/C/D）、违约标签。

输出：每家企业违约概率的量化估计 + 信贷决策（额度、利率）。

核心挑战：从发票数据中提取有效风险特征。文献中使用了以下几种方案：

- 11 指标 + 熵权 + TOPSIS (D1) ——客观赋权，但忽略了指标相关性
- 6 指标 + Logistic 回归 (D2) ——可解释但准确率有限（84.6%，违约召回率仅 48.1%）
- 20 指标 + Soft Voting 集成 (D3) ——AUC=0.994，但计算复杂
- 7 指标 + PCA 降维 → 安全指数 (D4) ——含 FFT 交易规律分析，创新性强

2.2 子问题 2：无标签企业的风险评估（附件 2）

核心挑战：附件 2 的 302 家企业没有信誉评级和违约标签。需要用附件 1 训练的模型推断附件 2 的风险。

文献中的方案：

- D2: 用欧氏距离匹配——将附件 2 企业的特征向量与附件 1 企业比较，以最近邻的信用等级作为预测等级，再代入 Logistic 模型。
- D3: Soft Voting + XGBoost 直接预测，准确率 87.8%。

- D4: BP 神经网络预测风险。

年度总额 1 亿的分配：所有文献都采用了多目标规划——在总贷款额度约束下，最大化风险调整后收益，最小化最大单笔风险和客户流失。

2.3 子问题 3：突发因素调整

核心挑战：量化新冠疫情对每个企业的影响，但没有精确的「冲击值」数据。
文献方案：

- D3: 系统聚类 → 将 302 家企业按疫情表现分为 3 类 → 每类赋风险乘数 $Q_1 = 1.2, Q_2 = 1.5, Q_3 = 2.0$ → 修正违约概率为 $(1 + Q_k)\theta$ 。
- D1: 三级因子法（固定因子 + 变量因子 + 模型因子），需要行业统计数据。
- D4: 经验评估 + 比例因子。

3 相关知识

3.1 风险量化方法选型

从知识库中识别出四种建模哲学（SP-005）：

表 1: 四种方案对比

维度	A: TOPSIS	B: Logistic	C: 集成学习	D: PCA+GA
指标数	11	6	20	7
核心理念	客观排序	概率模型	多模型集成	降维 + 优化
创新点	RAROC 理论	欧氏距离匹配	Voting AUC=0.994	FFT 交易规律
决策模型	RAROC 最大化	多目标	多目标	GA 非线性
突发事件	三级因子	指标修正	聚类 + 乘数	比例因子

3.2 关键陷阱（PF-007）

类别不平衡问题：123 家中仅约 27 家违约（22%）。仅看总体准确率会严重误导——D1 的 Logistic 回归准确率 84.6%，但违约类召回率仅 48.1%，漏掉了超过一半的真正违约者。

必须同时报告混淆矩阵、召回率和 AUC，不能仅依赖总体准确率。

3.3 信贷决策模型（MS-025）

三篇论文的共同框架：多目标规划。目标 1：最大化风险调整后的总收益。目标 2：最小化最大单笔风险（minimax 准则）。目标 3：最小化客户流失率（由利率驱动，见附件 3）。

约束：总贷款额 预算、单笔 10–100 万、年利率 4%–15%、信用评级 D 的企业原则上不放贷。

4 初始建模假设

1. 企业间信贷风险相互独立（不考虑行业联动违约）。
2. 当期决策相互独立（非动态规划，不考虑跨期依赖）。
3. 利率与客户流失率的关系稳定（基于附件 3 的 2019 年数据）。
4. 发票数据真实反映企业经营状况（有效发票 → 正常交易，作废/负数 → 异常）。

5 待解决的开放问题

1. **特征工程方案选择**：用 D1 的 11 指标、D2 的 6 指标，还是设计更优的特征集？
2. **风险量化方法选型**：四种方案各有优劣，需要根据实际情况选择（可解释性 vs. 预测精度 vs. 创新性）。
3. **问题 1 的年度信贷总额**：题目未明确，需要合理假设或从数据中反推。
4. **附件 2 企业的行业识别**：企业名称被脱敏，如何从发票数据推断行业归属？
5. **突发因素的冲击量化**：无外部宏观数据时，如何更客观地确定风险乘数？
6. **模型验证**：附件 1 仅有 123 个样本，训练-测试切分导致方差大。是否需要留出法、交叉验证或 Bootstrap？
7. **利率-流失率的函数形式**：附件 3 的数据结构未确认。需要选择线性/对数/多项式拟合。