

2025 C 题初始分析报告

MathModel AI

2026-07-18

1 问题重述

NIPT（无创产前检测）是一种通过采集母体外周血、检测胎儿游离 DNA 片段以分析染色体异常的产前检测技术。本问题要求：

1. 分析胎儿 Y 染色体浓度与孕妇孕周数、BMI 等指标的相关特性，建立关系模型并检验显著性。
2. 对男胎孕妇按 BMI 合理分组，确定每组最佳 NIPT 时点，最小化潜在风险，分析检测误差影响。
3. 综合考虑身高、体重、年龄等多因素、检测误差和达标比例，给出 BMI 分组和最佳 NIPT 时点。
4. 对女胎孕妇，基于 21/18/13 号染色体非整倍体判定结果，综合考虑 X 染色体 Z 值、GC 含量、读段数等因素，给出女胎异常判定方法。

2 子问题拆解

2.1 问题 1：Y 染色体浓度与孕周/BMI 的关系建模

- **核心变量：**Y 染色体浓度（因变量）、孕周（自变量）、BMI（自变量）
- **可能方法：**
 - 多元线性/非线性回归
 - Logistic 生长曲线模型（Sigmoid 型增长）
 - 广义加性模型（GAM）
 - 分段回归
- **显著性检验：**F 检验、t 检验、 R^2 、残差诊断
- **预期产出：** $Y_{\text{conc}} = f(\text{孕周}, \text{BMI}) + \varepsilon$

2.2 问题 2: BMI 分组与最佳 NIPT 时点 (单因素)

- **核心假设:** BMI 是影响 Y 染色体浓度最早达标时间的主要因素
- **数据依赖:** 使用问题 1 的模型预测各 BMI 分组的达标时间
- **风险函数:** $R(t) = w_1 \cdot \text{检测不准风险} + w_2 \cdot \text{治疗窗口风险}$
- **优化目标:** 最小化每组孕妇的总体潜在风险
- **误差分析:** 检测误差 (Z 值置信区间) 对时点选择的影响

2.3 问题 3: 多因素下的 BMI 分组与时点优化

- **扩展因素:** 年龄、身高、体重、IVF 妊娠、检测抽血次数等
- **达标比例:** 每组内 Y 染色体浓度 $\geq 4\%$ 的孕妇比例
- **优化框架:** 多约束下的分组 + 时点联合优化
- **方法候选:** 聚类分析 + 组内优化、决策树分组、动态规划

2.4 问题 4: 女胎异常判定

- **参考标准:** AB 列 (21/18/13 号染色体非整倍体判定结果)
- **特征集:** X 染色体 Z 值、13/18/21 号染色体 Z 值、GC 含量、读段数、比对比例、BMI 等
- **方法候选:**
 - 逻辑回归 (可解释性强)
 - 随机森林/XGBoost (分类性能好)
 - 支持向量机 (小样本分类)
 - Z 值多阈值联合判定
- **评估指标:** 准确率、召回率、精确率、F1-score、AUC

3 相关知识覆盖

3.1 知识库相关卡片

- **MS-024** (熵权法 + TOPSIS): 可用于女胎异常判定的多指标综合评价
- **MS-026** (Soft Voting 集成学习): 可用于女胎异常的多模型集成分类
- **MS-010** (Spearman vs Pearson 选择策略): 用于问题 1 的相关性方法选择
- **MS-005** (K-means++ 分层模型): 可用于 BMI 的合理分组
- **MS-042** (K-means 分群与聚类数确定): 分组数的确定方法
- **AL-016** (XGBoost): 可用于问题 4 的女胎分类

- **PF-005**（大样本下 p 值失效）：提醒问题 1 显著性检验的效应量评估
- **PF-007**（类别不平衡）：女胎异常数据可能存在类别不平衡
- **PR-005**（模糊概念操作化）：检测时点的”最佳”定义需要操作化

3.2 知识空白

- 胎儿 DNA 浓度与孕周的生物增长模型（非线性的 S 形曲线等）
- NIPT 检测时点优化的风险-收益权衡建模
- 染色体 Z 值的多变量联合判定方法
- 检测误差在 NIPT 中的传播建模

4 初始建模假设

1. Y 染色体浓度随孕周增加呈 Logistic/Sigmoid 增长趋势，受 BMI 负向调节。
2. 最早达标时间 ($T_{\text{达标}}$) 是 Y 染色体浓度曲线达到 4% 的时间点。
3. 潜在风险由两部分构成：检测不准风险（时点过早导致浓度不足 4%）和治疗窗口损失风险（时点过晚导致发现延迟）。
4. 孕妇可在一定孕周范围内多次检测，但应尽量减少检测次数。
5. 女胎的异常判定基于染色体 Z 值的联合分布，健康胎儿的 Z 值服从标准正态分布。

5 待解决的开放问题

1. Y 染色体浓度增长曲线的具体函数形式（Logistic、Gompertz 或其他？）
2. 风险函数中检测不准风险与治疗窗口风险的具体权重如何确定？
3. BMI 分组的最佳数量和方法（K-means、决策树分割、或基于风险的优化分割？）
4. 女胎异常判定中类别不平衡的处理策略（过采样、欠采样、代价敏感学习？）
5. 检测误差（测序质量指标如 GC 含量、比对比例等）如何量化并纳入模型？
6. 对于多次检测的孕妇数据，如何处理重复测量带来的相关性？