

问题 1 内部报告：Y 染色体浓度与孕周/BMI 关系建模

MathModel AI

2026-07-19

1 问题重述与分析

1.1 题目要求

分析胎儿 Y 染色体浓度与孕妇孕周数和 BMI 等指标的相关特性，给出关系模型并检验显著性。

1.2 数据特征

男胎 1082 条检测记录，来自 267 位独立孕妇（多数每人 4 次纵向检测，时间跨度 10–25 周）。Y 染色体浓度 $\geq 4\%$ 为检测可靠标准——这是 NIPT 能够给出有效结果的前提，因此 Y 浓度的建模直接决定后续子问题中「何时可以安全检测」的判断。

1.3 核心难点：横向信号被个体基线淹没

初步探索揭示了一个结构性困难：Y 浓度与孕周的横向 Spearman 相关系数仅 $\rho = 0.084$ （可忽略），与 BMI 仅 $\rho = -0.155$ 。这并非因为没有效应——而是因为不同孕妇的 Y 浓度基线差异可达 3–4 倍，个体间基线差异（占总变异约 65%）完全淹没了任何群体层面的孕周或 BMI 趋势。

这意味着：**横截面回归在此问题上将一无所获。必须利用数据的纵向结构——剥离个体基线后，在同一孕妇内部观察 Y 浓度的变化规律。**

1.4 对下游子问题的接口意义

本问题的产出（ $\hat{\beta}_1$ ：个体内孕周斜率， $\hat{\beta}_2$ ：BMI 效应）直接为子问题 2/3 提供参数基础。但需注意：子问题 2/3 实际使用直接计数法确定达标时点，不依赖 $\hat{\beta}_1$ 的外推预测——这是因 $CV R^2 = 0.248$ 偏低而采取的保守策略。

2 探索性分析

2.1 正态性与变换

Y 浓度偏度 = 0.70，峰度 = 1.00，D'Agostino-Pearson $p < 0.001$ 。取 $\tilde{y} = \ln(y)$ 后偏度降至 -0.55，超额峰度 0.20。

2.2 相关性分析

Spearman 秩相关（图 1）：

- Y 浓度 $\sim$ 孕周： $\rho = 0.084$ （可忽略）

- Y 浓度 ~ BMI: $\rho = -0.155$ (弱负相关)
- Y 浓度 ~ X 染色体浓度: $\rho = 0.474$ (最强)

横向相关性微弱。个体内中心化后孕周效应被清晰检测到——个体间基线差异淹没了群体趋势。




图 1: Spearman 秩相关矩阵

2.3 月份批次效应

2023 年 9–12 月 Y 浓度系统性偏低（达标率从 86%–94% 骤降至 65%–72%），提示实验室操作因素的批次效应（图 2）。引入月份哑变量控制。




图 2: 各月份 Y 浓度均值及达标率

3 模型 A：主模型

3.1 模型结构

个体内中心化回归框架：

$$\tilde{y}_{it} = \beta_0 + \beta_1 \Delta g_{it} + \beta_2 \text{BMI}_i^* + \sum_{k=1}^4 \theta_k \text{Tech}_{it}^{(k)} + \sum_{m=1}^{16} \gamma_m \text{Month}_m^{(it)} + \varepsilon_{it} \quad (1)$$

其中：

- $\Delta g_{it} = g_{it} - \bar{g}_i$ ：个体内中心化孕周。
- BMI_i^* ：中心化 BMI。
- $\text{Tech}^{(1\sim 4)}$ ：标准化后四项测序质量控制指标——原始读段数、比对比例、重复读段比例、过滤比例。
- $\text{Month}_m^{(it)}$ ：月份哑变量（基线 2023-01）。

3.2 GC 含量分析

赛题规定 GC 含量正常范围为 40% ~ 60%。男胎数据中 41.7% 的样本总 GC 含量低于 40% 下限（全部为偏低，无一偏高）。将数据按 GC 正常（ $\geq 40\%$ ）和 GC 偏低（ $< 40\%$ ）分组对比：

- Y 染色体浓度均值：GC 正常组 0.0768，GC 偏低组 0.0777——几乎一致。
- Y 浓度达标率（ $\geq 4\%$ ）：GC 正常组 86.7%，GC 偏低组 86.5%——无差异。

GC 含量对 Y 染色体浓度无实质影响，关键在于 Y 浓度的计算方式：Y 浓度 = Y 染色体 reads / 总 reads。GC 偏差对分子和分母产生同向影响，在比值中被自然约消。模型 A 中 GC 含量作为候选技术协变量检验，结果为 $t = 1.34, p = 0.18$ ，与上述实证一致——总体 GC 含量不影响 Y 浓度的建模和后续推理，因此从最终模型中剔除。¹

3.3 参数估计与检验

表 1 报告核心系数估计，图 3 展示置信区间。

¹此处指总体 GC 含量（GC 含量列）；染色体特异性 GC 差异（如 $\Delta \text{GC}_{18,13}$ ）在问题 4 中作为判别特征，两者为不同指标。

表 1: 模型 A 系数估计

变量	系数	t 值	p 值
孕周 (个体内)	0.0549***	13.96	0.0000
BMI	-0.0290***	-6.97	0.0000
原始读段数	-0.0577***	-4.54	0.0000
比对比例	-0.0237	-1.82	0.0685
重复读段比例	0.0308*	2.44	0.0147
过滤比例	0.0482***	3.68	0.0002
R^2			0.294
R^2			0.248

- **孕周 (个体内):** $\hat{\beta}_1 = +0.055, t = 13.96, p < 0.001$ 。每周 Y 浓度增加约 $e^{0.055} \approx 5.7\%$ 。
- **BMI:** $\hat{\beta}_2 = -0.029, t = -6.97, p < 0.001$ 。BMI 每高 1, Y 浓度降约 3%。中介分析显示加入 X 浓度后 BMI 系数几乎不变 ($-0.029 \rightarrow -0.023$), 表明 BMI 的负效应独立于胎儿 DNA 总量通路。此统计模式与文献记载的血浆体积稀释机制一致 (Wang et al., 2013)。
- **技术协变量:** 读段数 $t = -4.54^{***}$, 过滤比例 $t = 3.68^{***}$, 重复读段 $t = 2.44^*$, 比对比例 $t = -1.82$ (边缘)。
- **全模型:** $R^2 = 0.294, F(22, 1059) = 20.06, p < 10^{-16}$, 留一孕妇 $CV R^2_{CV} = 0.248$ 。




图 3: 核心系数估计及 95% 置信区间

3.4 模型诊断

残差 Q-Q 图 (图 4) 显示近似正态; 残差 vs 拟合值图无喇叭形或弯曲模式。异方差轻微存在 (低拟合区 $SD=0.46$ vs 高拟合区 $SD=0.34$), HC3 稳健标准误验证显示最大膨胀比仅 1.255 (BMI), 所有变量仍高度显著 ($|t| > 2.6$), 对推断无实质影响。CV 验证中线性形式完胜样条和指数 (Wilcoxon $p < 0.001$), 确认固定斜率模型为最优选择。




图 4: 残差诊断

3.5 效应量评估

- 留一孕妇 $CV R^2 = 0.248$: 模型在未见过的孕妇上的预测能力。
- 个体间基线差异约占总变异的 65%——Y 浓度的大部分变异来自不可观测的生物学基线。
- 孕周直接贡献约 10%，BMI 约 5%，技术 + 批次共约 10%。

4 模型 B: 中介分析

加入 X 染色体浓度（与 Y 同源，反映“胎儿 DNA 总浓度”）拆解孕周效应传递路径：

$$\tilde{y}_{it} = \beta'_0 + \beta'_1 \Delta g_{it} + \beta'_2 \text{BMI}_i^* + \beta'_X X_{it}^* + \text{constrols} + \varepsilon'_{it} \quad (2)$$

关键结果（表 2）：加入 X 后孕周系数从 +0.055 降至 +0.045（下降 21.3%），BMI 系数几乎不变（-0.029 → -0.023）。说明孕周对 Y 的影响中约 21% 通过“胎儿发育 → DNA 总量增加”间接实现，BMI 的负效应与此通路在统计上独立，与文献记载的稀释机制一致。全样本 R^2 提升至 0.441。

表 2: 中介分析对比

效应	不含 X(模型 A)	含 X(模型 B)	变化
孕周系数	0.0570	0.0449	-0.0122
BMI 系数	-0.0285	-0.0231	+0.0054
X 浓度系数	—	4.8201	—
中介比例 (孕周)	21.3%		

图 5 展示中介效应路径。




图 5: 孕周 → Y 浓度的中介效应路径

5 个体层面验证

5.1 个体轨迹

图 6 展示 9 位孕妇的 Y 浓度纵向轨迹。约 54% 的孕妇 Y 浓度单调递增，45% 波动；个体间基线差异显著（同一孕周 Y 浓度可差 3-4 倍）。

个体Y浓度轨迹示例




图 6: 9 例典型孕妇的 Y 浓度纵向轨迹

5.2 首次达标时间 vs BMI

各 BMI 组首次 $Y \geq 4\%$ 的孕周中位数 (图 7): $[20, 28)$ 12.7 周、 $[28, 32)$ 12.7 周、 $[32, 36)$ 12.9 周、 $[36, 40)$ 15.8 周、 $40+$ 19.6 周。BMI ≥ 36 晚 3-7 周。




图 7: 首次 $Y \geq 4\%$ 的孕周 vs BMI

6 与文献的一致性

Wang et al. (2013) 在 22,384 例大样本中报告胎儿 cfDNA 占比随孕周缓慢上升 (约 0.1%/周), 与母体体重显著负相关 ($p=0.0003$)。本研究发现的方向与文献一致。本数据达标率 (86.6%) 低于文献正常体重组 (97%-99%), 与题目“大多为高 BMI”一致。

7 模型假设与局限

7.1 核心假设

1. **条件对数正态性:** log 变换后残差近似正态 (偏度 -0.55, Q-Q 图可接受)。
2. **个体内线性孕周效应:** CV 验证中线性完胜样条和指数 (Wilcoxon $p < 0.001$)。
3. **批次效应可加:** CV 验证中未因该假设退化。

7.2 局限

1. $CV R^2=0.248$: 65% 的变异来自个体不可观测的生理基线差异。
2. 极端 BMI 区域稀疏 ([20, 28) 19 人、40+ 18 人) —— 系数估计和预测的可靠性有限。
3. 个体随机斜率未纳入 —— 受限于部分孕妇仅 1-2 次检测。
4. 异方差轻微存在 (低区 $SD=0.46$ vs 高区 $SD=0.34$), 但 HC3 稳健标准误验证确认不影响所有显著性结论。
5. 注意: 子问题 2/3 中使用直接计数法确定达标时点, 不依赖 $\hat{\beta}_1$ 的外推预测。

8 对后续问题的接口

- **问题 2:** $\hat{\beta}_1$ (孕周斜率) 用于预测达标时间; $\hat{\beta}_2$ 量化 BMI 对达标时间的延迟效应。
- **问题 3:** 模型框架可直接扩展 (加入年龄、IVF 等), 极端组在问题 3 中做 Bayesian shrinkage。
- **问题 4:** 技术变量控制方法可迁移用于女胎测序质量控制。