

问题 1 数学推导——Y 浓度与孕周/BMI 关系模型

MathModel AI

2026-07-19

1 符号表

符号	含义	取值/分布
i	孕妇索引, $i = 1, \dots, 267$	—
t	检测次数索引, $t = 1, \dots, T_i$, 大多数 $T_i = 4$	—
y_{it}	孕妇 i 第 t 次检测的 Y 染色体浓度	$\mathbb{R}^+$
$\tilde{y}_{it} = \ln(y_{it})$	log 变换后的 Y 浓度	$\mathbb{R}$
g_{it}	检测时孕周 (周)	$[10, 29]$
$\bar{g}_i$	孕妇 i 所有检测的平均孕周	—
$\Delta g_{it} = g_{it} - \bar{g}_i$	个体内中心化孕周	—
BMI_i	孕妇 i 的 BMI	—
$\text{BMI}_i^* = \text{BMI}_i - \overline{\text{BMI}}$	中心化 BMI	—
PC1_{it}	测序技术质量第一主成分得分	标准化后
$\text{Month}_m^{(it)}$	检测月份哑变量 ($m = 1, \dots, 16$, 基线 2023-01)	$\{0, 1\}$
α_i	个体随机截距	$\alpha_i \sim \mathcal{N}(0, \tau^2)$
ε_{it}	残差	$\varepsilon_{it} \sim \mathcal{N}(0, \sigma^2)$

2 模型 A: 主模型

2.1 模型结构

$$\tilde{y}_{it} = \beta_0 + \underbrace{\beta_1 \cdot \Delta g_{it} + \beta_2 \cdot \text{BMI}_i^*}_{\text{生物学信号}} + \underbrace{\beta_3 \cdot \text{PC1}_{it} + \sum_{m=1}^{16} \gamma_m \cdot \text{Month}_m^{(it)}}_{\text{技术/批次修正}} + \underbrace{\alpha_i}_{\text{个体基线}} + \varepsilon_{it}$$

含随机效应的总方差分解:

$$\text{Var}(\tilde{y}_{it}) = \tau^2 + \sigma^2$$

其中 τ^2 为个体间基线方差 (不可观测的生物学差异), σ^2 为残差方差。

2.2 log 变换的合理性

原始 Y 浓度偏度 = 0.70, 峰度 = 1.00, D'Agostino-Pearson $\chi^2 = 152.1, p < 0.001$, 拒绝正态性。取自然对数后, 条件残差的偏度降至 -0.55, 峰度降至 0.20, 显著改善。log 变换的附加优势:

回归系数可解释为 Y 浓度相对于基准水平的**倍数变化率**—— β_1 意为”孕周每增 1 周，Y 浓度变为原来的 e^{β_1} 倍”。

2.3 为什么用个体内中心化孕周

若将 g_{it} 直接放入回归，模型会将**个体间孕周差异**（如孕妇 A 平均检测 12 周，孕妇 B 平均检测 20 周）与**个体内孕周变化**（同一孕妇从 12 周到 16 周）混为一谈。由于个体间 Y 浓度的基线差异（ τ^2 ）远大于个体内变化，这种混淆会导致孕周系数的估计被严重稀释。个体内中心化 $\Delta g_{it} = g_{it} - \bar{g}_i$ 将模型焦点锁定在”同一个孕妇自身的变化上”，从而正确识别孕周的边际效应。

2.4 纯技术 PCA 的构造

从 5 个测序质量变量中提取第一主成分，不包含 Y 浓度和 X 浓度，以避免循环论证：

$$PC1_{it} = 0.392 \cdot z_{\text{读段数}} + 0.176 \cdot z_{\text{GC}} - 0.578 \cdot z_{\text{比对}} + 0.256 \cdot z_{\text{重复}} + 0.645 \cdot z_{\text{过滤}}$$

其中 $z_{(\cdot)}$ 为各变量标准化后的值。PC1 解释 25.0% 的测序技术变异。正的 PC1 得分对应”高过滤比例 + 低比对比例”——即测序质量较差的样本。

2.5 显著性检验

单个系数：对 $\beta_1, \beta_2, \beta_3$ 分别做 t 检验：

$$t_{\beta_k} = \frac{\hat{\beta}_k}{\text{SE}(\hat{\beta}_k)} \sim t_{n-p-1}$$

零假设 $H_0 : \beta_k = 0$ ，备择 $H_1 : \beta_k \neq 0$ 。检验水平 $\alpha = 0.05$ 。

全模型： F 检验评估所有固定效应联合显著性：

$$F = \frac{(\text{TSS} - \text{RSS})/(p)}{\text{RSS}/(n - p - 1)} \sim F_{p, n-p-1}$$

其中 p 为固定效应参数个数（不含截距）， $n = 1082$ 。

效应量：由于 $n = 1082 > 500$ ，必须同时报告效应量而非仅依赖 p 值。报告每系数对应的 Y 浓度倍率因子 $e^{\hat{\beta}_k}$ 及其 95% 置信区间。

3 模型 B：中介分析

3.1 模型结构

在模型 A 的基础上加入 X 染色体浓度：

$$\tilde{y}_{it} = \beta'_0 + \beta'_1 \cdot \Delta g_{it} + \beta'_2 \cdot \text{BMI}_i^* + \beta'_X \cdot \tilde{x}_{it} + \sum_{m=1}^{16} \gamma'_m \cdot \text{Month}_m^{(it)} + \varepsilon'_{it}$$

其中 $\tilde{x}_{it} = X_{it} - \bar{X}$ ， X_{it} 为 X 染色体浓度。

3.2 中介效应分解

X 染色体和 Y 染色体浓度均来自胎儿游离 DNA，反映同一潜在变量——“胎儿 DNA 总浓度”。模型 A 中 β_1 （含 X 不含 X 前的孕周系数）包含了孕周通过“增加胎儿 DNA 总量 → X 和 Y 同步升高”的完整效应。加入 X 后， β'_1 仅保留孕周通过其他路径（母体血容量变化、胎盘通透性等）的直接效应。

中介比例：

$$\text{Mediation Ratio} = \frac{\beta_1 - \beta'_1}{\beta_1} \times 100\%$$

控制 X 前后 BMI 系数的稳健性：

若 BMI 的负效应主要通过“母体血容量稀释胎儿 DNA”实现（即 BMI 高 → 血量大 → 总 DNA 浓度低），则加入 X（代表总 DNA 浓度）后 BMI 系数将大幅下降。若 BMI 效应保持不变，则说明 BMI 的稀释效应独立于胎儿 DNA 总量通道。

4 数学自检

4.1 共线检查

| 检查项 | 结论 | |——|——| | 孕周 g_{it} 是否间接含有 Y 浓度？ | 否。孕周独立于 Y 浓度，体外测量 | Δg_{it} 是否与 α_i 相关？ | 个体内中心化后， Δg_{it} 在个体内部均值为 0，与 α_i 无关 | | PC1 是否包含 Y 浓度？ | 否。PC1 仅从 5 个测序变量构建，Y 和 X 浓度均不在内 | | X 浓度是否与 Y 浓度有“循环论证”？ | X 和 Y 同源但模型 B 用 X 做**解释**而非**预测**，论文中不主张“用 X 预测 Y” |

4.2 量纲检查

| 项 | 变换前 | 变换后 | 一致性 | |——|——|——|——| | y_{it} | Y 浓度（比例，无量纲） | $\tilde{y}_{it} = \ln(y_{it})$ （无量纲） | | Δg_{it} | 孕周差（周） | 孕周差（周） | β_1 量纲 = 周⁻¹ | | BMI_i^* | BMI (kg/m²) | 中心化 BMI (kg/m²) | β_2 量纲 = (kg/m²)⁻¹ | | PC1_{it} | 无量纲（标准化后） | 无量纲 | β_3 无量纲 |

所有项在 log 尺度上量纲一致，通过量纲检查。

4.3 变换检查

| 变量 | 不取 log | 取 log | 原因 | |——|——|——|——| | y_{it} | （无必要） | （改善正态性） | | 因变量，已取 log | | g_{it} | | | 孕周已中心化，无需 log | | BMI | | | BMI 已中心化，无需 log | | X 浓度 | | | 已中心化，无需 log |

5 直觉解释

这个模型在做什么？

用非数学语言：同样 BMI 的孕妇，越到怀孕后期，血液中的胎儿 Y 染色体片段浓度会稍微高一点——但幅度很小，不像我们之前想的那么明显。真正让 Y 浓度波动大的是每个孕妇自己——每个人都有一个“基线水平”，有的天生偏高，有的天生偏低，这个基线差异解释了大部分变化。此外，测序仪有时“状态不好”（技术噪声）也会拉低数据，我们在 2023 年下半年看到了一次系统性的低迷。把这些都考虑进去后，我们能解释大约 23% 的整体变化——剩下的 77% 属于“每个人就是不一样”。

一个类比：Y 浓度就像考试分数。孕周 = 多复习几天的效果（微弱正效应），BMI = 天生的疲劳程度（微弱负效应），测序技术 = 当天精神好不好（批次波动），个体基线 = 每个人的”天赋”（最重要的因素）。

(Bayesian 建模将在问题 2 的极端组处理中引入，此处不详细展开，但已确认为后续阶段的计划方案。)