

问题 4 数学推导：女胎异常评分模型

MathModel AI

2026-07-19

1 问题形式化

设检测样本 i ($i = 1, \dots, N = 605$) 的特征向量包含四条染色体 Z 值：

$$\mathbf{z}_i = (z_i^{(13)}, z_i^{(18)}, z_i^{(21)}, z_i^{(X)})^T \in \mathbb{R}^4$$

另有标注样本子集 $\mathcal{L} \subset \{1, \dots, N\}$ ($|\mathcal{L}| = 67$)，每个标注样本携带标签 $y_i \in \{0, 1\}$ (0: 正常, 1: 异常)。

目标：构造评分函数 $S: \mathbb{R}^4 \rightarrow \mathbb{R}^+$ ，使得 $S(\mathbf{z}_i)$ 与异常概率单调正相关，并基于标注样本确定判别阈值。

2 第一层：GC Bias 校正

2.1 动机

总体 GC 含量 γ_i (取值范围 0.3677–0.4435) 反映测序文库的 GC 偏好。当 γ_i 偏离典型值，测序覆盖度出现系统性偏差，进而污染 Z 值估计。A 类实验证实： $\gamma_i < 0.4$ 的样本 18 号染色体 Z 值均值比正常组高 45%，X 染色体高 121%。此偏差非生物学信号，需在评分前剥离。

2.2 Loess 校正

对每条染色体 $k \in \{13, 18, 21, X\}$ ，在全部 605 个样本上拟合局部加权回归：

$$f^{(k)}(\gamma) = \text{loess}(\gamma, z_{\text{raw}}^{(k)}; \text{span} = 0.75)$$

校正后 Z 值：

$$\tilde{z}_i^{(k)} = z_{i,\text{raw}}^{(k)} - f^{(k)}(\gamma_i)$$

2.3 合理性论证

1. 非参数性：loess 不对 $f^{(k)}$ 预设函数形式，避免错误假设引入偏差。
2. **span** = 0.75：覆盖 75% 邻域样本，在局部拟合精度与平滑性间取平衡。灵敏度分析验证 $\text{span} \in \{0.5, 0.75, 0.9\}$ 下结果稳定。
3. 加性校正假设： $Z_{\text{observed}} = Z_{\text{biological}} + f(\text{GC}) + \varepsilon$ ，即 GC 偏差以加性方式叠加。这在 NGS 领域中类比 Benjamini & Speed (2012) 的 CAS-CA 方法，被广泛应用于 ChIP-seq 和 CNV 检测。

2.4 校正效果

校正后正常样本 ($y_i = 0$) 的 $\tilde{z}_i^{(k)}$ 均值均接近 0，GC 依赖被消除。校正前后正常样本 Z 值均值对比见表 ??。

表 1: GC 校正前后正常样本 Z 值均值

染色体	校正前	校正后	R^2
13	0.455	0.023	0.138
18	0.808	0.050	0.087
21	-0.139	-0.009	0.048
X	0.505	0.006	0.069

3 第二层：异常评分函数

3.1 参考分布估计

令 $\mathcal{N} = \{i : y_i = 0\}$ 为标注正常样本集 ($|\mathcal{N}| = 538$)。在 GC 校正后的 Z 值空间上估计参考分布：

$$\bar{\mu}_0 = \frac{1}{|\mathcal{N}|} \sum_{i \in \mathcal{N}} \tilde{z}_i$$

3.2 稳健协方差估计

预处理阶段 Mardia 检验拒绝多元正态性假设 ($p < 0.001$)，说明存在离群点可能污染经典协方差矩阵。采用 Minimum Covariance Determinant (MCD) 估计稳健协方差：

$$\hat{\Sigma}_{\text{MCD}} = \arg \min_{\Sigma \in \mathcal{S}} \det(\Sigma)$$

其中 $\mathcal{S}$ 为覆盖 $h = \lfloor 0.75 \cdot |\mathcal{N}| \rfloor$ 个子样本的协方差矩阵集合。MCD 通过排除最具影响力的 25% 观测值，抵御离群点的杠杆效应。

3.3 马氏距离评分

$$S_i = (\tilde{\mathbf{z}}_i - \bar{\boldsymbol{\mu}}_0)^T \hat{\Sigma}_{\text{MCD}}^{-1} (\tilde{\mathbf{z}}_i - \bar{\boldsymbol{\mu}}_0)$$

3.3.1 直觉含义

S_i 是在考虑了各染色体 Z 值之间的相关性后，样本 i 偏离「正常群体中心」的距离。若四条染色体 Z 值相互独立且方差均为 1，则 S_i 退化为欧氏距离平方 $\sum_k (\tilde{z}_i^{(k)})^2$ 。但实际 Z 值间存在正相关（如 13 号与 18 号 Z 值 $\rho = 0.45$ ），马氏距离通过 $\hat{\Sigma}_{\text{MCD}}^{-1}$ 将此相关性纳入考量——两个 Z 值同时偏高时， S_i 的增长幅度小于它们独立偏高时的简单加和，因为“一起偏高”在正常群体中比“单独偏高”更常见。

3.3.2 为何不依赖正态假设

标准马氏距离下 $S_i \sim \chi_4^2$ 要求数据多元正态。本数据不满足该假设，但我们不将 S_i 用于假设检验——它仅作为样本排序的连续评分。阈值 τ^* 由下文的 ROC 校准确定，不依赖 χ^2 分位数。因此非正态性不构成实质威胁。

3.4 染色体边际贡献分解

对评分超过阈值的样本，需要定位嫌疑人染色体。定义染色体 k 的边际贡献：

$$\Delta S_i^{(k)} = \frac{(\tilde{z}_i^{(k)} - \bar{\mu}_0^{(k)})^2}{\hat{\sigma}_k^2}$$

其中 $\hat{\sigma}_k^2 = [\hat{\Sigma}_{\text{MCD}}]_{kk}$ 。 $\Delta S_i^{(k)}$ 最大的染色体为最可疑异常源。注意此处简单分解忽略了协方差项，仅作为定性指向而非精确分解。

4 第三层：阈值校准与分类

4.1 ROC 分析

对标注样本（按孕妇代码去重后），逐一对阈值候选 τ 计算：

$$\text{TPR}(\tau) = \frac{|\{i \in \mathcal{L} : y_i = 1, S_i \geq \tau\}|}{|\{i \in \mathcal{L} : y_i = 1\}|}$$

$$\text{FPR}(\tau) = \frac{|\{i \in \mathcal{L} : y_i = 0, S_i \geq \tau\}|}{|\{i \in \mathcal{L} : y_i = 0\}|}$$

遍历 τ 绘制 ROC 曲线，以 Youden 指数最大化确定最优阈值：

$$\tau^* = \arg \max_{\tau} (\text{TPR}(\tau) - \text{FPR}(\tau))$$

报告 AUC（ROC 曲线下面积）作为评分函数的整体判别能力。

4.2 三分类输出

$$\text{判定}_i = \begin{cases} \text{高风险异常,} & S_i \geq \tau^* \text{ 且 } \max_k \Delta S_i^{(k)} > \theta_{\min} \\ \text{不确定/需复检,} & \tau_{\text{lower}} \leq S_i < \tau^* \\ \text{低风险,} & S_i < \tau_{\text{lower}} \end{cases}$$

其中 τ_{lower} 为 $\text{TPR} = 0.95$ 对应的阈值（宁可多报不漏报）， $\theta_{\min}$ 为防止评分略超阈值但无突出染色体贡献的情况。

4.3 样本权重说明

标注样本中 18 个孕妇出现重复（同一孕妇多次检测均异常），ROC 分析时按孕妇代码去重，保留最新一次检测。这确保每个孕妇在 ROC 中只有一票，避免多次检测的孕妇人为膨胀样本量。

5 后续验证项目

不在本推导中展开但需在阶段 2.1-2.2 执行的验证：

1. **MCD 稳定性：** $h = 0.75$ 与 $h = 0.5$ 下 $\hat{\Sigma}_{\text{MCD}}$ 差异，验证结果对 MCD 超参数不敏感
2. **校正前后 AUC 对比：**原始 Z 值的 AUC vs GC 校正后 Z 值的 AUC，量化 GC 校正的增益
3. **标注偏差分析：**对比标注样本与全体样本的特征分布（BMI、年龄、孕周），评估校准集是否代表总体
4. **41 条 Z 异常无标签样本：**在评分体系中自然归类，不强行贴标签
5. **标注样本内部验证：**留一法交叉验证 ROC，评估阈值稳定性