

S1 内部报告：GPU 需求预测与基础算力调度

MathModel 建模小组

2026-08-09

1 子问题概述

S1 子问题要求：(1) 对 GPU 需求进行统计分析；(2) 构建短期预测模型；(3) 建立基础算力调度模型，给出第 2376–2399 小时实际到达任务的调度方案，展示最后 24 小时调度甘特图和区域 GPU 利用率。

经阶段 1 方案探索，最终采用（人类裁定）：**Alpha 精确 MILP 调度（零跨区迁移、时间维调度、逐时利用率极差最小化）为主方案，Beta 贪心启发式作 B 类 head-to-head 对比基准。**预测段以”白噪声证明 + 简单基线”为口径（决策点 2：总序列 + 分类型双粒度）；阶段 3.2 已补四重对抗检验（BDS / Prophet / LSTM / Granger，公式见 `solution/model-notes/math-sub1.tex` § 预测段四重统计检验），结论未被动摇。

2 数据与预处理

数据源为 50,000 条 AI 任务轨迹(`workload_trace.xlsx`)与六区域 GPU 容量(`GPU_information.xlsx`)。阶段 1.4 预处理产出 `outputs/data/s1-preprocessed.pkl`，按赛题协议切分：0–2351 训练 / 2352–2375 调参 / 0–2375 重训 / 2376–2399 测试（滞后特征预热 168h，有效样本从 $t = 168$ 起）。

测试窗(2376–2399 到达)共 538 任务:194 训练 / 184 批量 / 160 实时。任务属性:GPU_Demand $\in [1, 127]$ （长尾右偏）、时长 $D_j \in [0.167, 6.65]$ h（精确小数折算）、训练/批量 LatestFinishHour 全部 = 2406（100% 弹性）。

3 统计段：GPU 需求分布与白噪声证明

3.1 逐时需求序列

按到达小时聚合 GPU 需求（式 1）：

$$Y_t = \sum_{j: A_j=t} g_j, \quad t = 0, \dots, 2399. \quad (1)$$

Total 序列：均值 614.0、标准差 208.4、峰值 1313，零值占比 0%。分类型占比：AITraining 80.1% / BatchInference 15.3% / RealTimeInference 4.6% ——训练任务为 GPU 容量占用主体。

3.2 白噪声证明

对 Total 及分类型序列计算样本 ACF（lag 1–200），全部 ≈ 0 （lag24 均在 ± 0.01 内，无日周期；lag168 亦无周周期）。任务到达计数均值 $\approx 20.8/\text{h}$ ，近似泊松。

不可预测性论证（阶段 3.1 修订）：逐时需求 $Y_t = \sum_{A_j=t} g_j$ 为复合泊松，其方差 $\text{Var}(Y) = \lambda \mathbb{E}[g^2] \approx 20.8 \times 2086 \approx 43,400$ （约为均值 614 的 70 倍），故**不能用泊松**”方差 $\approx$ 均值”性质论证预测下界。正确的下界论证链为：样本 ACF ($\text{lag } 1-200$) $\approx 0 \Rightarrow$ 在**线性预测框架**下， Y_t 与历史无显著线性依赖 $\Rightarrow$ 最优线性预测 $\approx$ 无条件均值 $\Rightarrow$ 常数均值基线的 RMSE (221.0) 即为该框架下的近似最优。

四重对抗检验（阶段 3.2 补证，2026-08-09）：阶段 3.1 曾限定”非线性结构（方差聚集/状态切换）未被检验”。该缺口已闭合——B 类阶段对同一序列执行四重检验（完整公式与结果表见 [solution/model-notes/math-sub1.tex](#) § 预测段四重统计检验）：

1. **BDS 非线性依赖检验** ($m = 2, 3, 4$)：Total 及分类型序列全部 $p \geq 0.30$ ，不拒绝 i.i.d. $\Rightarrow$ 任意 $m \leq 4$ 维依赖不存在，非线性结构（GARCH/状态切换）无可学信号；
2. **Prophet 对照**（日/周傅里叶季节）：测试窗 RMSE 214.7，仅优于常数均值 +2.9% ($< 5\%$ 判据)，且调参窗 186.4 低于测试窗 214.7（性能倒挂） $\Rightarrow$ 周期结构不存在；
3. **LSTM 对照**（滞后 24h 滚动一步 + 早停）：测试窗 RMSE 221.5，较均值基线**更差** (-0.2%)，调参窗 180.7 严重退化 $\Rightarrow$ 白噪声过拟合，无非线性记忆可学；
4. **Granger 因果**（跨类型 6 组 + 跨区域 4 组，VAR(3)）：最小 $p = 0.0607$ ，全部 $p > 0.05 \Rightarrow$ 无跨序列因果路径，外生变量预测路线不可行。

结论：可预测性的四条路径（线性依赖 / 非线性依赖 / 周期结构 / 横截面因果）全部检验完毕且均未发现可利用结构，”近乎不可预测”由单一 ACF 证据升级为五组独立证据。该发现是预测段叙事的基础。




图 1: 逐时 GPU 需求时序（上）与 ACF（下，lag1-200 全部 ≈ 0 ）：白噪声证明

4 预测段：简单基线对比

诚实口径下（训练窗均值外推，**无测试窗信息泄漏**）测试窗 RMSE:

预测基线	RMSE	MAPE
常数均值（训练窗外推）	221.0	23.4%
线性回归（周期特征）	215.4	23.1%
Last-Hour 朴素	293.5	34.5%
季节朴素（lag24）	331.5	37.7%

表 1: 测试窗 2376–2399 预测基线对比（诚实口径）

线性回归仅略优于常数均值（提升 2.5%），周期特征近乎无信息。**功效说明（阶段 3.1 修订）**：测试窗仅 24 个评价点，RMSE 估计的采样波动 $\approx 215/\sqrt{2 \times 24} \approx 31$ ，大于两基线差距（5.6）——该证据 **不能区分**“线性回归略优”与“二者等价”，结论限定为“24 个测试点上无法显著区分二者，且线性框架未发现可预测结构”。结合白噪声证明与阶段 3.2 四重对抗检验（Prophet +2.9%、LSTM -0.2%、BDS 与 Granger 均不显著），预测段结论为：**未发现任何可利用的可预测结构，以简单基线为最终口径**（阶段 1 曾核销 Prophet/LSTM 对比；该对比已补做，结果见 solution/model-notes/math-sub1.tex § 预测段四重统计检验）。




图 2: 测试窗 2376–2399 预测 vs 实际（4 基线，竖虚线分隔训练/预测期）

5 调度段：Alpha 精确 MILP

5.1 模型概要

决策变量 $x_{j,h} \in \{0,1\}$ （自由任务 j 在候选小时 h 开工），实时任务固定到达即开工。约束：(C1) 恰好开工一次；(C2) GPU 容量逐时约束（重叠系数 $a_{j,h,t} = g_j \cdot |[h, h + D_j) \cap [t, t + 1)|$ 精确折算）；(C3) 完成时限由窗口蕴含。目标为字典序两阶段：先可行性（容量松弛 $\rightarrow 0$ ），再均衡（ $\min(U_{\max} - U_{\min})$ ，逐时利用率极差）。

功率惰性假设（阶段 3.1 补充）：IT 功率约束由 GPU 容量约束蕴含（AI_IT_Load $\leq$ GPU_running $\times 0.16$ MW/GPU，A 类验证 F5 余量 3.1–4.7 $\times$ ）。设施功率 = IT $\times$ PUE（PUE ≤ 1.38 ）余量缩至约 2.2–3.4 $\times$ ，且时移堆叠放大同刻功率——量级上仍安全，但本模型未显式检验设施功率最坏情形（最坏时移堆叠下的峰值），属轻级假设局限。

求解: scipy.milp (HiGHS), 5768 个 0-1 变量, **472s 收敛至最优 (status=0)**。完整推导见 `solution/model-notes/math-sub1.tex`。目标口径说明(阶段 3.1 Q3 补实验): 极差目标(本模型主目标)的调度在测试窗同口径下成本高于”成本最小化”目标 19.21%(成本目标基线 3.89 vs 极差基线 4.82 M 元)——极差目标的时移选择并非成本最优。S2 基线采用 `obj=cost` (见 `iter-03-sub2`), 本报告极差目标用于利用率均衡评价, 两者目标不同、不可混比。

5.2 head-to-head 结果

方案	逐时利用率极差	利用率方差	超容量小时	求解时间 (s)
Alpha (精确 MILP)	0.6283	0.043992	0	472.4
Beta (贪心启发式)	0.8398	0.037166	0	<1

表 2: S1 基础调度 head-to-head 对比

Alpha 在极差口径胜出 (-25.2%), Beta 在方差口径胜出 (+18.4%)。两方案均满足全部硬约束(超容量 0)。调度结果与时域合规核验(结束 > 2406 违规 0、实时未到达即开工 0)已在阶段 2.1.5 门禁通过。

6 区域逐时 GPU 利用率 (Alpha vs Beta, 含收尾时段)




图 3: 6 区域逐时 GPU 利用率 (Alpha vs Beta, 含收尾时段; 两方案区域均值相同, 差异在逐时形态)

5.3 调度策略解读

综合讨论章节(第 6 节)的结论, 本模型刻画的基础调度策略为 ”目标引导时移、容量驱动兜底”:

1. **时移以均衡为目标**: 零时移测试显示仅 RegionF 存在 3 小时容量超限, 其余五区域完全可行——即绝大多数任务延后开工并非容量所迫, 而是均衡目标(削峰填谷)主动引导的结果。

2. **早排为主、晚排为辅**：拐角解中 155 个任务（91%）到达即开工（先填谷），仅 16 个（9%）拖至最晚（填峰后时段）——调度策略偏好”能早则早”，只有削峰需要时才延后。**归因局限（阶段 3.1 补充）**：该策略解读基于 HiGHS 返回的 **单一最优解**——极差目标下 MILP 常存在大量等价最优解（拐角解占比 45.2% 为征兆），未做解稳定性检验（扰动目标系数/随机起点/二次目标）；换一个等价最优解，”早排为主”叙事可能变化。归因描述为”目标引导下该求解器偏好”而非唯一策略。
3. **极差口径是策略靶点**：零迁移下各区域利用率均值恒定，调度能改变的唯一维度是逐时形态；以极差为靶点等价于压缩”最高/最低负荷点”，直接对应运营方削峰填谷的工程诉求。**口径局限（阶段 3.1 补充）**：极差由全局最高/最低两个时点决定，对离群小时敏感，且未按区域容量加权（小容量区域形态主导目标）；方差口径下 Beta 反而占优（+18.4%），”谁更优”取决于口径选择——S4 多目标权衡中同时报告极差与方差两指标保持透明。
4. **收尾时段为软缓冲区**：弹性任务延后至 [2400,2406) 即等效于”用收尾容量吸收延迟”，但该缓冲区未预留时长安全裕度（时长 +50% 时 57% 收尾任务违规），对 S2/S4 的鲁棒性设计构成输入。**口径说明（阶段 3.1 补充）**：本目标含收尾时段利用率（图 3 标注”含收尾时段”），极差计算覆盖 [0,2406)；22.4% GPU-hour 集中于收尾窗，属均衡目标的边界效应，非工程必需。




图 4: 最后 24h 调度甘特图（Alpha，按任务类型 3 分面，红虚线右为收尾时段 [2400,2406)，任务条含跨 2399 的收尾任务）

时段	GPU-hour	占比
主窗 [2376,2400)	46,551	77.6%
收尾 [2400,2406)	13,435	22.4%

表 3: Alpha 调度 GPU-hour 时段分布

5.4 收尾时段负载

96 个任务在收尾时域开工，收尾 6h 承载 22.4% 结清负载——末端结清压力值得 S2/S4 关注（弹性任务延后与收尾容量预留的权衡）。

6 讨论：未闭合问题的专门分析

阶段 2.2 结果分析提出 4 个未闭合问题，本节基于补充证据逐条深入。

6.1 问题一：拐角解 45.2% 的成因——容量宽松还是目标引导？

观测：378 个自由任务中 171 个（45.2%）开工在候选窗口边缘（位置 $\leq 2\%$ 或 $\geq 98\%$ ）。其中早边缘（到达即开工）155 个（91%）、晚边缘（拖到最晚）仅 16 个（9%）。

补充证据：

1. 若全部任务到达即开工（零时移），仅 RegionF 出现 3 小时超容量（峰值 1048/966），其余五区域零超容量——时移在绝大多数情形并非容量驱动。
2. 晚边缘任务窗口跨度中位 13.7h（非紧迫），说明拖到最晚是主动选择而非被迫。
3. 边缘解与中间解在 GPU 需求、时长上无显著差异（dem 中位数均 23），排除”大任务必须边缘排”的机制。

结论：拐角解主要由均衡目标引导而非容量压力。具体机制：155 个早边缘任务（训练 74 + 批量 81）到达即开工，是削峰操作中”先填谷”的自然结果——当某时段容量空闲时，目标函数倾向将其立即排入以平滑利用率；16 个晚边缘任务则是”填峰后时段”的延后放置。仅 RegionF 的 3h 超容量构成 **真实容量驱动**的时移（强制延后）。因此拐角解是”目标引导为主、容量驱动为辅”的混合形态，对调度策略无负面含义。

6.2 问题二：均衡口径敏感性——极差 vs 方差

观测：Alpha 优化极差（0.6283）在方差口径（0.043992）劣于 Beta（0.037166）；Beta 反之。

机理：极差与方差是利用率分布的两个不同统计量。极差仅取决于最大值与最小值两个点；方差则考虑全部分布。

- Alpha 压缩峰值/抬升谷值：B 区峰值 0.634→0.439（Beta 方案 0.634），但 E/F 区峰值反而更高（E 0.640 vs Beta 0.703 反超不明显，F 0.641 vs 0.853）。
- Beta 整体收紧方差：各区域峰值更均衡（B 0.439、C 0.324），但极差被”谷值太低”推大。
- **关键事实：**两方案各区域利用率均值完全相同（零迁移下 GPU-hour 总量恒定）——差异 100% 在逐时形态，而非总体水平。

结论：口径选择决定”谁更优”的叙事。S1 采用极差口径的理由：(1) 它直接对应”削峰填谷”的工程语义（运营者关心的是最高/最低负荷点）；(2) 极差是 MILP 可精确线性化的目标（方差需二次规划）。**风险：**若评审者偏好方差口径，Alpha 优势消失——论文须明确定义并论证极差口径的合理性，并在 S4 多目标中同时报告两个指标以保持透明。

6.3 问题三：白噪声下预测提升空间的边界

观测：ACF 全滞后 ≈ 0 、到达近似泊松、常数均值 RMSE 221.0 与线性回归 215.4 差距仅 2.5%。

四重检验补充（阶段 3.2，2026-08-09）：阶段 3.1 遗留的”非线性结构未被检验”缺口已闭合——BDS 不拒绝 i.i.d. ($p \geq 0.30$)、Prophet 仅 +2.9% 且性能倒挂、LSTM -0.2%（过拟合）、Granger 全不显著 ($p > 0.05$)。四条可预测性路径均无结构可利用。

理论边界：若到达过程近似泊松（强度 $\lambda \approx 20.8/h$ ），则逐时需求 Y_t 的方差 $\approx$ 均值（泊松性质），最优预测误差下界由泊松固有波动决定——即”预测不可能显著优于均值基线”，除非捕捉到 GPU_Demand 的条件分布（需求大小与到达时刻的联合结构）。

可探索方向（不纳入 S1）：事件级到达建模（Hawkes 过程）或”需求大小条件分布”预测可能小幅提升，但对调度无实际收益（S1 按实际到达调度，赛题规定预测仅用于评价）。**边界声明：**本报告不宣称”预测无价值”，而是”在本数据特征下简单基线已接近信息论下界”，该下界论证现已由四重检验（而非仅 ACF）支撑。

6.4 问题四：收尾时段负载——更长任务是否结清紧张？

观测：96 个任务收尾开工，收尾 6h 承载 22.4% GPU-hour；收尾任务时长均值 2.40h、最大 5.92h。

压力测试：若任务时长 +50%，96 个收尾任务中 55 个将超出时点 2406（违规），说明当前解没有为时长误差留裕度。

机理：S1 调度按精确小数时长排程（人类决策），未引入安全裕度。零迁移 + LatestFinish=2406 的设定使收尾时段成为唯一”软缓冲区”——弹性任务被推到收尾即等效于”用收尾容量吸收延迟”。

结论与启示：S1 无安全裕度是口径一致的（按声明时长排程），但暴露三类风险：(1) 时长高估误差直接转化为违规（+50% 时 57% 收尾任务违规）；(2) S2 引入迁移后收尾时段还要承载跨区域结清，压力更大；(3) 建议 S4 场景分析加入”时长不确定 $\pm 20\%$ ”的鲁棒性检验。S1 阶段保持现状（诚实口径），将鲁棒性讨论移交 S4。

7 结论

1. GPU 需求序列近乎不可预测（白噪声证明 + BDS/Prophet/LSTM/Granger 四重对抗检验，阶段 3.2），简单基线（线性回归 215.4）已接近信息论下界。
2. Alpha 精确 MILP 在极差口径显著优于 Beta 贪心（-25.2%），且最优性可证（status=0）；方差口径 Beta 更优——口径敏感性已在讨论节充分呈现。
3. 基础调度策略为”目标引导时移、容量驱动兜底”：时移绝大多数是均衡目标主动引导（零时移仅 RegionF 3h 超限），策略偏好”能早则早”，仅削峰需要时延后。
4. 收尾时段承载 22.4% 负载且未预留时长安全裕度（时长 +50% 时 57% 收尾任务违规），为 S2/S4 的鲁棒性设计提供明确输入。