

S1 数学推导：GPU 需求预测与基础算力调度

MathModel 建模小组

2026-08-08

1 问题形式化

S1 子问题由三段组成：统计（GPU 需求分布与白噪声证明）、预测（短期预测基线）、调度（测试窗 2376–2399 实际到达任务的零迁移基础调度）。本文件给出调度段（主方案 Alpha）的完整数学推导，并附预测段的统计口径。

1.1 索引与基本集合

$$\mathcal{R} = \{\text{RegionA}, \dots, \text{RegionF}\}, \quad |\mathcal{R}| = 6, \quad (1)$$

$$\mathcal{J} = \{j_1, \dots, j_{N_{\text{test}}}\}, \quad N_{\text{test}} = 538, \quad (2)$$

$$\mathcal{J}^{RT} \subseteq \mathcal{J} \quad \text{实时推理任务（到达即开工）}, \quad |\mathcal{J}^{RT}| = 160, \quad (3)$$

$$\mathcal{J}^F = \mathcal{J} \setminus \mathcal{J}^{RT} \quad \text{自由任务（训练 + 批量）}, \quad |\mathcal{J}^F| = 378, \quad (4)$$

$$\mathcal{T} = \{2376, 2377, \dots, 2405\} \quad \text{调度小时索引（2406 仅结算，不安排任务）}. \quad (5)$$

1.2 任务属性参数

每个任务 j 具有以下给定属性（来自 workload_trace.xlsx，阶段 0.3 清洗后）：

符号	物理意义	取值/单位
A_j	到达小时（= 最早开工小时）	[2376, 2399], h
D_j	任务时长（精确小数折算）	[0.167, 6.65], h
g_j	GPU 需求（等效 GPU 数）	[1, 127], 无量纲
L_j	最晚完成小时	训练/批量均为 2406, h
$r(j)$	来源区域	$\mathcal{R}$
$k(j)$	任务类型	RT / Batch / Training

其中 $D_j = \text{EstimatedDuration_min}_j/60$ （人类决策：精确小数，不用整数小时近似）。

2 调度模型（主方案 Alpha）

2.1 决策变量

$$x_{j,h} \in \{0, 1\}, \quad j \in \mathcal{J}^F, \quad h \in \mathcal{W}_j, \quad (6)$$

其中候选窗口

$$\mathcal{W}_j = \{h \in \mathcal{T} : A_j \leq h \leq \min(L_j, 2406) - D_j\}. \quad (7)$$

实时任务不设变量： $x_{j,A_j} = 1$ 固定（到达即开工）。

2.2 约束

(C1) 恰好开工一次：

$$\sum_{h \in \mathcal{W}_j} x_{j,h} = 1, \quad \forall j \in \mathcal{J}^F. \quad (8)$$

(C2) GPU 容量（跨小时重叠精确折算）：对每个区域 $r \in \mathcal{R}$ 、每个小时 $t \in \mathcal{T}$ ，

$$\underbrace{\sum_{j \in \mathcal{J}^F: r(j)=r} \sum_{h \in \mathcal{W}_j} a_{j,h,t} x_{j,h}}_{\text{自由任务占用}} + \underbrace{B_{r,t}}_{\text{实时固定占用}} \leq \text{Cap}_r, \quad (9)$$

其中重叠系数（常数，约束仍为线性）

$$a_{j,h,t} = g_j \cdot |[h, h + D_j) \cap [t, t + 1)| = g_j \cdot \max(0, \min(h + D_j, t + 1) - \max(h, t)). \quad (10)$$

$B_{r,t}$ 为实时任务在区域 r 小时 t 的固定 GPU-hour 占用（到达即开工，重叠折算同式 (10)）。

(C3) 完成时限：由窗口 (7) 蕴含 $h + D_j \leq \min(L_j, 2406)$ 。

(C4) 功率与时延约束：阶段 1.1 A 类验证 F5/F6 证明其在零迁移下为惰性约束（IT 功率余量 3.1–4.7 倍、同区时延 5ms 恒满足），不显式建模。论证见 §5。

2.3 目标函数（字典序两阶段）

2.3.1 阶段一：可行性

$$\min Z_1 = \sum_{r,t} s_{r,t} \quad \text{s.t.} \quad \sum_{j,h} a_{j,h,t} x_{j,h} + B_{r,t} - s_{r,t} \leq \text{Cap}_r, \quad s_{r,t} \geq 0. \quad (11)$$

F3 已证 $Z_1 = 0$ 可达（实时峰值利用率 $\leq 12.6\%$ ，训练/批量 GPU-hour 占容量 $\leq 48.7\%$ ）。

2.3.2 阶段二：逐时利用率均衡

定义区域 r 小时 t 的 GPU 利用率

$$u_{r,t} = \frac{\sum_{j,h} a_{j,h,t} x_{j,h} + B_{r,t}}{\text{Cap}_r}. \quad (12)$$

$$\min Z_2 = U_{\max} - U_{\min}, \quad (13)$$

线性化约束：

$$u_{r,t} \leq U_{\max}, \quad u_{r,t} \geq U_{\min}, \quad \forall r, t. \quad (14)$$

口径说明（关键）：零迁移下各区域 GPU-hour 总量恒定，故”区域平均利用率”不可被调度改变；真正可均衡的是**区域内逐时形态**。 Z_2 即逐时利用率极差，等价于削峰填谷。实证（B 类）：Alpha 极差 0.6283 vs Beta 0.8398，精确解在该口径显著更优。

3 预测段统计口径

3.1 预测目标序列

$$Y_t = \sum_{j: A_j=t} g_j, \quad t = 0, \dots, 2399, \quad (15)$$

即每小时到达任务的 GPU 需求总量；分类型序列 $Y_t^{(k)}$ 同理（决策点 2：双粒度，总序列 + 3 类型）。

3.2 简单基线（诚实口径）

- 常数均值： $\hat{Y}_t = \bar{Y}_{\text{train}}$ （训练窗均值外推，**无测试窗信息泄漏**）。
- Last-Hour： $\hat{Y}_t = Y_{t-1}$ 。
- 季节朴素 lag24： $\hat{Y}_t = Y_{t-24}$ 。
- 线性回归： $\hat{Y}_t = \beta_0 + \beta_1 t + \sum_{p \in \{24, 168\}} \left(\alpha_p \sin \frac{2\pi t}{p} + \gamma_p \cos \frac{2\pi t}{p} \right)$ 。

赛题协议切分：0–2351 训练 / 2352–2375 调参 / 0–2375 重训 / 2376–2399 测试；滞后特征预热 168h（有效样本从 $t = 168$ 起）。

3.3 白噪声证明

对序列 Y_t 计算样本自相关 $\hat{\rho}_k$ ($\text{lag } k = 1, \dots, 200$)，全部 ≈ 0 ；到达计数近似泊松（mean $\approx 20.8/\text{h}$ ）。结论：序列近乎不可预测，预测段以”白噪声证明 + 简单基线”为叙事（B 类确认线性回归 RMSE 215.4–216.1 仅略优于常数均值 221.0–221.1，提升 $< 2.3\%$ ）。ACF 仅排除线性自相关；为排除非线性依赖、周期结构与横截面因果等其余可预测性来源，B 类阶段补充四重对抗检验，公式与结果见 §4。

4 预测段四重统计检验（B 类对抗验证）

对”逐时 GPU 需求近乎不可预测”结论做对抗性检验，覆盖可预测性的四条可能路径：非线性依赖（BDS）、周期结构（Prophet）、非线性记忆（LSTM）、横截面因果（Granger）。全程遵守赛题协议（训练 0–2351 / 调参 2352–2375 / 重训 0–2375 / 测试 2376–2399），无测试窗信息泄漏。判据：相对常数均值基线测试窗 RMSE 提升 $< 5\%$ 视为”无实质改善”。

4.1 T1 BDS 非线性依赖检验

ACF $\hat{\rho}_k \approx 0$ 只能排除**线性**自相关；若序列存在非线性依赖（GARCH 类波动聚集、阈值效应等），LSTM 等模型仍可能获益。BDS 检验（Brock–Dechert–Scheinkman, 1996）对任意 m 维嵌入依赖结构敏感，原假设 H_0 ：序列 *i.i.d.*。

对样本 $\{Y_t\}_{t=1}^T$ ，定义 m 维嵌入向量 $Y_t^m = (Y_t, \dots, Y_{t-m+1})$ ，相关积分

$$C_m(\varepsilon) = \frac{2}{(T-m+1)(T-m)} \sum_{s < t} \prod_{i=0}^{m-1} \mathbf{1}\{|Y_{s+i} - Y_{t+i}| \leq \varepsilon\}, \quad (16)$$

取 $\varepsilon = 1.5 \hat{\sigma}_Y$ 。BDS 统计量在原假设下渐近标准正态：

$$W_{m,T}(\varepsilon) = \sqrt{T-m+1} \frac{C_m(\varepsilon) - C_1(\varepsilon)^m}{\hat{\sigma}_m(\varepsilon)} \xrightarrow[H_0]{d} \mathcal{N}(0, 1), \quad (17)$$

其中 $\hat{\sigma}_m^2(\varepsilon)$ 为原假设下相关积分渐近方差 (Brock et al., 1996)。双侧 $p < 0.05$ 拒绝 H_0 。

序列	$p(m=2)$	$p(m=3)$	$p(m=4)$	判定
Total (逐时 GPU 需求)	0.4004	0.8208	0.7652	不拒绝 H_0 ($\approx$ i.i.d.)
AITraining	0.7363	0.9130	0.7801	不拒绝 H_0
BatchInference	0.3073	0.5551	0.3440	不拒绝 H_0
RealTimeInference	0.5504	0.5769	0.7321	不拒绝 H_0

全部 $p \geq 0.30$ ：不仅线性自相关，任意 $m \leq 4$ 维的非线性依赖结构亦不存在。

4.2 T2 Prophet 对照检验

Prophet 将序列分解为趋势与傅里叶周期项：

$$Y_t = g(t) + s_{\text{day}}(t) + s_{\text{week}}(t) + \varepsilon_t, \quad s_p(t) = \sum_{n=1}^{N_p} \left(a_n \cos \frac{2\pi nt}{p} + b_n \sin \frac{2\pi nt}{p} \right), \quad (18)$$

开启日周期 ($p = 24$) 与周周期 ($p = 168$) 傅里叶项。若序列存在真实周期结构，Prophet 应显著优于常数均值。

阶段	RMSE	MAPE
调参窗 2352–2375	186.4	32.7%
测试窗 2376–2399	214.7	22.6%

测试窗提升仅 +2.9% ($< 5\%$)，且调参窗 (186.4) 显著低于测试窗 (214.7) ——该“提升”为样本间波动，不具备泛化性：周期结构不存在。

4.3 T3 LSTM 对照检验

单层 LSTM (16 隐单元)，输入 = 滞后 24h 窗口 $[Y_{t-24}, \dots, Y_{t-1}]$ ，输出 $= \hat{Y}_t$ ，滚动一步预测；训练于 0–2351，调参窗早停选最优 epoch，归一化统计量仅由训练窗估计。若存在非线性时序记忆，LSTM 应优于均值基线。

阶段	RMSE	说明
调参窗最优 (早停)	180.7	训练窗内表现
测试窗 2376–2399	221.5	泛化表现

测试窗 LSTM RMSE = 221.5，较常数均值 221.1 更差 (-0.2%)；调参窗 180.7 到测试窗 221.5 的严重退化是典型的“对白噪声过拟合”。

4.4 T4 跨类型 / 跨区域 Granger 因果检验

若某序列（如训练任务到达）能 Granger 原因解释目标序列，则可借外生路径提升预测。对候选原因 X 与目标 Y ，比较受限与不受限回归：

$$\text{受限: } Y_t = \alpha_0 + \sum_{i=1}^p \alpha_i Y_{t-i} + u_t, \quad \text{不受限: } Y_t = \alpha_0 + \sum_{i=1}^p \alpha_i Y_{t-i} + \sum_{i=1}^p \beta_i X_{t-i} + v_t, \quad (19)$$

$H_0: \beta_1 = \dots = \beta_p = 0$ (X 不 Granger 原因 Y)，检验统计量

$$F = \frac{(\text{RSS}_r - \text{RSS}_u)/p}{\text{RSS}_u/(T - 2p - 1)} \sim F(p, T - 2p - 1), \quad (20)$$

取 $p = 3$ ；判定规则：“ ≥ 2 个滞后阶显著才判”存在因果”（抑制多重检验假阳性）。

原因 X	目标 Y	lag= 1	lag= 2	lag= 3	判定
AITraining	BatchInference	0.4013	0.5668	0.6724	无
AITraining	RealTimeInference	0.4697	0.4161	0.4635	无
BatchInference	AITraining	0.4507	0.6245	0.6576	无
BatchInference	RealTimeInference	0.4565	0.6965	0.8163	无
RealTimeInference	AITraining	0.1287	0.0699	0.1255	无
RealTimeInference	BatchInference	0.0607	0.1541	0.2507	无
RegionA	RegionB	0.1909	0.2227	0.3928	无
RegionA	RegionD	0.6930	0.7993	0.6960	无
RegionB	RegionC	0.4725	0.6015	0.7596	无
RegionE	RegionF	0.7044	0.6903	0.8560	无

6 组类型间 + 4 组区域间配对的最小 $p = 0.0607$ （仍 > 0.05 ）：不存在可利用的跨序列因果路径，外生变量预测路线不可行。

4.5 综合结论与对比表

模型	RMSE	MAPE	相对常数均值
Prophet（日/周季节）	214.7	22.6%	+2.9%
线性回归（周期特征）	216.1	23.1%	+2.3%
常数均值（基准）	221.1	23.4%	—
LSTM（滚动一步）	221.5	23.4%	−0.2%

四项检验覆盖可预测性的四条路径——线性依赖（ACF）、非线性依赖（BDS）、周期结构（Prophet）、横截面因果（Granger）——全部未推翻白噪声结论；最复杂模型 Prophet 提升仅 +2.9%，低于 5% 实质改善判据且调参/测试性能倒挂。故预测段口径为：**统计发现**（逐时需求 $\approx$ i.i.d. 白噪声，到达近似泊松， $\text{mean} \approx 20.8/\text{h}$ ）；**预测模型**（常数均值训练窗均值外推为主，线性回归对照，测试窗 RMSE 221.1/216.1）；**口径声明**（赛题说明 2：末 24h 调度以实际到达任务为输入，预测误差不影响调度方案）；**边界说明**（本文证”点预测不可行”；分布预测可用泊松刻画到达过程，属后续工作，不改变点预测结论）。

5 简化假设与合理性论证

假设	内容	合理性
A1 零迁移	任务只在来源区域运行, 调度自由度在时间维	人类决策点 1; F3 证可行域宽松, 无需迁移
A2 实时固定	实时任务到达即开工	赛题规定 + 数据 100% 符合
A3 功率惰性	IT/设施功率约束自动满足	F5 数学证明: $g_{\max} \cdot \text{Cap} \leq 0.16 \times \text{Cap} \ll \text{Max_IT_Power}$, 余量 3.1-4.7 倍
A4 时延惰性	零迁移 = 同区 5ms 恒满足	F6: 训练/批量/实时 $\text{MaxLatency} \geq 5\text{ms}$
A5 精确小数	D_j 按分钟/60 折算	人类决策; 避免整数近似容量偏差
A6 同质 GPU 池	区域 GPU 无型号差异	数据无异构信息

6 数学自检

- 量纲一致:** $Z_2 = U_{\max} - U_{\min}$ 无量纲 (利用率比值); Z_1 为 GPU-hour 松弛量 (无量纲 GPU 计数)。目标与约束量纲自洽。
- 无因变量自包含:** 预测回归中自变量 (t , 周期函数, 滞后值) 均不含 Y_t 本身或其代数变换; 滞后值 Y_{t-1} 等为历史值, 非同期因变量。
- 变换对应** (本模型无 $\ln$ /比值变换; 列出约束参数映射): $g_j \rightarrow$ GPU-hour 系数 $a_{j,h,t}$ (乘重叠长度); $\text{Cap}_r \rightarrow$ 利用率分母; $D_j \rightarrow$ 窗口上界。
- 整数解存在性:** F4 证测试窗 5,768 个 0-1 变量, HiGHS 472s 收敛至最优 (status=0)。
- 线性化正确性:** (14) 中 $u_{r,t}$ 含 $\sum ax$ (线性) 与常数 B 、 Cap , 不等式两侧移项后全为线性, 无二次项。

7 直觉解释 (无公式)

调度问题好比给 538 个”工作订单”排班, 每个订单写着: 什么时候到、要占多少台机器、干多久、最晚几点交。约束很简单——每个订单只能开工一次, 任何时候一台机器不能同时被两个订单占用; 目标是想办法让各区域的机器”忙得均匀”, 不要在某个小时挤爆、另一小时闲置。因为订单不允许跨区域 (零迁移), 所以每个区域的机器只服务本地订单, 我们只需要安排”几点开始干”。

数据告诉我们两件事: 一是机器非常充裕 (最忙也只用掉约一半容量), 所以一定排得开; 二是订单到达时间完全是随机的 (像投硬币), 所以”预测下一小时来多少订单”这件事本身就难——我们把”它确实不可预测”这件事作为统计发现写进论文, 用最简单的基线做对照即可。

8 假设检验计划

核心假设	检验方法	结果/状态
A1 零迁移可行	F3 逐时叠加 vs 容量	实时峰值 $\leq 12.6\%$, 无超容量
A3 功率惰性	F5 最坏上界 vs Max_IT_Power	余量 3.1-4.7 倍
A4 时延惰性	F6 MaxLatency vs 同区 5ms	全部满足
A5 精确小数必要	敏感性: 整数近似 vs 精确折算	阶段 2.2 补做灵敏度
白噪声假设	$\text{ACF} \approx 0$ + 泊松拟合	已证 (F1)
MILP 最优性	HiGHS status=0 + gap=0.01	已证 (472s)

9 参数物理意义与取值范围汇总

参数	物理意义	取值范围
A_j	任务到达小时	[2376, 2399]
D_j	时长 (小时, 精确小数)	[0.167, 6.65] (=10–399 min/60)
g_j	GPU 需求	[1, 127]
Cap_r	区域可用 GPU	A:630, B:585, C:540, D:1472, E:1012, F:966
$u_{r,t}$	逐时 GPU 利用率	[0, 1] (约束上限)
$U_{\max}, U_{\min}$	全区域逐时利用率极值	连续变量, ≥ 0
$B_{r,t}$	实时任务固定 GPU-hour 占用	由数据计算, 峰值 ≤ 41.6