

S2 数学推导：碳感知任务调度模型

MathModel 建模小组

2026-08-08

1 问题形式化

S2 子问题：以第 0–2399 小时实际到达的 50,000 个任务及对应逐时电力参数为输入，以**任务迁移目的地与开工时段**为决策变量，在 GPU 容量、IT/设施功率、网络时延 SLA 与完成时限约束下，建立**碳感知任务调度模型**，优化运行成本与碳排放，并以网络时延、新能源利用率作为评价指标。

S1 已完成零迁移时间维调度的精确 MILP（5768 变量、472s 收敛）。S2 在其基础上放开**迁移维度**： $\mathcal{M}_j$ 个候选目的地 $\times$ 时间窗口，全时域变量规模约 4000 万（F4, S1 验证），直接 MILP 不可行。故采用**两级分解**（人类裁定）：目的地分配层（容量感知贪心） $\rightarrow$ 时间维调度层（S1 框架复用，每区域独立 MILP）。

2 索引与集合

$$\mathcal{R} = \{\text{RegionA}, \dots, \text{RegionF}\}, \quad |\mathcal{R}| = 6, \quad (1)$$

$$\mathcal{J} = \{j_1, \dots, j_{50000}\}, \quad (2)$$

$$\mathcal{T} = \{0, 1, \dots, 2405\}, \quad \text{主时域 } 0\text{--}2399 \text{ 到达, } 2400\text{--}2405 \text{ 收尾}. \quad (3)$$

任务 j 的属性（来自 workload_trace.xlsx）：

符号	物理意义	取值/单位
A_j	到达小时	$[0, 2399]$, h
D_j	任务时长（精确小数折算）	$[0.167, 6.65]$, h
g_j	GPU 需求	$[1, 127]$, 无量纲
L_j	最晚完成小时	≤ 2406 , h
s_j	来源区域	$\mathcal{R}$
k_j	任务类型	RT / Batch / Training
ℓ_j	最大容忍时延	20/80/150 ms
p_j	单位 GPU 功率	0.08/0.10/0.16 MW/GPU

区域参数（来自 region_time_data.xlsx / GPU_information.xlsx）：

符号	物理意义	备注
$\text{Price}(r, t)$	区域 r 小时 t 电价	元/MWh, 468–1096
$\text{CI}(r, t)$	碳强度	tCO ₂ /MWh, 0.196–0.688
$\text{PUE}(r)$	能效比	1.25–1.38
Cap_r	可用 GPU	540–1472
$\tau(r_1, r_2)$	区域间时延	ms, 5–82

3 可行域 (MaxLatency 裁剪)

对任务 j , 可迁移目的地集合:

$$\mathcal{M}_j = \{r \in \mathcal{R} : \tau(s_j, r) \leq \ell_j\}. \quad (4)$$

数据事实 (阶段 1.4 P1 核验):

- AITraining (150ms): $\mathcal{M}_j = \mathcal{R}$, 全图 36/36 可达。
- BatchInference (80ms): 34/36 可达; $A \rightarrow F = 82\text{ms} > 80$ 被禁。
- RealTimeInference (20ms): A/B/C 三区互迁 (12-15ms) + E/F 互迁 (18ms) + D 锁死 ($D \rightarrow E = 22$ 、 $D \rightarrow F = 25$ 均 > 20 ; 无任何区域可迁入 D, 因 $A/B/C \rightarrow D = 58-65$ 、 $E/F \rightarrow D = 22-25$)。

裁剪效果: 平均候选目的地 4.85 个/任务; 仅 D 来源实时任务 (488 个, 0.98%) 完全锁死。

4 两级分解模型

4.1 层 1: 目的地分配 (容量感知贪心)

对每任务 j , 候选目的地按**单位成本**排序:

$$\hat{r}_j = \arg \min_{\substack{r \in \mathcal{M}_j \\ \mathcal{D}_r + \text{GH}_j \leq 0.9 \cdot \text{Cap}_r \cdot 2400}} \left(\text{PUE}(r) \cdot \text{Price}(r) \right) \quad (5)$$

其中 $\text{GH}_j = g_j D_j$ 为任务 GPU-hour, $\mathcal{D}_r$ 为该区域已分配累计, $\text{Price}(r)$ 为区域平均电价。若无候选满足 90% 阈值, 退路选择负载率最低区域:

$$\hat{r}_j = \arg \min_{r \in \mathcal{M}_j} \frac{\mathcal{D}_r}{\text{Cap}_r \cdot 2400}. \quad (6)$$

A 类验证 F3: 该层实现成本 -16.6%、碳 -30.4% (vs S1 零迁移基线), 退路仅 117/50000 (0.23%), E/F 负载恰好 90%、A/B 空置、无超容量。

4.2 层 2: 时间维调度 (每区域独立 MILP, S1 框架复用)

对每个目的地 r_j^* , 在区域 r 内建立时间索引 0-1 MILP。

决策变量: $x_{j,h} \in \{0,1\}$, 任务 j 在小时 h 开工, $h \in \mathcal{W}_j = \{h : A_j \leq h \leq \min(L_j, 2406) - D_j\}$ 。

目标 (成本最小化, 含电价时移):

$$\min \sum_{j:r_j^*=r} \sum_{h \in \mathcal{W}_j} \underbrace{g_j p_{k_j} \cdot \text{PUE}(r) \cdot \text{Price}(r, h)}_{\text{单位小时能耗成本系数}} \cdot x_{j,h} \quad (7)$$

约束:

1. 恰好开工一次: $\sum_h x_{j,h} = 1, \forall j$ 。

2. GPU 容量 (重叠折算, S1 同构):

$$\sum_j \sum_{h'} a_{j,h',t} x_{j,h'} \leq \text{Cap}_r - B_{r,t}, \quad a_{j,h',t} = g_j \cdot |[h', h' + D_j) \cap [t, t+1)|. \quad (8)$$

3. 完成时限：由窗口蕴含。

4.3 碳排放 ε -约束（决策点 2）

全局碳排放（含所有区域）：

$$E(x) = \sum_{r \in \mathcal{R}} \sum_{j: r_j^* = r} \sum_h g_j p_{k_j} \cdot \text{PUE}(r) \cdot \text{CI}(r, h) \cdot x_{j,h} \leq \bar{E} = \eta \cdot E_0, \quad (9)$$

其中 E_0 为 S1 零迁移时移基线碳排放（374.28kt），约束上限选取区间 $[E_{\min}, E_0]$ 的多档值（实测 $E_{\min}=232.94\text{kt}$ ，350–251kt 均收敛自由解 251.78kt，仅 $\bar{E} = 240\text{kt}$ 触发让渡 2,667 任务收敛于 242.46kt；230/220kt 低于 $E_{\min}$ 不可达）。式 (9) 为线性约束（系数 $g_j p_{k_j} \text{PUE}(r) \text{CI}(r, h)$ 为常数）。

注意：由于碳排放约束跨区域耦合，层 1 目的地分配与层 2 时间调度为**迭代**关系——先按 η 档做目的地分配，再在时间维嵌入式 (9) 校验；若不满足则微调分配（把高碳区域任务让给低碳区域），迭代至收敛。

5 评价指标（不进目标）

- **网络时延：** $\bar{\tau} = \frac{1}{|\mathcal{J}_{\text{mig}}|} \sum_{j \in \mathcal{J}_{\text{mig}}} \tau(s_j, r_j^*)$ ，仅统计发生迁移的任务。
- **新能源利用率：**S2 只评价（通过迁往弃电富余区间接贡献）；正式口径（直接消纳 + 储能充电 + 外送）/可用，移交 S3/S4 计算。

6 简化假设与合理性论证

假设	内容	合理性
A1 两级分解	目的地分配与时间调度解耦	容量感知 F3 验证可行（退路 0.23%）
A2 迁移零成本	不建模带宽/能耗/费用	赛题说明 7
A3 区域均值电价	层 1 用平均电价选目的地	层 2 用逐时电价精排，两级互补
A4 90% 阈值	目的地分配预留容量裕度	F3 验证 E/F 恰 90%、无超容量
A5 碳排迭代收敛	ε -约束通过分配-调度迭代满足	高碳区任务让渡低碳区

7 数学自检

1. **量纲：**目标 (7) 为元 ($\text{MW} \times \text{h} \times \text{元}/\text{MWh}$)；碳排 (9) 为 tCO_2 ；时延为 ms。自治。
2. **无因变量自包含：**目标系数均来自输入 ($g_j, p_{k_j}, \text{PUE}, \text{Price}$)，不含 x 的代数变换。
3. **线性性：**式 (8) 的 $a_{j,h',t}$ 为常数系数；(9) 亦线性。MILP 可直接求解。
4. **整数解存在：**层 2 每区域任务量 5k–15k，滚动窗后变量量级与 S1 测试窗可比。
5. **收敛性：**层 1 贪心 + 层 2 MILP 迭代，碳排约束单调逼近（高碳让渡），有限步收敛。

8 直觉解释（无公式）

S2 像”物流调度的绿色版”：每件货物（任务）都写着”最晚几号到、路上不能超过多少毫秒的延迟”。西部仓库（E/F）电费和碳排放都便宜，但离东部远、延迟高——所以只有”不赶时间”的

货物（训练）可以全图乱跑；”中等赶时间”的（批量）大多数能跑，只有个别线路超时被禁；”最赶时间”的（实时）只能在邻居仓库间移动。

模型分两步：先决定每件货放哪个仓库（看哪家便宜且装得下，90% 容量红线）；再在每个仓库内排”几点开工”（把货尽量排在电价便宜的时段）。最后设定” 全公司碳排放不能超过 X 吨” 的红线，从宽到严试三档，看为减排多花多少钱——这就是给决策者的成本-减排权衡曲线。

9 假设检验计划

核心假设	检验方法	结果/状态
A1 两级分解可行	F3 容量感知分配	通过（退路 0.23%，无超容量）
A2 迁移零成本	赛题说明 7 约束	接受（论文讨论节注明边界）
A3 区域均值电价	层 2 逐时电价 vs 均价对比	待补（不影响结论，均价选目的地 + 逐时精排两级互补）
A4 90% 阈值	阈值 80/85/90/95% 敏感性	通过（90% 退路最低 117，E/F 恰贴阈值，图 sub2-threshold-sensitivity.pdf）
A5 碳排迭代收敛	ϵ 三档 + 紧档位迭代	通过（240kt 让渡 2,667 任务后收敛于 242.46kt；350–251kt 均收敛自由解 251.78kt；230/220kt 低于 $E_{\min}$ 不可达）
可行域裁剪	F1/P1 核验	通过（训练 36/36、批量 34/36、实时 E/F 互迁 18ms）
迁移收益量化	S1 时移基线 vs S2 结果	通过（成本 +2.0%、碳 -32.7%，迁移 76.4%，时延 35.3ms）
A/B 空置合理性	minutil 灵敏度 0/5/10/15%	通过（15% 保底仅 +2.4%，0% 为成本最优边界）