

S4 数学推导：多区域算一储一电协同优化

MathModel 建模小组

2026-08-08

1 问题形式化

S4 子问题（问题四）在 S1-S3 基础上建立**多区域算一储一电协同优化模型**：统一考虑任务迁移、电价、碳排放、可用新能源、储能、区域购售电边界、网络时延及任务异构性，在运行成本、碳排放、网络时延、服务质量、新能源利用率与区域峰值净购电之间权衡，并比较不同碳约束、电价机制与新能源波动场景下的策略变化。

架构采用**半耦合两级分解**（人类裁定，approach-sub4-confirmed §2.1）：

层级	作用	方法
层 1	任务目的地分配 + 基荷预填	容量感知贪心 + P25 矩形 EDF 预填
层 2	每区域时间维调度 + 储能/购售电/新能源	0-1 MILP (S1 框架) + 连续 LP (S3 框架) 合并

区域电力独立（说明 7，无跨区潮流），故层 2 逐区域独立求解；跨区耦合仅存在于任务迁移（层 1 处理）。

1.1 索引与基本集合

$$\mathcal{R} = \{\text{RegionA}, \dots, \text{RegionF}\}, \quad |\mathcal{R}| = 6, \quad (1)$$

$$\mathcal{J} = \{j_1, \dots, j_{50000}\}, \quad (2)$$

$$\mathcal{T} = \{0, 1, \dots, 2405\}, \quad \mathcal{T}^{main} = \{0, \dots, 2399\}, \quad \mathcal{T}^{set} = \{2400, \dots, 2405\}. \quad (3)$$

1.2 任务属性参数（workload_trace.xlsx，阶段 0.3 清洗后）

符号	物理意义	取值/单位
A_j	到达小时（= 最早开工）	$[0, 2399]$, h
D_j	任务时长（精确小数折算）	$[0.167, 6.65]$, h
g_j	GPU 需求（等效 GPU 数）	$[1, 127]$
L_j	最晚完成小时	≤ 2406 , h
s_j	来源区域	$\mathcal{R}$
k_j	任务类型	RT / Batch / Training
ℓ_j	最大容忍时延	20/80/150 ms
p_{k_j}	单位 GPU 功率	0.08/0.10/0.16 MW/GPU
GH_j	GPU-hour = $g_j D_j$	

1.3 区域参数

符号	物理意义	备注
Cap_r	可用 GPU	540–1472
PUE_r	能效比	1.25–1.38
$\text{Price}_{r,t}$	购电电价	元/MWh, 235–1096
$\text{SellPrice}_{r,t}$	售电电价	元/MWh, A/B/C 为 0
$c_{r,t}$	购电碳强度	tCO ₂ /MWh, 0.196–0.688
$\text{Avail}_{r,t}$	可用新能源	MW, 500–1100
$\text{NonAI}_{r,t}$	非 AI IT 负荷	MW (IT 侧, 不可调度)
$E_r^{\text{cap}}, E_r^{\text{min}}, E_r^{\text{init}}$	储能容量/SOC 下限/初始	MWh
$P_r^{\text{ch}}, P_r^{\text{dis}}$	充/放电功率上限	MW
η_c, η_d	充/放电效率	0.92–0.94
$\bar{G}_r, \bar{S}_r$	购/售电功率上限	MW ($\bar{S}_r$: A/B/C=0)
$\tau(r_1, r_2)$	区域间时延	ms, 5–82
C_r^{base}	区域基准碳排 (主时域)	kt

2 可行域 (MaxLatency 裁剪)

对任务 j , 可迁移目的地集合:

$$\mathcal{M}_j = \{r \in \mathcal{R} : \tau(s_j, r) \leq \ell_j\}. \quad (4)$$

数据事实 (阶段 1.4 P1 核验, S2 同源):

- AITraining (150ms): $\mathcal{M}_j = \mathcal{R}$, 全图 36/36 可达。
- BatchInference (80ms): 34/36; $A \rightarrow F = 82\text{ms} > 80$ 被禁。
- RealTimeInference (20ms): A/B/C 三区互迁 (12–15ms) + E/F 互迁 (18ms) + D 锁死。

3 层 1: 目的地分配 (容量感知贪心, 复用 S2)

对每任务 j , 候选目的地按单位成本升序:

$$\hat{r}_j = \arg \min_{r \in \mathcal{M}_j, \mathcal{D}_r + \text{GH}_j \leq 0.9 \cdot \text{Cap}_r \cdot 2400} (\text{PUE}_r \cdot \bar{\text{Price}}_r), \quad (5)$$

其中 $\mathcal{D}_r$ 为区域 r 已分配 GPU-hour 累计, $\bar{\text{Price}}_r$ 为区域平均电价。若无候选满足 90% 阈值, 退路选候选内负载率最低区域:

$$\hat{r}_j = \arg \min_{r \in \mathcal{M}_j} \frac{\mathcal{D}_r}{\text{Cap}_r \cdot 2400}. \quad (6)$$

遍历顺序 = 数据行序 (与 S2 capacity_aware_assign 完全一致, 保证 Q3 方案 A/B 对比口径)。实时任务同样分配目的地 (到达即开工, 时间维固定)。

4 基荷预填 (新能源基荷匹配策略, S4 核心创新)

4.1 基荷矩形

对区域 r , 取可用新能源的统计下界 (Q1 裁定 P25 分位):

$$\text{Baseload}_r = Q_{25}(\text{Avail}_{r,t} : t \in \mathcal{T}^{main}) = 588 \text{ MW (六区相同)}. \quad (7)$$

其物理含义：75% 的小时可用新能源 $\geq 588 \text{ MW}$ ，是可确定性消纳的”绿色基荷”，类比核电机组不参与调峰、以恒定出力承担基荷的运行哲学。

4.2 逐时 AI IT 配额

基荷矩形为设施侧功率，折算为 IT 侧并扣除逐时 NonAI 后，得 AI 任务可用的绿色 IT 功率配额：

$$\text{Quota}_{r,t} = \max\left(\frac{\text{Baseload}_r}{\text{PUE}_r} - \text{NonAI}_{r,t}, 0\right), \quad (8)$$

单位为 MW (IT 侧)。逐时化 (审查 M-3 修正)：高峰 NonAI 小时配额趋零，保证”基荷 = 绿色算力”物理保证成立。

4.3 EDF 预填

候选 = 分配到 r 的延迟容忍任务 (训练 + 批量)，按 GPU-hour 降序。任务 j 在小时 h 开工可行，当且仅当其运行全程满足：

$$\begin{aligned} (\text{GPU 容量}) \quad & \underbrace{\sum_{j' \in \text{placed}} g_{j'} \cdot |[h', h' + D_{j'}] \cap [t, t+1]| + g_j \cdot |[h, h + D_j] \cap [t, t+1]|}_{\text{已填占用}} \leq \text{Cap}_r, \quad (9) \\ (\text{基荷配额}) \quad & \underbrace{\sum_{j' \in \text{placed}} g_{j'} p_{k_{j'}} \cdot |[h', h' + D_{j'}] \cap [t, t+1]| + g_j p_{k_j} \cdot |[h, h + D_j] \cap [t, t+1]|}_{\text{已填 AI IT}} \leq \text{Quota}_{r,t}. \quad (10) \end{aligned}$$

初始占用含实时任务固定开工的 GPU + AI IT。窗口 $\mathcal{W}_j^{bl} = \{h : A_j \leq h \leq \min(L_j, 2406) - D_j\} \cap \{h : h + D_j \leq 2400\}$ (完整落在主时域，跨收尾段交层 2)。

填入成功 $\Rightarrow$ `baseload=True` + 开工小时固定，不进层 2 MILP 变量空间。

4.4 第二轮改派

EDF 失败任务改派至候选内 GPU-hour 负载率最低且未满 90% 的区域，重试 EDF；成功则更新目的地并同步扣减旧区域账本。仍失败 (实测 50 个) 进层 2 显式处理。

4.5 基荷预填实测结果 (阶段 1.4, preprocess-sub4.py)

区域	候选任务	基荷填充	配额填充率	实测瓶颈
A/B/C	0	改派承接 E/F 溢出	7.6%/6.9%	任务供给不足
D	4,657	4,646	17.3%	任务供给不足
E	15,076	11,497	72.8%	物理 GPU 容量
F	13,543	10,110	70.9%	物理 GPU 容量
全局	50,000	33,226 (66.5%)	GPU-hour 95.3%	

关键发现：E/F 是基荷实际主力（GPU 容量锁死下的最大确定性消纳）；D 配额充足但层 1 分配任务供给不足（17.3%）；A/B 经改派承接溢出启用基荷。基荷任务占全局 GPU-hour 95.3%——层 2 MILP 变量空间压缩至 $\sim 5\%$ ，EDF 贪心成为主导调度器（Q3 方案 A/B 对比检验其与全局最优的偏差）。

5 层 2：每区域独立 MILP（S1 调度框架 + S3 储能框架合并）

5.1 决策变量

对区域 r ，三类变量：

时间维调度（非基荷的自由任务，继承 S1/S2）：

$$x_{j,h} \in \{0,1\}, \quad j \in \mathcal{J}_r^F, \quad h \in \mathcal{W}_j, \quad (11)$$

其中 $\mathcal{W}_j = \{h : A_j \leq h \leq \min(L_j, 2406) - D_j\}$ 。基荷任务 $x_{j,h_j^*} = 1$ 固定（ h_j^* 由 EDF 确定），不进变量空间。

储能与电力侧（继承 S3，全部连续变量）：

$$G_t \geq 0, \quad S_t \geq 0, \quad R_t \geq 0, \quad C_t^g \geq 0, \quad C_t^r \geq 0, \quad D_t \geq 0, \quad E_t \in \mathbb{R}. \quad (12)$$

5.2 约束

（C1）恰好开工一次（非基荷自由任务）：

$$\sum_{h \in \mathcal{W}_j} x_{j,h} = 1, \quad \forall j \in \mathcal{J}_r^F. \quad (13)$$

（C2）GPU 容量（重叠精确折算，S1 同构）：对小时 t ，

$$\underbrace{\sum_j \sum_{h'} a_{j,h',t} x_{j,h'}}_{\text{非基荷自由任务}} + \underbrace{B_{r,t}^{bl}}_{\text{基荷任务固定占用}} + \underbrace{B_{r,t}^{rt}}_{\text{实时任务固定占用}} \leq \text{Cap}_r, \quad (14)$$

其中 $a_{j,h,t} = g_j \cdot |[h, h + D_j) \cap [t, t + 1)|$ ， $B_{r,t}^{bl}$ 、 $B_{r,t}^{rt}$ 分别为基荷任务与实时任务在区域 r 小时 t 的固定 GPU-hour 占用。

（C3）功率平衡（S3 同构）：

$$G_t + R_t + D_t = \underbrace{(\text{AI_IT}_t + \text{NonAI}_t) \cdot \text{PUE}_r}_{\text{设施负荷}} + C_t^g + S_t, \quad \forall t \in \mathcal{T}. \quad (15)$$

其中 AI 任务的 IT 功率由调度决定：

$$\text{AI_IT}_t = \sum_j g_j p_{k_j} \cdot \text{overlap_ratio}_{j,t} = \sum_j g_j p_{k_j} \cdot \frac{a_{j,h_j^*,t}}{g_j} = \sum_j p_{k_j} \cdot a_{j,h_j^*,t}, \quad (16)$$

即按任务实际开工（ x 或固定 h_j^* ）逐时叠加。

（C4）新能源消纳（受限，S3 B1 同口径）：

$$R_t + C_t^r \leq \text{Absorb}_t \equiv \text{Used}_t + \text{Rch}_t, \quad \forall t, \quad (17)$$

其中 Absorb_t 为消纳能力上限（基准观测直消纳 + 新能源充电，c-data 逐时，含结清段实际值）。
口径实证修正（阶段 2.1）：原方案采用自由消纳 $R + C^r \leq \text{Avail}$ ，实测可用新能源（500–1100 MW）恒大于负荷（241–652 MW），LP 购电 $\rightarrow 0$ 、碳排 $\rightarrow 0$ 、 $\varepsilon = 1.00$ 碳上限不绑定、成本为负（卖电套利）——场景对比失效（与 S3 R1 退化同因）。故排除自由消纳，回归受限口径。基荷策略以统计下界提供消纳下界（P25 确定性部分），受限消纳提供上界（电网物理能力观测值），两者兼容。

（C5）SOC 递推与边界：

$$E_t = E_{t-1} + \eta_c(C_t^g + C_t^r) - \frac{D_t}{\eta_d}, \quad E_{-1} = E_r^{\text{init}}, \quad (18)$$

$$E_r^{\min} \leq E_t \leq E_r^{\text{cap}}, \quad E_{2406} \geq E_r^{\text{init}}. \quad (19)$$

（C6）充放/购售电边界：

$$0 \leq C_t \leq P_r^{\text{ch}}, \quad 0 \leq D_t \leq P_r^{\text{dis}}, \quad 0 \leq G_t \leq \bar{G}_r, \quad 0 \leq S_t \leq \bar{S}_r. \quad (20)$$

（C7）同时充放互斥： $\eta_c \eta_d < 1$ 下同刻充放为纯损耗，成本目标自动排除（F4 实证 0 h），不引入 0-1 变量。

（C8）碳排放 ε -约束（主时域）：

$$\sum_{t \in \mathcal{T}^{\text{main}}} G_t c_{r,t} \leq 10^3 \varepsilon C_r^{\text{base}}, \quad \varepsilon \in \{1.00, 0.95, 0.90\} \text{（三档对比）}. \quad (21)$$

5.3 目标函数

最小化运行成本（购电 – 卖电收入，全时域含结清段）：

$$\min Z_r = \sum_{t \in \mathcal{T}} (G_t \text{Price}_{r,t} - S_t \text{SellPrice}_{r,t}), \quad (22)$$

总成本 $Z = \sum_r Z_r$ 。GridSell 为**兜底变量**（Q4 裁定）：中国电价体系下 SellPrice 远低于替代区域购电价，优化结果自然形成“GPU 填满 $\rightarrow$ 储能满 $\rightarrow$ 剩余新能源外卖”的优先级，不存在“卖电 vs 算力”的主动取舍。

6 六指标（评价口径，主时域 $\mathcal{T}^{main}$ ）

$$\text{运行成本: } Z^{main} = \sum_r \sum_{t \in \mathcal{T}^{main}} (G_{r,t} p_{r,t} - S_{r,t} q_{r,t}), \quad (23)$$

$$\text{碳排放: } \text{CO}_2 = \sum_r \sum_{t \in \mathcal{T}^{main}} G_{r,t} c_{r,t} \text{ (tCO}_2\text{)}, \quad (24)$$

$$\text{网络时延: } \bar{\tau} = \frac{\sum_j \tau(s_j, r_j^*) \cdot \text{GH}_j}{\sum_j \text{GH}_j} \text{ (ms, GPU-hour 加权)}, \quad (25)$$

$$\text{服务质量: } \text{QoS} = \frac{\#\{j : \text{按时完成}\}}{50,000}, \quad (26)$$

$$\text{新能源利用率: } \text{REU} = \frac{\sum_{r,t} (\text{Used}_{r,t}^{opt} + \text{Rch}_{r,t}^{opt})}{\sum_{r,t} \text{Avail}_{r,t}}, \quad (27)$$

$$\text{区域峰值净购电: } \text{Peak} = \max_{r,t \in \mathcal{T}^{main}} (G_{r,t} - S_{r,t}) \text{ (MW)}. \quad (28)$$

其中 Used^{opt} 、 Rch^{opt} 为优化解的新能源直供与充电（由 R_t 、 C_t^r 给出）。

7 场景对比设计（Q2 裁定：4-6 组关键对比）

场景	维度变化	参数	预期观察
S0 基准	无	$\epsilon = 1.00$, 当前电价, 基准新能源	基荷策略主解
S1 碳约束趋紧	ϵ	0.95/0.90	任务迁移方向变化; D 基荷承接空间是否启用
S2 电价机制	峰谷价差	峰谷价差 $\times 1.5$ (Peak 上调)	时移调度加强; 储能套利增强
S3 新能源波动	出力	可用新能源 $\pm 20\%$	基荷矩形高度变化; 利用率与购电权衡

方案 A/B 对比（Q3 裁定）：方案 A = 层 2 MILP 直接调度全部任务（无基荷预填）；方案 B = 本方案（基荷预填 + 层 2 调度剩余）。差异 = 基荷策略纯贡献 + EDF 贪心偏差（两者需分离归因）。

8 求解方法

- 求解器：`scipy.optimize.milp` (HiGHS)，与 S1/S2 一致；连续部分 `linprog` 备用验证。
- 规模：基荷预填后每区 0-1 变量数千（D 区为主 $\sim 4\text{--}5\text{k}$ ）、连续变量 $\sim 7 \times 2406 \approx 1.7$ 万。
- 求解策略：逐区域独立（区域电力解耦）；并行 6 区 $\approx 5\text{--}8$ min/组；场景 4 组 $\approx 1\text{h}$ 。
- 终态： $E_{2406} = E_{2405}$ ，仅施加式 (19) 下界，不引入 2406 时点变量。

9 简化假设与合理性论证

1. **半耦合分解**：区域电力独立（说明 7），层 1 分配 $\rightarrow$ 层 2 独立 MILP。全耦合变量 ~ 4000 万不可行（S2 F4），分解以 0.23% 退路代价获得可解性。
2. **迁移免费**：说明 7（正式限问题四适用），不建模带宽/能耗/费用。

3. **基荷预填 EDF 贪心**：基荷任务开工时刻由 EDF 确定而非 MILP 全局最优——偏差量级由 Q3 方案 A/B 对比量化。
4. **受限消纳 (S3 B1 同口径, 阶段 2.1 实证修正)**：消纳上限 $R + C^r \leq Used + Rch$ (基准观测, c-data 逐时)。原方案自由消纳 $R + C^r \leq Avail$ 实测退化——可用新能源恒大于负荷, LP 购电 $\rightarrow 0$ 、碳排 $\rightarrow 0$ 、 $\varepsilon = 1.00$ 不绑定、成本为负, 场景对比失效 (S3 R1 同因)。基荷以统计下界提供消纳下界, 受限消纳提供上界, 两者兼容。
5. **碳基准 = S4 自身 free 解 (阶段 2.1 实证修正)**： ε 上限 $1e3 \cdot \varepsilon \cdot C_r^{ref}$, C_r^{ref} 为 S4 无碳约束解碳排 (E0_S4), 非 S3 baseline 基准——S4 负荷结构 (实时 + 基荷任务) 与 S3 给定负荷不同, E/F 固定负荷最小购电碳排已超 S3 基准 (E 121.2 vs 84.6 kt), 直接套用 S3 基准导致 $\varepsilon = 1.00$ 不可行。与 S3 " $\varepsilon = 1.00 =$ 无刻意降碳碳排" 语义一致。 $\varepsilon = 0.95$ 实测仅 D 可行 (碳排刚性), $\varepsilon = 0.90$ 全不可行, 与 S3 结论呼应。
6. **GridSell 兜底**：中国电价体系下卖电收益远低于替代购电成本, 不存在"卖电 vs 算力"取舍。
7. **NonAI 固定 (Q4 裁定)**：赛题未说明 NonAI 可变, 固定处理。
8. **时域口径**：0–2399 主时域 (指标评价 + 碳约束) + 2400–2405 结清段 (计成本不计碳) + 2406 状态结算。
9. **同时充放自动排除**： $\eta_c \eta_d < 1$ (F4 实证)。

10 直觉解释

S4 的协同本质是三层"搬运"的统一：**空间搬运** (任务迁往低电价低碳区, 层 1)、**时间搬运** (任务推迟到低价/低碳小时, 层 2 调度)、**能量搬运** (储能把便宜/绿色时段的多余电存到高价/高碳时段用, 层 2 储能)。基荷匹配策略把新能源的确定性下界作为"绿色容量信号"——像核电基荷一样恒定、可计划, 任务调度的去留不再依赖电价信号的偶然同向性, 而是物理可用量的确定性。

11 假设检验计划

核心假设	检验方法	检验结果 (阶段 2.2 回填)
H1 层 2 各区域 MILP 可行	status=0 (可行 + 最优)	
H2 基荷任务不超 GPU/配额	后验: 基荷占用逐时 $\leq Cap$ 且 $\leq Quota$	
H3 同时充放自动排除	最优解后验: 同刻充放小时数 = 0	
H4 ε 档有效	三档成本单调性 + 碳排响应	
H5 EDF 偏差量级	Q3 方案 A/B 对比 (成本/碳排差异)	
H6 GridSell 兜底成立	最优解后验: 卖电仅出现在 GPU 满 + 储能满后	
H7 终态约束可行	$SOC(2406) \geq Initial$ 且 status=0	