

AI 工具使用详情

2026 年 7 月 28 日

领域知识与数据准备

[AI-0-2]

所用 AI 工具名称和版本：

DeepSeek, DeepSeek-V4, 深度求索 (DeepSeek)

具体使用目的和环节：

赛题分析与领域知识检索。团队在接到赛题后，需要系统了解评分者信度 (ICC, Kendall's W, Fleiss' Kappa)、评委偏差分类框架 (严厉度/宽容度、中心化趋势、光环效应)、相关性 vs 一致性的概念区分等教育测量学领域知识，以及通用的数学建模方法 (熵权法、TOPSIS、K-Means、Kruskal-Wallis、Isolation Forest 等)，以指导后续建模方案的设计。团队确定上述知识领域后，要求 AI 通过联网检索整理领域知识卡片，并在读题阶段进行头脑风暴，梳理子问题间的依赖关系，给出初步方法论建议。

关键交互记录 (重要提示词与回复)：

提示词：这是一道关于竞赛网评结果建模与分析的 C 题。请先检索以下领域知识：评分者信度 (ICC, Kendall W, Fleiss Kappa)、评委偏差分类框架 (严厉度/宽容度、中心化趋势、光环效应)、多组比较方法 (Kruskal-Wallis)，整理成知识卡片，包含阈值标准和适用场景。然后阅读赛题，梳理 5 个子问题之间的依赖关系，给出初步方法论建议。

AI 回复：整理了 ICC 模型选择指南 (Koo & Li, 2016)、评分者信度三维框架 (Stemler, 2004)、评委偏差分类框架、多组比较方法等知识卡片。识别出子问题依赖关系：Q2→Q3→Q4 为一条线，Q1→Q5 为另一条线。提出了 Spearman+Pearson 两步走、四维度指标体系 (信度/效度/公平性/区分力)、熵权法 + TOPSIS 综合评价、Kruskal-Wallis+Dunn 检验等方法论建议。核心发现：评委完全不跨题，五题使用独立评委池，因此 Q4 中题目效应和评委池效应无法分离，只能报告“存在差异”。

采纳和人工修改情况：

团队审核了全部知识卡片的阈值标准和文献来源，采纳了 ICC(2,1) 成对比较、Kruskal-Wallis+Dunn 检验等方法建议。子问题依赖关系图被直接用于后续工作安排。方案设计中团队补充了关键约束——Q4 中题目效应与评委池效应无法分离，并要求在论文中坦诚此局限性。部分方法（如 Fleiss' Kappa）因数据为连续评分而非分类数据，经团队评估后不予采用。

[AI-0-3]

所用 AI 工具名称和版本：

DeepSeek, DeepSeek-V4, 深度求索（DeepSeek）

具体使用目的和环节：

数据清洗与数据画像。团队在建模前需要对附件 A-E 五个题目的评审数据进行系统性清洗和探索性分析，包括：检测重复记录与缺失值、统计各题数据量及入围比例、识别异常评分模式；随后进行多路径数据画像（聚类、降维、异常检测），为建模方案提供数据结构层面的验证。

关键交互记录（重要提示词与回复）：

提示词：读取附件 A-E.xlsx，合并为统一数据集。检查重复记录（按阅卷号）、缺失值分布、各题数据量和入围比例。对评分列做 IQR 异常值检测，但异常值不做删除。统计评委跨题情况。输出清洗报告。

清洗完成后，对 196 位评委的 11 维特征矩阵做三条路径的数据画像：路径 A——K-Means++ 聚类（K 由肘部法则确定），路径 B——PCA 降维（前 3 个主成分），路径 C——Isolation Forest 异常检测。三条路径交叉验证，输出画像报告。

AI 回复：清洗结果：4876 行 × 12 列，零重复记录，成绩列 2802 条 NaN 为正常淘汰。IQR 异常评分占比 0.1%-2.3%，不做删除。确认 196 位评委完全不跨题。聚类路径发现两个评委群体（“严格型”132 人，“宽松型”64 人），Silhouette=0.283。PCA 路径前 3 主成分累积解释 85.8% 方差：PC1 为评分水平因子（54.7%）、PC2 为评分离散度因子（22.0%）、PC3 为获奖率因子（9.1%），PC3 与 PC1 正交说明标准分公式有效消除了尺度差异。异常检测路径发现 27 位异常评委（13.8%），分为极端严格（ $z < -1.5$ ）、极端宽松 + 低离散（ $z > +2.0$ 且 σ 低）、高离散度三类。三条路径交叉验证一致。

采纳和人工修改情况：

团队审核了清洗报告的数据准确性，确认异常评分保留不删除的策略——这些是评委评分差异的正常体现而非数据错误。数据画像结果直接支撑了后续方案设计：PCA 揭示的“获奖率独立于评分水平”验证了标准分公式的有效性；聚类揭示的“严格/宽松”两极分化强化了 Q2 中“公平性”维度的必要性；异常检测揭示的三类异常评委为 Q3/Q5 的异常评委标记和降权策略提供了依据。

子问题 1：网评与终评相关性分析

[AI-1-1]

所用 AI 工具名称和版本：

DeepSeek, DeepSeek-V4, 深度求索 (DeepSeek)

具体使用目的和环节：

子问题 1 方案设计与代码实现。团队确定了“Spearman+Pearson 两步走 + 多维度评估”的总体框架后，要求 AI 完成以下工作：(1) 实现按评委 ID 分组计算 z-score（而非按列位置），取 4 位评委 z-score 均值作为网评标准分；(2) 分五题计算 Spearman ρ 和 Pearson r，报告效应量和置信区间；(3) 构建前 55% 筛选的混淆矩阵，计算命中率和假阴性率；(4) 绘制 ROC 曲线，计算 AUC 评估网评对一等奖的区分能力。

关键交互记录（重要提示词与回复）：

提示词：对 Q1 实现标准分按评委计算——建立 judge_mu_sigma 映射，每个评委用自己的 μ 和 σ 做 z-score，取 4 个 z-score 均值。然后分五题计算 Spearman ρ （含 95% CI 和效应量），对入围论文计算 Pearson r。构建 55% 筛选混淆矩阵，计算命中率和假阴性率。绘制全题汇总 ROC 曲线。代码文件命名为 c2_q1q4_model.py。

AI 回复：代码实现了按评委 ID 的 z-score 计算 (c2_q1q4_model.py, L34-50)，通过 judge_mu_sigma 字典建立评委到均值/标准差的映射。Spearman ρ 全题汇总为 0.797（强相关），AUC=0.932（卓越），前 55% 筛选命中率 74.8%，假阴性率 3.3%。C 题表现最弱： $\rho=0.762$ 、 $r=0.319$ 、AUC=0.872（仍属良好）。

采纳和人工修改情况：

团队审查代码后发现初始版本存在关键错误——按列位置而非按评委 ID 计算 z-score，导致不同评委的评分被混合计算均值和标准差。团队要求 AI 修复此问题后重新运行全部 Q1 计算。修复后 Spearman ρ 从 0.737 升至 0.797，AUC 从 0.893 升至 0.932，网评有效性结论更加稳固。团队进一步要求 AI 对 C 题三指标联动（ ρ 高而 r 低 + 低 AUC）给出实际含义解读，确认了“C 题网评初筛功能正常但入围论文内部分数拉不开”的结论。

[AI-1-2]

所用 AI 工具名称和版本：

硅基流动图像理解模型, Qwen3-VL-30B, 阿里云 / 硅基流动 (SiliconFlow)

具体使用目的和环节：

Q1 相关图表的可视化审查。子问题 1 生成了 q1-spearman-bar、q1-confusion-heatmap、q1-roc 五题、q1-top55-bar 等图表。团队要求 AI 利用多模态模型逐一检查图表的标注

正确性、视觉可读性和数据标注准确性，并通过自动修复流程迭代至通过标准。审查内容包括：横纵轴标签是否完整、图例是否遮挡数据、标题是否准确、数值标注是否与计算输出一致。

关键交互记录（重要提示词与回复）：

提示词：请依次审查以下图表的质量、标注正确性、数据解读和建模适用性——q1-spearman-bar.png, q1-confusion-heatmap.png, q1-roc.png, q1-top55-bar.png。检查横纵轴标签、图例位置、数值标注。

AI 回复：q1-spearman-bar 通过（轴标签“Spearman ρ ”正确，数值标注与模型输出一致）。q1-confusion-heatmap 通过（四个象限标注清晰，颜色映射合理）。q1-roc 通过（五条 ROC 曲线可辨识，AUC 标注完整）。q1-top55-bar 通过（各题命中率/假阴性率柱状图清晰，高于 55% 基准线标注完整）。4/4 图表通过多模态审查。

采纳和人工修改情况：

团队审核了多模态审查结论，确认所有 Q1 图表标注正确、数据一致。特别核对了 q1-roc 图中五条 ROC 曲线的 AUC 数值与终端输出一致，q1-confusion-heatmap 中混淆矩阵的四个象限数值与原始计算结果匹配。

子问题 2：评委基本素质指标体系

[AI-2-1]

所用 AI 工具名称和版本：

DeepSeek, DeepSeek-V4, 深度求索（DeepSeek）

具体使用目的和环节：

子问题 2 指标体系设计与指标计算实现。团队参考 Stemler(2004) 的三维评分者信度框架，结合竞赛实际场景，将指标体系扩展为四维度（信度/效度/公平性/区分力）。团队确定各维度的量化指标后，要求 AI 实现：(1) 成对 ICC(2,1) 计算每位评委的信度；(2) 评分与最终奖项的 Spearman ρ 计算效度；(3) 评分均值偏离度的 z 值计算公平性；(4) 评分标准差计算区分力。同时要求 AI 验证四维度间的独立性（交叉相关性），确保指标体系无严重冗余。

关键交互记录（重要提示词与回复）：

提示词：对 196 位评委构建四维度指标体系。信度：成对 ICC(2,1) 均值，使用 pingouin 或手写 ANOVA 分解实现。效度：评委评分与奖项等级的 Spearman ρ ，需包含淘汰论文（奖项填 0）。公平性：评委均值偏离同题全体均值的 z 值绝对值。区分力：评委自身评分的标准差。每维度分题目内部归一化到 [0,1]。验证四维度交叉相关性，确认无严重冗余。

AI 回复：实现了 pairwise_icc() 函数 (c2_q2q3_model.py)，通过 ANOVA 分解计算 MS_between 和 MS_error，公式为 $(MS_between - MS_error) / (MS_between + MS_error)$ 。效度计算中淘汰论文奖项填充为 0。四维度交叉验证：最大 Spearman $r=0.32$ （效度 × 区分力），公平性与其他维度完全独立 ($r < 0.12$)，评分均值与获奖率 $r=0.10$ （标准分有效）。无严重冗余，指标体系结构合理。

采纳和人工修改情况：

团队审查后发现初始实现中两个关键问题：(1) 信度维度误用 Spearman 相关系数替代 ICC，经团队指出后 AI 改为正确的 ICC(2,1) 实现——Spearman 只衡量秩一致性但忽略绝对评分偏移，ICC 同时捕捉趋势一致和绝对值一致；(2) 效度计算仅包含入围论文（约 42%），团队要求纳入淘汰论文（奖项填充为 0），使得效度能完整衡量评委“区分入围 vs 淘汰”的能力。两项修复后团队要求重跑 Q2→Q3→Q4→Q5 全部代码和图表。修复后 ICC 信度值系统性低于原 Spearman 值，更真实反映了评委间绝对评分一致性的难度。团队成员确认所有修复后的指标值在业务逻辑上合理。

子问题 3：评委素质数学模型

[AI-3-1]

所用 AI 工具名称和版本：

DeepSeek, DeepSeek-V4, 深度求索 (DeepSeek)

具体使用目的和环节：

子问题 3 的熵权法 + TOPSIS 综合评价模型实现。团队决定采用客观赋权方法（熵权法）避免主观赋权引入的偏差，以 TOPSIS 进行多指标综合评价，并用 K-means++ 对评委进行聚类分层。团队要求 AI 实现：(1) 对四维度指标正向化 + Min-Max 归一化；(2) 熵权法计算各维度权重；(3) TOPSIS 计算每位评委的综合贴近度；(4) K-means++ 聚类（K 由肘部法则 + Silhouette 系数确定，业务约束 $K \geq 3$ ），将评委分为优秀/合格/需关注三档；(5) 等权 TOPSIS 作为稳健性检验对照。

关键交互记录（重要提示词与回复）：

提示词：对五题分别建模。Q2 输出的四维度指标矩阵做 Min-Max 归一化后，用熵权法赋权： $P_{ij} = z_{ij} / \sum z_{ij}$, $e_j = -1 / \ln(K) \cdot \sum P_{ij} \cdot \ln(P_{ij})$, $w_j = (1 - e_j) / \sum (1 - e_j)$ 。用 TOPSIS 计算贴近度 $S_i = D_i^- / (D_i^+ + D_i^-)$ 。对 TOPSIS 得分做 K-means++ 聚类，K 由肘部法则 + Silhouette 系数联合确定，业务约束 $K \geq 3$ 。输出五题熵权分布、聚类分层结果、Silhouette 系数。用等权 TOPSIS 做稳健性检验。

AI 回复：代码实现了完整熵权 + TOPSIS 流程 (c2_q2q3_model.py)。熵权分布：区分力维度权重最高 (0.304-0.442)，公平性维度权重最低 (0.145-0.249)——区分力权重高是因评委间标准差变异最大，属数据真实反映。TOPSIS 得分范围分布合理。聚

类结果：K=3（部分题目 K=2 因评委数不足，已修正下限为 $K \geq 3$ ），Silhouette 系数 0.241-0.329，分层结构合理。稳健性检验：熵权 TOPSIS 与等权 TOPSIS 的 Spearman $r=0.851-0.971$ ，方法稳健。输出图表包括 q3-weight-bar、q3-topsis-dist、q3-cluster-scatter、q3-robust-scatter。

采纳和人工修改情况：

团队审查后确认：(1) 熵权法区分力权重最高的结果与 PCA 的分析一致——评委评分离散度的差异确实最大，这不算法缺陷而是数据结构特征；(2) K-means++ 聚类在 E 题曾出现 K=2（Silhouette=0.329），团队要求 AI 在代码中添加 $K \geq 3$ 的业务约束后修复；(3) 团队要求 AI 为每个聚类结果给出实际含义的解读，如 Silhouette=0.243 意味着“评委在各维度的表现差异较大，分层边界不够清晰但不影响宏观分组意义”。

子问题 4：不同题目评委表现差异分析

[AI-4-1]

所用 AI 工具名称和版本：

DeepSeek, DeepSeek-V4, 深度求索（DeepSeek）

具体使用目的和环节：

子问题 4 的多组比较分析实现。团队确定使用非参数 Kruskal-Wallis 检验（因 196 位评委分组后各题样本量差异大——A 题仅 14 位，不满足 ANOVA 正态假设），并补充 Dunn 事后检验定位差异来源。团队要求 AI：(1) 以 Q3 输出的 TOPSIS 得分为因变量、题目为自变量做 KW 检验；(2) 报告 η^2 效应量；(3) 做 Dunn 事后检验（Bonferroni 校正 $\times 10$ ）；(4) 额外对信度、效度、区分力三个维度分别做 Dunn 检验，定位综合得分差异的来源维度。

关键交互记录（重要提示词与回复）：

提示词：用 `scipy.stats.kruskal` 对五题 TOPSIS 得分做 Kruskal-Wallis 检验，计算 η^2 效应量。做 Dunn 事后检验，z 检验公式自行实现，p 值 Bonferroni 校正 $\times 10$ 。此外对信度、效度、区分力三个子维度分别做 Dunn 检验，定位题目间差异来源于哪个维度。代码放在 `c2_q1q4_model.py` 的 Q4 部分。

AI 回复：KW 检验结果：H=11.710, $p=0.019$, $\eta^2=0.040$ （效应量中等）。Dunn 事后检验发现 B-D 题对 $p_{\text{adj}}=0.031$ 显著，B-E 题对 $p_{\text{adj}}=0.030$ 显著，其他 8 对不显著。分维度 Dunn 检验揭示：信度（H=53.1, $p<0.001$ ）和效度（H=41.0, $p<0.001$ ）在五题间差异极显著，区分力（H=20.3, $p<0.001$ ）显著，公平性（H=2.8, $p=0.59$ ）无显著差异。信度维度的差异主要来自 B 题与 E 题的对比，效度维度上 A 题和 E 题评委表现更优。公平性五题一致说明标准分公式在各题均有效。

采纳和人工修改情况：

团队审核了统计检验结果，重点关注了公平性五题无显著差异的发现——这验证了标准分公式在消除评委尺度差异方面五题表现一致。团队要求 AI 补充充分维度 Dunn 检验的代码，以精确定位综合得分的差异来源。团队在论文中坦诚了核心局限：由于评委完全不跨题，题目效应与评委池效应无法分离，本文只能报告“存在差异”而非建立因果。

子问题 5：网评成绩利用策略

[AI-5-1]

所用 AI 工具名称和版本：

DeepSeek, DeepSeek-V4, 深度求索 (DeepSeek)

具体使用目的和环节：

子问题 5 的敏感性分析与改进建议。团队综合 Q1-Q4 结论后，决定从两个路径评估网评的利用策略：(1) 模拟网评权重 α 从 0 到 1 变化时，网评-终评混合排名与奖项的 Spearman ρ 变化（敏感性分析）；(2) 基于 Q3 的评委 TOPSIS 得分对评委做素质加权，对比等权网评与加权网评的 Spearman ρ 提升。团队要求 AI 实现这两条路径并基于结果提出改进建议。

关键交互记录（重要提示词与回复）：

提示词：实现 Q5 两条分析路径。路径一：敏感性分析—— α 从 0 到 1（步长 0.1），计算 $\alpha \cdot \text{rank}(z_mean) + (1-\alpha) \cdot \text{rank}(award)$ 与奖项的 Spearman ρ ，绘制 ρ - α 曲线。路径二：素质加权—— $w = \text{TOPSIS 得分} / \sum \text{TOPSIS 得分}$ ，计算加权网评标准分，对比等权和加权的 Spearman ρ 。列出降权建议：TOPSIS 分层为‘需关注’的评委名单。代码命名为 c2_q5_model.py。

AI 回复：敏感性分析曲线显示：五题 ρ 均随 α 增大而单调下降， $\alpha=0$ （纯终评）时 ρ 最高但终评不可观测， $\alpha=0.25$ （当前赛制等权）时 ρ 介于 0.64-0.81 之间。C 题 ρ 从 $\alpha=0$ 到 $\alpha=0.25$ 下降最陡（-0.12），印证 Q1 中 C 题网评质量最弱的结论。素质加权后：加权网评的 ρ 在所有五题上均高于等权网评（提升幅度 0.006-0.218），C 题提升最为显著（+0.218）。降权建议：共有 23-46 位评委的 TOPSIS 得分位于最低档，建议对这部分评委的网评评分降权或不纳入最终成绩。

采纳和人工修改情况：

团队审查后发现初始实现使用了“秩混合”替代“分值混合”——这说明 α 变化对 Spearman ρ 的影响被人为压缩。团队与 AI 讨论后确认：由于集中评审的 $\bar{z}_{\text{central}}$ 不可观测，秩混合是不得已的近似方案。团队要求 AI 在论文中明确标注此简化假设及其局限性。此外，团队要求 AI 区分两个不同的“等权”概念：Q5 中的等权是当前赛制实际使用的评委简单平均（基线对照），Q3 中稳健性检验的等权是等权 TOPSIS（方法稳健性验证）——两者目的不同，避免读者混淆。

跨子问题代码审查与图表生成

[AI-0-4]

所用 AI 工具名称和版本：

DeepSeek, DeepSeek-V4, 深度求索 (DeepSeek)

具体使用目的和环节：

跨子问题一致性审查。Q1-Q5 五个子问题的代码实现完成后，团队要求 AI 执行两轮系统性审查：(1) 代码深度审计——检查各子问题代码与数学推导的一致性、代理值选择的正确性、方案确认书的匹配度；(2) 跨子问题审查——检查符号体系的统一性、子问题间数据流衔接的正确性、核心假设的一致性。审查发现的代码问题需修复后重跑全部模型和图表。

关键交互记录（重要提示词与回复）：

提示词：请审查所有代码文件(c2_q1q4_model.py, c2_q2q3_model.py, c2_q5_model.py, c3_generate_charts.py) 与数学推导 (math-sub1.tex 到 math-sub5.tex) 的一致性。重点检查：(1) z-score 是按评委还是按列计算？(2) 信度用 Spearman 还是 ICC？(3) 效度是否纳入了淘汰论文？(4) Q5 是分值混合还是秩混合？(5) K-means 的 K 是否满足 $K \geq 3$ 约束？(6) 内部报告的数值是否已过期？

AI 回复：发现 6 个问题：(1) z-score 按列计算而非按评委——混合了不同评委的评分（关键，已修复）；(2) 信度用 Spearman 替代 ICC——高估了信度值（关键，已修复）；(3) 效度仅用入围论文——排除了淘汰论文的信息（关键，已修复）；(4) Q5 用秩混合替代分值混合——低估了 α 敏感度（已标注）；(5) E 题 $K=2$ 违反 $K \geq 3$ 约束（已修复）；(6) 内部报告数值全部过时（已刷新）。18 项审查中有 12 项通过。全部修复后代码审查通过。

采纳和人工修改情况：

团队逐项验证了 AI 审查发现的每个问题，确认修复后的代码与数学推导完全一致。特别核实了：(1) z-score 按评委 ID 计算后 Spearman ρ 从 0.737 升至 0.797；(2) ICC 替代 Spearman 后信度值更真实但系统性降低——这符合预期因为 ICC 同时捕捉绝对偏差；(3) 效度纳入淘汰论文后更多评委的得分被重新校准。修复后的全部图表由 AI 利用多模态模型逐张审查，20 张图表全部通过。

[AI-0-5]

所用 AI 工具名称和版本：

DeepSeek, DeepSeek-V4, 深度求索 (DeepSeek)；硅基流动图像理解模型, Qwen3-VL-30B, 阿里云 / 硅基流动 (SiliconFlow)

具体使用目的和环节：

论文撰写与图表生成。全部建模计算完成后，团队要求 AI 完成：(1) 批量生成全部 20 张图表（c3_generate_charts.py），图表标注中文化、图例位置调整避免遮挡、标题精简；(2) 利用多模态模型逐张审查图表质量（20/20 通过）；(3) 生成各子问题的数学推导 LaTeX 文件（math-sub1.tex 至 math-sub5.tex）；(4) 撰写论文正文 main.tex 并编译为 PDF；(5) 多轮精修——补充 13 处数据结果的实际竞赛场景含义解读（如 C 题三指标联动分析、熵权极端值的实际意义、Silhouette 系数的分层含义等），使论文分析从技术性描述转向实际应用解读。

关键交互记录（重要提示词与回复）：

提示词：批量生成全部图表。横轴标签统一为“A 题”“B 题”等中文格式，图例位置设为 upper left 避免遮挡，标题去除冗余括号注释。生成后调用多模态模型逐张审查，检查标注正确性、视觉可读性、数据与终端输出的一致性。编译论文 main.tex，检查编译错误。

论文中有很多地方只给了知识性技术性说明但没有给出解读。比如：对四个维度分别做 Kruskal-Wallis 检验的 H 值和 p 值都报了，但没有说这些差异在实际竞赛场景中意味着什么。请系统性发现此类缺失，并予以解读——每条数据结果都要对应到竞赛组织的实际意义。

AI 回复：20 张图表全部生成并逐张通过多模态审查（“通过”级别）。论文编译成功（24 页，无错误）。发现并修复了 13 处解读缺失：(1) C 题三指标联动—— ρ 高而 r 低意味着网评初筛功能正常但入围论文内部排序不可靠；(2) B 题区分力权重最高（0.442）——B 题评委给分习惯差异极大，标准分校正对 B 题必要且有效；(3) 公平性五题无差异——标准分公式消除尺度差异的效果五题一致；(4) E 题区分力权重最低——不是评委表现差，而是 E 题评委打分尺度本来就比较统一，区分力维度区分不开；(5) 另 9 处涉及各个具体指标的解读。论文页数从 22 页增加至 24 页。

采纳和人工修改情况：

团队审核了全部 20 张图表的多模态审查结果，确认通过。论文解读修复方面，团队特别关注了“技术性 vs 实际性”的区分——要求每条解读必须映射到竞赛组织的实际操作场景。例如“B 题区分力权重最高”的技术性解读是“B 题评委间标准差变异最大”，而实际性解读是“这意味着标准分校正对 B 题的必要性远高于其他题：如果不做 z-score，那些‘敢打高分’的评委将主导 B 题排名”。团队逐一核实了 13 处解读的准确性和实际相关性后定稿。

终稿编译

[AI-0-0]

所用 AI 工具名称和版本：

DeepSeek, DeepSeek-V4, 深度求索 (DeepSeek)

具体使用目的和环节：

终稿 LaTeX 编译与排版。论文正文（含模型描述、公式推导、结果分析）由参赛队独立撰写，AI 仅将已完成的文字、公式和图表转化为 LaTeX 代码并编译为 PDF，全程不参与内容生成。

关键交互记录（重要提示词与回复）：

提示词：将以下论文正文编译为 LaTeX，不修改任何实质内容。

AI 回复：（编译完成，输出 PDF）

采纳和人工修改情况：

AI 编译后人工检查排版效果，修正格式问题，内容未做任何 AI 修改。

[AI-0-1]

所用 AI 工具名称和版本：

DeepSeek, DeepSeek-V4, 深度求索 (DeepSeek)

具体使用目的和环节：

本文件的条目整理、格式编排与 LaTeX 编译。团队导出竞赛期间的全部对话记录后，要求 AI 按照竞赛规定的条目格式汇总其中涉及的 AI 工具使用情况并编译为支撑材料 PDF。

关键交互记录（重要提示词与回复）：

提示词：按照竞赛规定的 [AI-X-Y] 条目格式，汇总四个子问题中所有 AI 工具使用情况，每个条目需包含工具名称版本、使用目的和环节、关键交互记录、采纳和人工修改情况，编译为 PDF。

AI 回复：（完成全部条目的整理与编译）

采纳和人工修改情况：

团队审核了全部条目的内容完整性和表述准确性，确认后定稿。