

关于某竞赛网评结果的建模与分析

2026 年 7 月

摘 要

本文针对某竞赛双阶段评审制度中网评结果的有效性问题的有效性问题，基于 A-E 五个题目共 4876 篇论文的评审数据，完成了五项系统建模任务。首先，采用 Spearman 秩相关系数和 ROC 曲线从多角度量化网评与终评的相关性；其次，从信度、效度、公平性、区分力四个维度构建评委基本素质指标体系；再次，运用熵权法结合 TOPSIS 建立评委综合素质评价模型，并以 K-means++ 实现分层管理；接着，通过 Kruskal-Wallis 检验分析不同题目评委表现的差异；最后，综合各子问题结论提出网评成绩利用的改进策略。

主要结果如下：(1) 网评标准分与最终奖项的全题 Spearman $\rho = 0.797$ ，筛选命中率 74.8%，假阴性率仅 3.3%，ROC AUC 达 0.932，表明网评制度总体有效；(2) 构建的四维度指标体系维度间最大交叉 Spearman $r = 0.558$ ，无严重冗余，公平性与其他维度完全独立 ($r < 0.12$)；(3) 熵权法在五题中给出差异化的客观权重，区分力权重始终最高 (均值 0.386)，TOPSIS 综合评价后通过 K-means++ 将 196 位评委分为优秀、良好、合格、需关注四档，熵权与等权的 Spearman r 达 0.864–0.969，方法稳健；(4) 五题评委 TOPSIS 综合得分无显著差异 (Kruskal-Wallis $H = 8.450$, $p = 0.076$)，但信度、效度、区分力等子维度在题目间差异极显著 ($p < 0.001$)，公平性维度跨题一致 ($p = 0.59$)；(5) 基于评委 TOPSIS 得分的素质加权方案在所有五题中均正向提升网评与奖项的 Spearman ρ ，E 题收益最大 (+0.028)，建议保留当前 1/4 网评权重并对 6.6% 低素质评委降权。

关键词：网评审查；评委素质评价；指标体系；熵权 TOPSIS；K-means 聚类；Spearman 相关分析

1 问题重述

某竞赛采用双阶段评审机制。网评阶段，每篇论文随机分配给 4 位评委以百分制评分，通过标准分公式归一化后按总分排名，前 55% 进入集中评审。集中评审由 3 位评委独立评分，其标准分与网评平均标准分各占 1/4 和 3/4 权重合成最终成绩。题目附带附件 A-E 五个题目的网评评审数据，包含评委 ID、原始分、最终奖项等信息，要求完成以下五项建模任务：

- (1) 量化网评成绩与最终成绩的相关性，从多角度评价网评结果的有效性。
- (2) 从不同角度出发，构建合理的评委基本素质指标体系。
- (3) 建立评价评委基本素质的数学模型，应用于附件数据并给出结论。
- (4) 分析五个题目中评委整体表现的显著差异及可能原因。
- (5) 分析将网评成绩加入总成绩的利弊，提出更有效利用网评成绩的建议。

各子问题的依赖关系为：Q2（指标体系）为 Q3（数学模型）和 Q4（差异分析）提供评价维度，Q3 的输出为 Q4 提供个体评委得分，Q1（相关性分析）与 Q3/Q4 可独立进行，Q5（利用策略）需要综合前四个子问题的全部结论。

2 基本假设

为简化建模复杂度，本文做出以下关键假设：

1. **最终奖项作为论文真实水平的代理。**集中评审评分在数据中不可见，但集中评审评委素质理论上高于网评评委，因此最终奖项（一等奖/二等奖/三等奖/未入围）是论文真实水平的最优观测代理。
2. **评委不跨题评审，各题独立评奖。**数据验证显示 196 位评委的 ID 均含题目前缀（如专家 A01 仅在 A 题出现），五题评委池完全互斥。各题按题内排名确定入围名单及奖项等级（一等奖/二等奖/三等奖），不存在跨题竞争——各题评委表现可独立建模，排名与相关性分析均在题内进行。
3. **标准分公式有效消除评分尺度差异。**每位评委按自身均值和标准差对原始分进行 z-score 标准化，消除了不同评委习惯性偏高或偏低的系统性偏差。
4. **4 位评委对同一论文的评分可视为独立重复测量。**网评阶段每篇论文由 4 位评委独立评分，为计算评分者间信度（ICC）提供了必要的重复测量结构。
5. **评价维度间不存在循环依赖。**信度基于评委间评分一致性、效度基于评分与奖项的相关性、公平性基于评分均值偏差、区分力基于评分离散度——四者均直接由原始数据计算，无相互引用。

3 数据概览

赛题提供的附件包含 A-E 五个题目的网评评审数据，经清洗后共 4876 篇论文、196 位评委。各题基本统计量如下：

表 1: 各题数据概览

题目	论文总数	按规则入围数 (55%)	获奖数	评委数
A	355	195	150	14
B	1542	848	577	55
C	479	263	202	20
D	1908	1049	735	69
E	592	326	410	38
合计	4876	2681	2074	196

注：按赛题规则，网评排名前 55% 的论文进入集中评审（入围）。获奖论文指最终获得一等奖、二等奖或三等奖的论文（共 2074 篇，占总数的 42.5%）。未获奖论文的奖项字段为空值（NaN），在相关性分析中映射为 0。数据清洗包括：读取各题附件 Excel、提取评委 ID 与题目前缀、计算标准分并合并为统一格式（详见支撑材料 `c0_data_clean.py`）。

4 符号说明

表 2: 主要符号说明

符号	含义
$x_{j,i}$	评委 j 对论文 i 的原始评分
$z_{j,i}$	评委 j 对论文 i 的标准分
$\bar{z}_i$	论文 i 的网评平均标准分
ρ	Spearman 秩相关系数
r	Pearson 线性相关系数
ICC_{jk}	评委 j 与 k 之间的组内相关系数
R_j^{rel}	评委 j 的信度得分
F_j	评委 j 的公平性得分 (偏差 $ z $ 值)
D_j	评委 j 的区分力 (评分标准差)
w_j	第 j 维度的熵权
S_i	评委 i 的 TOPSIS 贴近度
H	Kruskal-Wallis 检验统计量
η^2	Kruskal-Wallis 效应量

5 子问题 1：网评与终评相关性分析

5.1 模型建立

由于最终奖项为等级数据 (未入围 =0、三等 =1、二等 =2、一等 =3)，网评标准分为连续数据，本文采用 Spearman 秩相关系数作为主要度量。对入围论文追加 Pearson 线性相关作为辅助分析，但需前置正态性检验 ($|\text{偏度}| < 1$ 且 $|\text{峰度}| < 3$)。

5.1.1 标准分计算

根据赛题给定的标准分公式，对每位评委 j 评阅的 n_j 篇论文：

$$\bar{x}_j = \frac{1}{n_j} \sum_{i=1}^{n_j} x_{j,i}, \quad z_{j,i} = \frac{x_{j,i} - \bar{x}_j}{\sigma_j} \quad (1)$$

其中 σ_j 为评委 j 评分标准差。每篇论文的网评综合得分取其 4 位评委标准分的均值 $\bar{z}_i$ 。

5.1.2 Spearman 秩相关

将 $\bar{z}_i$ 和奖项 y_i 分别排序得 $\{r_i^{(z)}\}, \{r_i^{(y)}\}$ ：

$$\rho = 1 - \frac{6 \sum_{i=1}^n (r_i^{(z)} - r_i^{(y)})^2}{n(n^2 - 1)} \quad (2)$$

大样本效应量规范：全题 $n = 4876$ ， p 值必然显著，必须报告效应量 $|\rho|$ ：< 0.1 可忽略、0.1–0.3 弱、0.3–0.5 中等、> 0.5 强。

5.1.3 Pearson 线性相关（辅助）

对获奖论文（ $n = 2074$ ；按规则前 55% 约 2681 篇入围集中评审，其中 2074 篇最终获奖），经正态性检验通过后计算 Pearson r ：

$$r = \frac{\sum_{i=1}^n (\bar{z}_i - \bar{z})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (\bar{z}_i - \bar{z})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (3)$$

5.1.4 筛选有效性

网评排名前 55% 的论文进入集中评审的命中率与假阴性率：

$$\text{命中率} = \frac{|\{\text{前 55}\% \} \cap \{\text{获奖}\}|}{|\{\text{前 55}\% \}|}, \quad \text{假阴性率} = \frac{|\{\text{后 45}\% \} \cap \{\text{获奖}\}|}{|\{\text{获奖}\}|} \quad (4)$$

选用命中率和假阴性率而非 Accuracy 或 TPR（召回率）是出于竞赛场景的领域考量。数据严重不平衡——前 55% 入围、后 45% 淘汰——Accuracy 天然偏向“预测淘汰”的多数类，无法反映筛选质量。赛方的核心关切不是“抓住了多少好论文”，而是“被淘汰的里面有没有冤案”——一个一等奖论文如果在网评阶段就被踢出局，是制度层面的严重事故。假阴性率直接回答了这一焦虑：FNR=3.3%，意味着每 100 个获奖者里只有约 3 个被网评误杀。

5.1.5 ROC 曲线——区分能力

以网评标准分为预测变量，以“是否获一等奖”为二分类标签绘制 ROC 曲线，AUC 衡量网评对优秀论文的识别能力。

5.2 结果分析

表 3: 网评标准分与最终奖项的相关性

题目	Spearman ρ	Pearson r (入围)	ROC AUC (一等)
A	0.768	0.515	0.942
B	0.792	—	0.932
C	0.762	0.319	0.872
D	0.811	0.641	0.975
E	0.808	0.543	0.933
全题	0.797	0.540	0.932

注: B 题入围论文网评标准分偏度/峰度不满足正态性假设, Pearson r 不报告。




图 1: 各题网评效率 (效应量规范)

本文区分网评的两个任务维度: **初筛效率** (全样本 Spearman ρ , 度量网评能否区分论文整体优劣) 和 **入国内效率** (获奖论文上的 Spearman ρ 或 Pearson r , 度量网评在获奖论文内部继续区分奖项等级的能力)。两者分属不同任务, 数值不可直接比较。

全题 Spearman $\rho = 0.797$, 属于强相关。五题 ρ 值在 0.762–0.811 之间, 均远超中等相关阈值 (0.3) 和强相关阈值 (0.5), 表明网评排名与最终奖项排名高度一致。D 题相关性最强 ($\rho = 0.811$), 说明 D 题网评与最终奖项排名的一致性最好。

值得关注的是 C 题: 虽然 Spearman ρ 仍在强相关区间 (0.762), 但 Pearson r 仅为 0.319, 且 AUC (0.872) 低于其他四题 (均 ≥ 0.932)。 ρ 高而 r 低意味着 C 题网评能正确区分论文的相对优劣 (排序对), 但入围论文之间的得分差距很小、线性趋势弱。C 题初筛效率强 ($\rho = 0.762$), 但入国内效率弱 ($\rho = 0.303$ 、 $r = 0.319$), 五题最低——入围后排序应更依赖集中评审。




图 2: ROC 曲线: 网评标准分预测一等奖

五题 ROC AUC 在 0.872–0.975 之间, 全题 AUC 为 0.932, 远超随机分类 ($AUC=0.5$), 表明网评对一等奖具有卓越的区分能力。D 题 AUC 达 0.975, 几乎接近完美分类。

需要指出的是, 一等奖 AUC 反映最乐观的识别力。随二分类阈值放宽 (一等奖 vs 其余 $\rightarrow$ 二等奖及以上 vs 其余 $\rightarrow$ 获奖 vs 未入围), AUC 将递减, 入围论文内部的区分力远低于一等奖的区分力——多阈值 ROC 对比图见附录 A, C 题在此递减趋势中的衰减最为显著。

网评筛选命中率 74.8%, 假阴性率仅 3.3%, 即前 55% 论文中约 3/4 最终获奖, 被淘汰但实际获奖者仅占获奖总数的 3.3%。网评制度在牺牲极少优秀论文的代价下, 有效过滤了约 25% 的低质量论文。

5.3 本节结论

网评结果与最终成绩存在强秩相关 ($\rho = 0.797$), 能有效完成初筛任务。全题 ROC AUC 达 0.932, 对一等奖的区分力卓越。筛选命中率 74.8% 且假阴性率仅 3.3%, 网评制度在效率与公平之间取得了良好的平衡。

6 子问题 2: 评委基本素质指标体系

6.1 构建原则

“评委基本素质”是模糊概念, 必须先操作化为可度量指标。本文从利益相关者视角, 构建四维度指标体系:

本文从所给数据 (评委评分与最终奖项) 中穷尽了可推导的所有独立维度: 评分者间一致性 (信度)、与基准的一致性 (效度)、评分分布偏倚 (公平性) 和评分离散度 (区

分力)。未覆盖的侧面(如评语质量、审阅效率等)因数据中不存在,不在本文讨论范围内。

6.2 维度一: 信度 (Reliability) ——其他评委视角

评分者间信度的评估方法在教育和心理测量领域已有广泛讨论 [2, 3, 4, 5]。

定义: 该评委的评分能否被其他评委复现。如果换一位评委审阅同一篇论文, 结论是否一致?

量化: 成对 ICC(2,1) 均值。对评委 j 与评委 k ($k \neq j$), 计算两人共同评阅论文子集 $\mathcal{P}_{jk}$ 上的 ICC:

$$\text{ICC}_{jk} = \frac{\sigma_{\text{between}}^2}{\sigma_{\text{between}}^2 + \sigma_{\text{within}}^2} \quad (5)$$

其中 $\sigma_{\text{between}}^2$ 为论文间方差 (系统变异), σ_{within}^2 为评分者内方差 (随机误差)。评委 j 的信度得分:

$$R_j^{\text{rel}} = \frac{1}{K-1} \sum_{k \neq j} \text{ICC}_{jk} \quad (6)$$

选用 ICC(2,1) 而非 ICC(1,1), 因评委和论文均为随机效应 (评委从潜在评委池中抽取, 论文从所有投稿中抽取); 选用“单一评分者” ($k=1$) 而非“平均评分者” ($k=4$), 因本文关心的是单个评委是否可靠——若换成另一位评委, 结论是否一致。

取值范围 $[0, 1]$, 根据 Koo & Li (2016)[1] 的建议, 阈值: < 0.50 差, $0.50-0.75$ 中等, > 0.75 良好。

信度和效度的区别在于——信度不关心奖项结果, 只关心评委之间是否一致。一个评委可能四人一致但全部判错 (信度高、效度低), 也可能总是独行但每次都对 (信度低、效度高)。两者捕获的是评委素质的不同侧面。

6.3 维度二: 效度 (Validity) ——参赛者视角

定义: 该评委的评分能否有效识别论文真实质量。高分论文最终是否获奖?

量化: 以全部论文 (含淘汰论文, 奖项等级 $=0$) 为样本, 计算评分与最终奖项的 Spearman 秩相关系数:

$$\rho_j = 1 - \frac{6 \sum_{i=1}^{n_j} (r_i^{(x)} - r_i^{(y)})^2}{n_j(n_j^2 - 1)} \quad (7)$$

采用 Cohen 效应量分级标准: $|\rho_j| < 0.1$ 可忽略, $0.1-0.3$ 弱, $0.3-0.5$ 中等, > 0.5 强。

6.4 维度三：公平性（Fairness）——组织者视角

定义：该评委是否存在系统性评分偏差——对所有人特别严格或特别宽松？

量化：评分均值偏离同题全体均值的标准化偏差：

$$\text{bias}_j = \bar{x}_j - \bar{X}_{\text{topic}}, \quad F_j = \left| \frac{\text{bias}_j}{\sigma_{\text{bias}}} \right| \quad (8)$$

本文采用标准化偏差的绝对值，设定阈值： $|z| < 1$ 正常，1-2 轻微偏差， > 2 显著偏差。

6.5 维度四：区分力（Discrimination）——学术评审理角

定义：该评委的评分能否有效拉开论文差距。如果所有论文得分相同，等于没有评审。

量化：评分标准差和变异系数：

$$D_j = \sigma_j = \sqrt{\frac{1}{n_j - 1} \sum_{i=1}^{n_j} (x_{j,i} - \bar{x}_j)^2}, \quad \text{CV}_j = \frac{\sigma_j}{\bar{x}_j} \quad (9)$$

本文根据各题评分标准差的分布特征，设定阈值： $\sigma_j < 8$ 区分度不足， $\sigma_j > 20$ 评分不稳定。

区分力和公平性之间存在潜在权衡——给极端分的评委区分力高但均值可能偏离全题均值，全文将在 5.6 验证四维度不存在严重重叠（最大交叉 $r = 0.558$ ，信度 $\times$ 效度），并在子问题 3 通过熵权法客观确定各维度在综合评价中的权重。

6.6 统计独立性验证

四维度间最大交叉 Spearman $r = 0.558$ （信度 $\times$ 效度），属于中等相关，远低于严重共线性阈值（ $r > 0.8$ ）。公平性与其他所有维度 $r < 0.12$ ，完全独立。信度与效度的中等正相关（ $r = 0.558$ ）并非冗余，而是说明评委素质具有跨维度一致性——好评委往往在信度、效度、区分力等多个侧面同时占优，这恰好支持了使用多维度综合评价（而非单一指标筛选）的建模必要性。




图 3: 评委基本素质指标体系层次结构图

6.7 本节结论

从信度（可复现性）、效度（准确性）、公平性（无系统偏差）、区分力（区分度）四个维度构建的指标体系，实现了对“评委基本素质”的全面操作化定义，维度间存在中等正相关但不构成严重冗余。该体系为子问题 3 的综合评价模型提供了清晰的输入框架。

7 子问题 3: 评委素质综合评价模型

7.1 模型框架

子问题 2 输出归一化后的四维度指标矩阵 $\mathbf{Z} = [z_{ij}]_{K \times 4}$ ，其中 z_{ij} 为评委 i 在维度 j 上的归一化得分（ $i = 1, \dots, K$ ， $j = 1, \dots, 4$ ， $z_{ij} \in [0, 1]$ ）。四个维度均正向化（越大越好），其中公平性取 $|z|$ 值的负向做 Min-Max 归一化。

目标：将四维度映射为一维综合素质得分 $S_i \in [0, 1]$ ，并对评委进行分层。

7.2 步骤一：熵权法确定客观权重

熵权法基于数据驱动，利用各维度数据的区分度（信息熵）自动分配权重，避免主观赋权的争议。

概率化：

$$p_{ij} = \frac{z_{ij}}{\sum_{i=1}^K z_{ij}}, \quad j = 1, \dots, 4 \quad (10)$$

信息熵：

$$e_j = -\frac{1}{\ln K} \sum_{i=1}^K p_{ij} \ln p_{ij} \quad (11)$$

$e_j \in [0, 1]$ 。 $e_j \rightarrow 1$ 表示该维度所有评委得分几乎相同（无区分度）， $e_j \rightarrow 0$ 表示差异极大。信息效用值 $d_j = 1 - e_j$ ，熵权：

$$w_j = \frac{d_j}{\sum_{k=1}^4 d_k}, \quad \sum_{j=1}^4 w_j = 1 \quad (12)$$

值得指出的是， w_j 反映的是维度的“区分度”而非“重要性”[7]。某维度权重低可能因为所有评委在该维度表现接近，而非该维度不重要。

7.3 步骤二：TOPSIS 综合评价

TOPSIS 法 [6] 通过计算各方案与正负理想解的距离进行排序：

加权标准化矩阵： $v_{ij} = w_j \cdot z_{ij}$ 。

正理想解（各维度最优值）： $A^+ = (\max_i v_{i1}, \max_i v_{i2}, \max_i v_{i3}, \max_i v_{i4})$

负理想解（各维度最劣值）： $A^- = (\min_i v_{i1}, \min_i v_{i2}, \min_i v_{i3}, \min_i v_{i4})$

欧氏距离与贴近度：

$$D_i^+ = \sqrt{\sum_{j=1}^4 (v_{ij} - A_j^+)^2}, \quad D_i^- = \sqrt{\sum_{j=1}^4 (v_{ij} - A_j^-)^2}, \quad S_i = \frac{D_i^-}{D_i^+ + D_i^-} \in [0, 1] \quad (13)$$

$S_i \rightarrow 1$ ：越接近理想最优； $S_i \rightarrow 0$ ：越接近最劣。

7.4 步骤三：K-means++ 分层

以 TOPSIS 得分 S_i 和四维度原始归一化值 $\{z_{i1}, \dots, z_{i4}\}$ 为特征，聚类不以一维 TOPSIS 得分直接切段，而是以五维特征进行。TOPSIS 得分为聚类提供了“优秀方向”的锚定——保证各簇有明确的高低次序；四维度原始值则保留了个体在不同维度上的类型差异——两个 TOPSIS 得分相近但雷达图形状迥异的评委可能因此被归入不同簇。最终各簇按 TOPSIS 均值降序排列命名。对 K 位评委做 K-means++ 聚类 [8]。聚类数 C 由 Silhouette 系数确定，并受业务约束 $C \geq 3$ （保证“优秀/合格/需关注”三档的最低区分度）。

7.5 稳健性检验

同时计算等权 TOPSIS ($w_j = 0.25$) 得分 S_i^{eq} ，比较 Spearman 秩相关：

$$\rho_{\text{robust}} = \text{Spearman}(S_i, S_i^{\text{eq}}) \quad (14)$$

$\rho_{\text{robust}} > 0.8$ 则权重选择对排名影响有限，结论稳健。

7.6 结果分析

7.6.1 熵权分布

表 4: 五题四维度熵权分布

题目	信度	效度	公平性	区分力
A	0.153	0.224	0.240	0.382
B	0.203	0.203	0.152	0.442
C	0.199	0.216	0.222	0.363
D	0.203	0.183	0.177	0.437
E	0.153	0.383	0.159	0.304




图 4: 五题四维度熵权分布

区分力权重在所有五题中均最高（均值 0.386），因评委间评分标准差的变异最大。B 题区分力权重最高 (0.442)，意味着 B 题评委的给分习惯差异极大——有人评分跨度达 30-90 分，有人只在 55-65 之间徘徊。反过来说，这也表明标准分校正对 B 题的必要性远高于其他题：如果不做 z-score，那些”敢打高分”的评委将主导 B 题排名。相比之下，E 题区分力权重最低 (0.304)，评委打分尺度相对统一，区分力维度区分不开谁好谁差——这不是评委表现差，而是大家在这方面确实差不多。效度在 E 题权重最高 (0.383)，说明 E 题评委之间预测论文奖项的能力差异最为明显；而 D 题效度权重最低 (0.183)，意味着 D 题评委在”谁能获奖”这件事上半斤八两——谁的预测都跟最终结果差不太多，该维度在 D 题缺乏区分价值。信度和公平性权重各题相对稳定。

7.6.2 TOPSIS 得分与分层

表 5: 各题评委 TOPSIS 分层结果

题目	评委数	K	Silhouette	分层结构
A	14	3	0.391	优秀 2/良好 6/合格 6
B	55	4	0.244	优秀 16/良好 22/合格 11/需关注 6
C	20	3	0.375	优秀 3/良好 14/合格 3
D	69	4	0.250	优秀 24/良好 21/合格 17/需关注 7
E	38	3	0.277	优秀 14/良好 20/合格 4




图 5: 各题评委 TOPSIS 得分分布




图 6: 评委聚类散点图: 信度 $\times$ 区分力 (按分层着色)

五题 TOPSIS 得分均值在 0.458–0.569 之间。E 题得分最高 (0.569), C 题得分最低 (0.458)。

Silhouette 系数反映了聚类结构的清晰程度 (< 0.25 弱结构, $0.25\text{--}0.50$ 可接受): A 题 0.391 最高, 说明 A 题评委素质分层最清晰——“好评委”和“一般评委”之间有明显的断层, 划分数线时有信心; B 题 0.244 最低, 说明 B 题评委素质是连续谱, 没有自然断崖, 边界上的评委可能“差一点就掉档”, 对其做分层管理时不宜一刀切。

从分层看, “需关注”评委合计 13 人 (占 6.6%)。D 题 7 人需关注为各题最多——D 题评委池最大 (69 人), 但质量问题也最多, 提示规模扩大后质量管控难度增加。A 题无“需关注”档, 虽为小题目但评委整体素质整齐。C 题“优秀”与“合格”各仅 3 人、中间 14 人在“良好”档, 呈现“两头小中间大”的橄榄形——多数 C 题评委表现中规中矩, 极好和极差的都很少。但 C 题雷达图 (附录 B) 揭示了更深层的问题: 优秀层 3 位评委 (C01、C05、C17) 虽然在区分力和效度上表现突出, 但他们恰恰是评分偏离全题均值最大的评委——C01 平均给分 37.4 (远低于均值约 54)、C05 平均 73.6 (远高于均值)、C17 平均 35.9 (远低于均值), 导致优秀层的公平性指标 (归一化后 0.14) 远低于良好层 (0.84)。这一现象与 C 题本身的低信号特征密切相关。Q1 已显示 C 题 Pearson $r = 0.319$, 是五题入围论文中唯一的弱相关——入围论文质量高度接近, 网评数值难以反映真实等级差异。在此背景下, 区分力与公平性之间存在条件性张力: 当论文质量有明显梯度时 (如 D 题 $r = 0.641$), 评委打分散分仍能对齐群体共识; 但当论文质量接近时 (如 C 题 $r = 0.319$), 评委缺乏明确的评分锚点, 打分散分自然意味着偏离群体均值——C01 (区分力 22.2) 偏离全题均值 -21.6 分即是这一机制在低信号环境下的极端表现。区分力与公平性的关系并非普遍规律, 而是取决于题目自身的信号强度。由于熵权法中区分力权重最高 (C 题 0.363), 极端评分者在 TOPSIS 综合排名中被推至前列, 但这并不意味着他们是“最合理”的评委, 实际管理中需结合公平性维度综合权衡。

7.6.3 稳健性

五题熵权 TOPSIS 与等权 TOPSIS 的 Spearman 秩相关系数分别为: A 题 0.969、B 题 0.895、C 题 0.947、D 题 0.864、E 题 0.962, 全部 > 0.8 。方法对权重选择不敏感。进一步测试了 CRITIC、CV、标准差、PCA、灰色关联度共 5 种客观赋权法, 全题排名与熵权的 Spearman ρ 最低 0.867 (PCA)、最高 0.990 (CV), 聚类分层结构完全不变。TOPSIS 排名对赋权方法的选择不敏感, 结论稳健。D 题 0.864 相对最低——“数据强烈”建议”给区分力高权重 (0.437), 如果强行均分四维度各 25%, 排名偏移会比其他题稍大; 但即使变化最大的 D 题, 两种排序的一致性仍然很高, 实际使用中两种方案差异不大。

值得指出的是, 熵权 w_j 反映各维度在加权标准化矩阵中的输入权重, 但 TOPSIS 以欧氏距离为排序准则, 高方差维度在距离计算中天然占据更大比例。五题 Shapley 方差分解显示, 区分力实际贡献为 0.231–0.797, 在 A/B/C/D 四题中单独解释 77–88% 的 TOPSIS 方差。但这不是方法的偏向, 而是数据告诉我们的核心事实: 在竞赛网评场景

中, 一个评委能否有效区分不同质量的论文 (区分力), 本身就是综合素质中最核心的维度。熵权法只是忠实地反映了这一数据特征。E 题提供了反例验证——当效度维度的区分度足够大时 (熵权 0.383), 效度取代区分力成为 TOPSIS 得分的最大贡献者 (Shapley 0.451), 说明该方法不会机械地跟随单一维度。

7.7 本节结论

熵权法 +TOPSIS 成功将四维度指标合成为一维综合评价得分。K-means++ 聚类将评委分为三至四档, 为差异化管理和 Q5 的降权建议提供了数据基础。

8 子问题 4: 不同题目评委表现差异分析

8.1 Kruskal-Wallis H 检验

五题评委完全不跨题, 因此不能假设同一评委在不同题目的表现差异, 只能比较五组独立评委池的素质分布。部分题目样本量小 (A 题 14 位), 不满足 ANOVA 正态性假设, 选用非参数 Kruskal-Wallis 检验 [9]。

对于 $k = 5$ 组独立样本, 原假设 H_0 : 五组来自同一分布。将 $N = 196$ 个观察值混合排序:

$$H = \frac{12}{N(N+1)} \sum_{g=1}^5 \frac{R_g^2}{n_g} - 3(N+1) \quad (15)$$

其中 R_g 为第 g 组的秩和。若 KW 显著 ($p < 0.05$), 进行 $\binom{5}{2} = 10$ 对 Dunn 事后检验 [10] (Bonferroni 校正 $p_{\text{adj}} = \min(p_{\text{raw}} \times 10, 1)$)。

效应量:

$$\eta^2 = \frac{H - k + 1}{N - k} \quad (16)$$

解释: < 0.06 小效应, $0.06-0.14$ 中等, > 0.14 大效应。

8.2 结果分析

表 6: 各题 TOPSIS 得分与四维度均值对比

题目	评委数	TOPSIS	信度	效度	区分力
A	14	0.494±0.132	0.481	0.570	13.1
B	55	0.516±0.156	0.608	0.654	13.9
C	20	0.458±0.152	0.426	0.568	12.0
D	69	0.515±0.146	0.667	0.695	15.6
E	38	0.569±0.172	0.626	0.677	13.8




图 7: 五题评委 TOPSIS 得分对比

Kruskal-Wallis 检验结果: $H = 8.450$, $p = 0.076 > 0.05$, $\eta^2 = 0.023$ 。五题评委 TOPSIS 综合得分无显著差异, 效应量极小。Dunn 事后检验经 Bonferroni 校正后, 10 对比较全部不显著。

尽管均值无显著差异, 各题评委素质的离散程度有所不同: E 题 TOPSIS 标准差最大 (0.172), 评委之间水平最不均匀; A 题最小 (0.132), 虽只有 14 人但质量整齐——没有特别突出的好评委, 也没有严重拖后腿的。E 题的高方差也预示着: 若对 E 题使用素质加权 (让好评委说话分量更重、差评委降权), 收益会是五题中最大的 (Q5 中 E 题 $\Delta\rho = +0.028$ 最高, 证实了这一预期)。

8.2.1 分维度检验

对四个维度分别做 Kruskal-Wallis 检验:

- 信度: $H = 53.1$, $p < 0.001$ ——五题间差异极显著
- 效度: $H = 41.0$, $p < 0.001$ ——五题间差异极显著

- 区分力: $H = 20.3$, $p < 0.001$ ——五题间差异极显著
- 公平性: $H = 2.8$, $p = 0.59$ ——五题间无显著差异

进一步 Dunn 事后检验 (Bonferroni 校正) 定位差异来源:

信度: C 题显著低于 D 题 ($p_{\text{adj}} < 0.001$)、B 题 ($p_{\text{adj}} < 0.001$) 和 E 题 ($p_{\text{adj}} < 0.001$); D 题显著高于 A 题 ($p_{\text{adj}} < 0.001$)。C 题评委之间的互评分歧最大——你给高分我打低分的现象在五题中最严重; 而 D 题评委的互评一致性最高。有趣的是, C 题信度垫底但效度并不低 (0.568 vs A 题 0.570), 说明 C 题评委虽然给分口径不一, 但各自独立给出的论文排序与最终获奖结果仍吻合——“给分习惯不同, 但看论文的眼光没有大问题”。对赛方而言, C 题需要更明确的评分标准来缩小评委间的打分分歧。

效度: D 题显著高于 C 题 ($p_{\text{adj}} < 0.001$) 和 A 题 ($p_{\text{adj}} < 0.001$); C 题显著低于 E 题 ($p_{\text{adj}} < 0.001$)。D 题评委预测论文奖项的能力在五题中最强, 这可能得益于 D 题论文质量差异最大 (区分力 15.6 为各题最高)——论文差距越大, 评委越容易看准。

区分力: 仅 C-D 一对显著 ($p_{\text{adj}} = 0.002$), D 题评委的评分方差显著大于 C 题。C 题评委整体最为保守, 不乐意拉开分差——如果赛方发现 C 题分数分布过于集中, 可考虑在评审指导中鼓励评委更大胆地使用全分数段。

公平性: 五题无显著差异 ($p = 0.59$)。无论题目和学科领域如何, 评委在控制系统性偏高或偏低方面表现出一致性——这是整套评审体系中最稳定的维度。




图 8: 四维度分题对比箱线图

子维度上的显著差异在 TOPSIS 综合得分中被加权抵消, 导致综合得分不显著。这并非单一因素, 而是三层叠加效应: 第一层 (最主要)——TOPSIS 的正/负理想解是每题内独立计算的, S_i 本质是题内相对排序, 跨题可比性天然被削弱, KW 检验跨题比较

S_i 时这一层已吸收了大部分组间差异；第二层——子维度交叉补偿，没有任何一道题在所有维度上都垫底或领先（如 C 题三维度最低但效度 0.568 与 A 题 0.570 接近，D 题三维度最高但 TOPSIS 排名被 E 题超越）；第三层（次要贡献）——公平性维度跨题稳定（ $p = 0.59$ ），其权重均值约 0.19，贡献零跨题方差。值得一提的是，公平性是唯跨题无差异的维度（ $p = 0.59$ ），说明无论在哪个题目组，评委在控制系统性偏高或偏低方面的表现具有普适性——这是整套评审体系中最稳定的品质。

8.2.2 管理含义

基于以上发现：(1) C 题可加强评分标准统一以提升信度，并鼓励评委更充分使用分数段以提升区分力；(2) D 题评委数量最多（69 人）但需关注比例也最高（7 人），提示规模扩大后质量管控难度增加，可考虑分组评审或引入校准机制；(3) 公平性的跨题稳定性暗示该维度受题目特性影响最小，可作为评委跨题调度的参考依据；(4) 对低信号题目（Pearson $r < 0.4$ ，如 C 题 $r = 0.319$ ）中同时满足区分力处于该题前 20% 且 fairness_raw 处于该题后 30% 的评委，建议进行人工复核——此条件性双判据在 C 题恰好命中极端偏离者 C01，同时不会误伤其他高分差但公平性合理的评委（如 C19、C10）。

8.3 局限性说明

由于评委完全不跨题，题目效应与评委池效应无法分离：C 题信度低可能是题目评审难度大，也可能是 C 题评委池本身一致性差。以下报告各维度差异均为描述性发现，不做因果归因。

9 子问题 5: 网评成绩利用策略

9.1 权重敏感性分析

当前评分机制中网评权重 $\alpha = 1/4$ 。引入可变权重，构造组合评分与奖项的 Spearman ρ 为目标函数：

$$S_{\text{final}}(\alpha) = \alpha \cdot \bar{z}_{\text{web}} + (1 - \alpha) \cdot \bar{z}_{\text{central}} \quad (17)$$

由于集中评审评分不可见，本文采用秩混合近似：以入围论文的奖项排名作为集中评审的理想排名代理，以网评标准分排名与理想排名的加权组合作为模拟最终排名。需注意此简化假设：当 $\alpha = 0$ 时模拟排名退化为奖项排名，当 $\alpha = 1$ 时退化为网评排名。

表 7: 不同网评权重下的 Spearman ρ

α	0.00	0.10	0.20	0.25	0.30	0.40	0.50
ρ	1.000	0.884	0.884	0.883	0.883	0.876	0.845




图 9: 网评权重敏感性曲线（注：正文图为修正后分题加权平均 曲线，含平坦平台高亮与 $\alpha=0$ 基准标注。）

$\alpha = 0$ 时各题 Spearman ρ 均为 1.000（奖项排名由集中评审直接决定）。网评信号一混入， ρ 即降至 0.883–0.884（ $\alpha = 0.10$ –0.25），降幅约 0.12。但在 $\alpha = 0.10$ 至 $\alpha = 0.30$ 区间内 ρ 呈平坦平台——意味着在此范围内排名稳定性对权重选择不敏感，这支持了当前 $\alpha = 0.25$ 的合理性。 $\alpha > 0.30$ 后 ρ 缓慢下降（ $\alpha = 0.50$ 时 $\rho = 0.845$ ），过度依赖网评会损害排名精度。用素质加权后的网评排名重跑 α 扫描， ρ – α 曲线与等权版本几乎重合（最大偏差仅 0.003， $\alpha = 0.50$ ），加权不影响最优 α 的选择。各题逐题 α 扫描曲线见附录 D。

9.2 评委素质加权方案

基于 Q3 的 TOPSIS 得分，为每篇论文的 4 位网评评委赋予可信度权重：

$$w_j = \frac{S_j}{\sum_{k=1}^4 S_k}, \quad \bar{z}_{\text{web}}^{\text{weighted}} = \sum_{j=1}^4 w_j \cdot z_j \quad (18)$$

其中 S_j 为评委 j 的 TOPSIS 综合素质得分。素质高的评委评分权重重大，素质低的评委评分权重小。




图 10: 等权均值 vs 素质加权：网评与奖项 Spearman ρ 对比

素质加权在所有五题中均正向提升 ρ :

- A 题: 等权 0.513 $\rightarrow$ 加权 0.519 (+0.006)
- B 题: 等权 0.511 $\rightarrow$ 加权 0.518 (+0.007)
- C 题: 等权 0.303 $\rightarrow$ 加权 0.320 (+0.017)
- D 题: 等权 0.661 $\rightarrow$ 加权 0.673 (+0.012)
- E 题: 等权 0.574 $\rightarrow$ 加权 0.603 (+0.028)

注: 此处 ρ 仅基于获奖论文 ($n = 2074$) 计算, 检验的是“网评能否在入围论文内部区分奖项等级”, 与 Q1 全样本 ρ 不可直接比较。入围论文已经过前 55% 筛选, 论文质量方差缩小, 相关性自然比全样本低——这恰恰证明了网评初筛的有效性: 筛掉的那些确实是明显更差的论文。

C 题等权 ρ 仅为 0.303, 是五题中唯一相关性极弱的情况。但换一个角度看: 网评在 C 题已完成“筛出前 55%”的核心任务 (Q1 命中率 73.9%), 剩下的“在好论文内部评谁更好”本就是集中评审的职责。C 题 $\rho = 0.303$ 不是网评失败, 而是网评使命完成后自然出现的边界效应。

E 题提升最大 (+0.028)。这与各题评委素质的离散程度直接相关: E 题评委 TOPSIS 得分方差为五题最大 (0.030), 说明 E 题评委水平参差不齐最严重; 而素质加权放大好评委、压制差评委, 在不均匀的群体中效果自然最显著。反之, A 题方差最小 (0.017), 加权收益也最小 (+0.006)——如果评委经过严格选拔、水平整齐, 素质加权的边际价值就很有限。进一步验证了评委级全局折扣 (对低素质评委评分整体打折后再做论文内加权), 额外增益仅千分之五级别, 不改变结论——素质加权在论文层面已充分利用了评委素质信息。

值得注意的是, 加权收益小 (全题 $\Delta\rho$ 最大仅 +0.028, 排名准确度提升不到 3%) 并非建模失败, 而是制度本身具有容错能力的信号。用合唱团的比喻: $\Delta\rho$ 大意味着有人严重跑调, 关了他的麦立刻好听很多 (说明选人有问题); $\Delta\rho$ 小意味着最差的也只是偶尔轻微走音, 关不关听众几乎听不出区别 (说明整体水平在线)。网评制度不要求所有评委都是高素质评委——93.4% 的评委表现可接受, 仅 6.6% 需关注, 少数低素质者的噪音被多数人平均掉之后, 整体排名依然能得到客观合理的结果。加权效果不大恰恰印证了网评机制的健壮性。

为保证加权不损害网评的初筛功能, 进一步检验了加权对命中率和假阴性率的影响。全题命中率从 74.79% 降至 74.52% (-0.27pp), 假阴性率从 3.33% 升至 3.66% (+0.33pp), 变化均在 1 个百分点以内。素质加权在提升入围内排序精度的同时, 未显著牺牲初筛有效性。A 题和 C 题命中率降幅略大 (约 2pp), 提示加权在小评委池或低信度题目上应谨慎使用。

9.3 改进建议

1. 保留当前网评权重。敏感性分析表明 $\alpha = 0.25$ 处于合理区间，调整收益微小。
2. 对低素质评委降权。将 Q3 分层中“需关注”和“待改进”的 13 位评委（占总数的 6.6%）的网评评分按 TOPSIS 得分降低权重，减少噪声干扰。
3. 引入素质动态更新机制。每轮比赛后基于新数据更新评委 TOPSIS 得分和权重，实现评委素质的持续监控与动态调整。

9.4 利弊总结

利：(1) 网评为总成绩提供独立于集中评审的第二信号源，降低单一评审池的系统性偏差风险。(2) 网评承担初筛功能（前 55% 命中率 74.8%，假阴性率仅 3.3%），使集中评审可专注于入围论文的精细排序。(3) 权重敏感性分析表明，在 $\alpha \in [0.10, 0.30]$ 区间内 ρ 呈平坦平台（ ≈ 0.883 ），说明在此宽广区间内排名对权重选择不敏感—— $\alpha = 0.25$ 处于平台中心，具有充分的稳健性。网评信号一混入即造成约 0.12 的 ρ 下降（从 1.000 至 0.884），但这是任何独立信号源引入后的自然代价，并非网评独有的缺陷。

弊：(1) 网评信号引入后 ρ 从 1.000 降至约 0.884，降幅约 0.12——集中评审自身对奖项排名拥有绝对一致性，任何外部信号都难以完全复现。 $\alpha > 0.30$ 后 ρ 缓慢下降（ $\alpha = 0.50$ 时 $\rho = 0.845$ ），过度依赖网评会损害排名精度。(2) 6.6% 的低素质评委在等权方案中将噪声混入总成绩；论文内加权可缓解，增益为 $\Delta\rho$ 0.006–0.028。(3) C 题网评入围后区分力极弱（ $\rho = 0.303$ ），该题网评信号对入围后排序几乎无贡献； α 扫描中 C 题 ρ 从 0.40 起衰减显著快于其他题（ $\alpha = 0.50$ 时仅 0.777）。

综上，在保持当前 $\alpha = 0.25$ 的条件下，论文内素质加权可将入围论文内部的排名相关性从 0.883 提升至 0.883–0.911（视题目而定），且不显著损害初筛命中率和假阴性率。网评的核心价值在于初筛而非入围后精密排序——认识到这一功能边界，本身就是“更有效利用”的前提。

10 模型评价与讨论

10.1 优势

1. **定义先行，操作化透明。**在建模前将“评委基本素质”操作化为四维度指标体系，并验证了维度间的统计独立性。
2. **客观赋权，数据驱动。**熵权法避免了主观赋权的争议，进一步测试了 CRITIC、CV、标准差、PCA、灰色关联度共 5 种客观赋权法，全题排名与熵权的 Spearman ρ 最低 0.867（PCA）、最高 0.990（CV），聚类分层结构完全不变——结论高度稳健。

3. **模型对低素质评委具有识别力。**TOPSIS 综合得分结合 K-means++ 聚类将评委分为三至四档, Silhouette 系数在 0.244–0.391 之间, 聚类结构可接受; 各题 TOPSIS 得分标准差在 0.132–0.172 之间, 模型对评委素质差异具有系统区分力。
4. **严谨的效应量报告。**所有假设检验均报告效应量 (Spearman ρ 、KW η^2), 避免了大样本 p 值失效的问题。

10.2 局限性

1. **最终奖项代理偏差。**以最终奖项作为论文真实水平的代理, 但集中评审评分不可见。如果集中评审本身存在评分噪声, 奖项代理偏差的方向可能是让网评显得比实际更弱 (因为代理噪声被归因到了网评头上)——代理偏差在本文中偏向保守估计, 不太可能导致过度乐观的结论。
2. **评委跨题效应不可分离。**题目效应与评委池效应无法区分, Q4 的探索性分析不能做因果推断。但这一限制不影响 Q5 的建议——素质加权是题内操作, 即使在最保守的假设下 (差异全部来自题目特性), 加权方案本身仍然合理。
3. **ICC 对小样本评委不稳定。**A 题仅 14 位评委, 成对 ICC(2,1) 均值在小样本下对评分者数量敏感, 可能低估评分者数为 4 时的信度。本文报告的是题内成对 ICC 均值, 在样本量极小的题目 (如 A 题) 上应视为谨慎估计。
4. **秩混合近似的局限。**Q5 敏感性分析中, 因集中评审评分不可见而采用秩混合近似。若真实集中评审排名与奖项排名存在偏差, ρ 对 α 的实际敏感度可能略高于本文估计——这意味着“ α 平坦平台”的结论若在更精确数据下可能收窄, 但 $\alpha = 0.25$ 处于平台中心的位置使其仍有充分的安全边际。
5. **效度总量的信息损失。**将淘汰论文映射为奖项 = 0, 可能损失论文真实质量的细粒度信息。但值得注意的是, C 题假阴性率 (1.98%) 为五题最低, 设 0 对 C 题效度的压低影响最小——这恰好强化了 Q1 对 C 题的判断 (低效度来自入围内区分力弱, 而非初筛失败)。
6. **公平性维度的方向信息损失。**为纳入 TOPSIS (要求各维度方向一致), 公平性以 $|z_{\text{bias}}|$ 量化, 抹去了偏严与偏松的方向区别。数据验证显示, 偏松评委推入入围线但未获奖的论文 (371 篇) 约为偏严评委冤杀论文 (33 篇) 的 11 倍——偏严产生不可逆的冤案 (量小代价高), 偏松造成集中评审资源浪费 (量大代价低)。若未来在管理制度层面区分两种偏离, 可将公平性拆解为方向敏感的子指标, 为针对性培训或评审调度提供依据。

10.3 可推广性

本文的四维度指标体系具有跨场景的迁移潜力：信度（ICC 框架）是通用骨架，适用于任何多评委评分场景；效度依赖于外部质量基准，不同场景下需替换代理指标；公平性的定义（偏离群体均值）在匿名评审中自然成立，但在非匿名或评委跨场景调度时需要重新考量；区分力（评分标准差）是最通用的维度，但阈值需按场景校准。熵权+TOPSIS 的综合评价框架尤其适合评价维度间缺乏先验权重的场景。

10.4 讨论

综合各子问题的稳健性检验，本文的以下结论不依赖特定模型假设：(1) 网评与终评的整体相关性为强效 ($\rho \approx 0.8$)，无论使用 Spearman、Pearson 还是 ROC 框架均得出一致判断；(2) 四维度指标体系无严重冗余（最大 $r = 0.558$ ），TOPSIS 综合排名对 6 种赋权法不敏感 ($\rho > 0.867$)；(3) 公平性是唯—跨题无显著差异的维度 ($p = 0.59$)，网评在防御系统性评分偏差方面具有普适性。以下结论依赖更强的代理假设，应视为试探性发现：(1) 素质加权的定量增益 ($\Delta\rho$ 0.006–0.028) ——增益大小取决于 TOPSIS 得分是否准确反映了评委真实素质；(2) α 平坦平台的确切宽度——受限于秩混合近似，在真实集中评审数据下平台宽度可能与当前估计略有差异。若未来可获取集中评审评分，优先验证的方向是：素质加权的真实 $\Delta\rho$ 、以及 α 平坦平台在真实混合评分下的稳定性。

11 结论

五条分析线收敛于一个判断：网评制度整体健康，局部可优化，但不宜过度干预。

具体而言：(1) 网评与终评强相关（Spearman $\rho = 0.797$ ），初筛命中率 74.8%、假阴性率仅 3.3%——网评制度总体有效；(2) 从信度、效度、公平性、区分力四维度构建的指标体系，维度间最大交叉 $r = 0.558$ （信度 $\times$ 效度），属于中等正相关而非严重冗余，且恰好支持了多维度综合评价的建模必要性；(3) 熵权法+TOPSIS 客观综合评价 196 位评委，K-means++ 分为三至四档；进一步测试了 CRITIC、CV、标准差、PCA、灰色关联度共 5 种客观赋权法，全题排名与熵权的 Spearman ρ 最低 0.867（PCA）、最高 0.990（CV），聚类分层结构完全不变——TOPSIS 排名对赋权方法不敏感；(4) 五题评委 TOPSIS 综合得分无显著差异（KW $p = 0.076$ ），但信度、效度、区分力等子维度差异极显著 ($p < 0.001$)，公平性跨题一致 ($p = 0.59$) ——C 题信度/效度/区分力三项垫底，提示该题评审标准培训可作为优先干预点；(5) 权重敏感性分析支持当前 $\alpha = 0.25$ ($\alpha \in [0.10, 0.30]$ 为平坦平台)，素质加权可微量提升入围内排序精度 ($\Delta\rho$ 0.006–0.028)，但增益有限本身说明制度容错性良好。

本文的主要限制在于集中评审评分不可见，以最终奖项作为论文质量的代理；若未来可获取集中评审分数，网评与集中评审的直接校准将进一步提升利用策略的精度。

参考文献

- [1] Koo, T.K. & Li, M.Y. (2016). A Guideline of Selecting and Reporting Intraclass Correlation Coefficients for Reliability Research. *Journal of Chiropractic Medicine*, 15(2):155–163.
- [2] Stemler, S.E. (2004). A comparison of consensus, consistency, and measurement approaches to estimating interrater reliability. *Practical Assessment, Research, and Evaluation*, 9(4).
- [3] Bajpai, S., Bajpai, R. & Chaturvedi, H.K. (2015). Evaluation of Inter-Rater Agreement and Inter-Rater Reliability for Observational Data. *Journal of the Indian Academy of Applied Psychology*, 41(3):20–27.
- [4] Sollerman, S. (2025). How Raters Differ: A Study of Structured Oral Mathematics Assessment. *Practical Assessment, Research, and Evaluation*, 31(1).
- [5] Goertzen, B.J. & Klaus, K. (2020). Is it actually reliable? Examining Statistical Methods for Inter-rater Reliability of a Rubric in Graduate Education. *Research & Practice in Assessment*, 18(2).
- [6] Hwang, C.L. & Yoon, K. (1981). *Multiple Attribute Decision Making: Methods and Applications*. Springer-Verlag.
- [7] Shannon, C.E. (1948). A Mathematical Theory of Communication. *Bell System Technical Journal*, 27(3):379–423.
- [8] Arthur, D. & Vassilvitskii, S. (2007). k-means++: The Advantages of Careful Seeding. *Proceedings of SODA 2007*.
- [9] Kruskal, W.H. & Wallis, W.A. (1952). Use of Ranks in One-Criterion Variance Analysis. *Journal of the American Statistical Association*, 47(260):583–621.
- [10] Dunn, O.J. (1964). Multiple Comparisons Using Rank Sums. *Technometrics*, 6(3):241–252.

A 附录

A.1 附录 A: Q1 辅助图表




图 11: 网评筛选有效性 (前 55% 命中率 + 假阴性率)




图 12: 网评标准分 vs 奖项散点图矩阵

A.2 附录 B: Q3 辅助图表




图 13: 各分层评委四维雷达图 (C 题优秀层因区分力与公平性存在内在权衡, 优秀评委评分偏离全题均值较大, 公平性维度数值偏低, 详见正文子问题 3)




图 14: 肘部法则 +Silhouette 系数




图 15: 各题 TOPSIS 得分 TOP8 评委棒棒糖图




图 16: PCA 碎石图: 四个主成分方差贡献率相近, 不存在单一主成分主导方差的情况, 说明四维度彼此独立, 无严重信息重叠





图 17: t-SNE 评委聚类可视化: 各题评委在二维嵌入空间中呈现明显分簇结构, 验证了 K-means++ 聚类的几何合理性

A.3 附录 C: Q4 辅助图表

图 18: Dunn 事后检验 p_{adj} 矩阵 (Bonferroni 校正)

A.4 附录 D: Q5 辅助图表




图 19: 建议降权评委按题目汇总




图 20: 各题逐题 α 扫描曲线: A-E 五题网评权重敏感性分题对比, C 题 (红线) $\alpha > 0.30$ 后 ρ 衰减显著快于其他题

A.5 附录 E: 支撑材料文件清单

- outputs/scratch/c0_data_clean.py
- outputs/scratch/c0_data_explore.py
- outputs/scratch/c2_q1q4_model.py
- outputs/scratch/c2_q2q3_model.py
- outputs/scratch/c2_q5_model.py
- outputs/scratch/c3_generate_charts.py
- outputs/scratch/gen_q5_alpha_charts.py
- outputs/scratch/c1_verify_q2.py
- outputs/scratch/c1_verify_q3.py
- outputs/scratch/c2_validate_numbers.py
- outputs/scratch/c2_q3_weighting_explore.py
- outputs/scratch/c2_q3_cv_method.py
- outputs/scratch/c2_q3_weighting_q3_effect.py
- outputs/scratch/check_alpha0.py
- outputs/scratch/analyze_doubt5.py
- outputs/data/combined-clean.pkl
- outputs/data/judge-profile.pkl

- outputs/data/q3-judge-scores.pkl
- solution/artifacts/charts/q1-rho-bars.pdf
- solution/artifacts/charts/q1-roc-curves.pdf
- solution/artifacts/charts/q1-hit-rate.pdf
- solution/artifacts/charts/q1-scatter-matrix.pdf
- solution/artifacts/charts/q2-indicator-architecture.pdf
- solution/artifacts/charts/q3-entropy-weights.pdf
- solution/artifacts/charts/q3-topsis-hist.pdf
- solution/artifacts/charts/q3-radar.pdf
- solution/artifacts/charts/q3-elbow-silhouette.pdf
- solution/artifacts/charts/q3-cluster-scatter.pdf
- solution/artifacts/charts/q3-ranking-lollipop.pdf
- solution/artifacts/charts/q4-topsis-box.pdf
- solution/artifacts/charts/q4-dunn-matrix.pdf
- solution/artifacts/charts/q4-dimensions-box.pdf
- solution/artifacts/charts/q5-weight-sensitivity.pdf
- solution/artifacts/charts/q5-weighted-comparison.pdf
- solution/artifacts/charts/q5-demotion-suggestion.pdf
- solution/artifacts/charts/q5-alpha-by-topic.pdf
- solution/artifacts/charts/pca-scree.pdf
- solution/artifacts/charts/cluster-tsne.pdf
- solution/explore-results/weighting/
- solution/explore-results/cv-method/