

2026 校赛 C 题初始分析报告

阶段 0.1 产出

2026-07-28

1 问题重述

某竞赛采用双阶段评审机制。网评阶段每篇论文由 4 位评委以百分制评分，通过标准分（z-score）归一化后按总分排名，前 55% 进入集中评审。集中评审阶段每篇论文由 3 位评委独立评分（同样百分制），换算为标准分后，与网评平均标准分取均值作为最终成绩。

本题要求基于 A-E 五个题目的评审数据，完成五项建模任务：(1) 网评与终评相关性分析；(2) 评委基本素质指标体系；(3) 评委素质数学模型；(4) 不同题目评委表现差异分析；(5) 网评成绩利用策略优化。

2 子问题拆解

2.1 子问题 1：网评与终评相关性分析

目标：量化网评成绩与最终成绩的相关性，评价网评结果的有效性。

方法思路：

- 对每篇论文计算其网评 4 位评委的标准分均值，作为“网评成绩”
- 以最终奖项（一等奖/二等奖/三等奖/未入围）作为“最终成绩”
- 使用 Spearman 秩相关系数（奖项为等级数据）度量相关性
- 辅助分析：网评前 55% 筛选的命中率（是否正确筛选出入围论文）
- 辅助分析：ROC 曲线评估网评对一等奖/二等奖的区分能力

2.2 子问题 2：评委基本素质指标体系

目标：构建多维度评委素质评价框架。

拟构建维度：

1. **评分一致性（Reliability）：**该评委与其他评委对同一批论文的评分趋向是否一致，用成对 ICC 或平均绝对偏差度量
2. **区分度（Discrimination）：**该评委的评分能否有效区分不同质量水平的论文，用评分方差、与最终成绩的相关性度量
3. **准确性（Accuracy）：**该评委的评分与“真实水平”（以最终成绩为代理）的吻合程度

4. **偏差控制 (Bias Control)**: 该评委是否存在系统性偏高或偏低的倾向, 用评分均值偏离全体均值的程度度量
5. **稳定性 (Stability)**: 同一评委在不同论文上的评分模式是否一致, 用评分分布的统计特征度量

2.3 子问题 3: 评委素质数学模型

目标: 基于 Q2 的指标体系, 建立综合评价模型并应用于附件数据。

方法思路:

- 各维度指标归一化 (min-max 或 z-score)
- 权重确定: 熵权法 (客观) 或 AHP (综合主客观)
- 综合评分: 加权线性组合或 TOPSIS
- 对每位评委输出综合素质评分和排名

2.4 子问题 4: 不同题目评委表现差异分析

目标: 检验 A/B/C/D/E 五题评委整体素质是否存在显著差异, 分析原因。

方法思路:

- 以 Q3 输出的评委素质评分为因变量, 题目类别为自变量
- 正态性检验后选择 ANOVA 或 Kruskal-Wallis 检验
- 若有显著差异, 事后检验 (Tukey HSD 或 Dunn 检验) 定位差异来源
- 差异原因假设: 不同题目论文质量分布不同? 不同题目评委遴选标准不同?

2.5 子问题 5: 网评成绩利用策略

目标: 分析网评成绩加入总成绩的利弊, 提出改进建议。

方法思路:

- 利弊分析: 利——增加样本量、降低单个评委偶然误差的影响; 弊——网评阶段若评委素质参差可能引入噪声
- 模拟分析: 假设不同的网评权重 (当前为 1/4), 比较排序稳定性
- 提出改进方案: 基于评委素质的动态权重调整、异常评委评分识别与降权等

3 相关知识

3.1 标准分 (z-score)

标准分公式 $z_i = (x_i - \bar{x})/\sigma$ 是统计学中的标准化变换, 消除评委打分尺度差异。性质: 均值为 0, 标准差为 1, 保留原始分布形态。

3.2 评分者信度

- **ICC (组内相关系数)**: 适用于连续评分的多评委一致性度量, ICC(2,k) 适合本场景 (评委和论文均为随机效应)
- **Kendall's W**: 多评委排序一致性, 取值范围 [0,1]
- **Pearson vs ICC**: 高 Pearson 相关不等于高分值一致 (如评委 A 给 [1, 2, 3], B 给 [11, 12, 13], Pearson=1 但 ICC 很低)

3.3 评委偏差类型

- 严厉度偏差: 某评委系统性偏低
- 宽容度偏差: 某评委系统性偏高
- 中心化趋势: 回避极端分数
- 光环效应: 对某些论文的非理性偏爱

4 初始建模假设

1. 最终奖项 (一等/二等/三等) 真实反映了论文的相对质量水平
2. 网评 4 位评委之间独立评分, 无串通
3. 同一题目内的论文来自同一学科领域, 评分标准可比
4. 集中评审的评委整体素质较高 (集中评审是精选环节)
5. 标准分公式能有效消除不同评委的尺度差异

5 待解决的开放问题

1. 数据中只有网评原始分和最终奖项, 集中评审阶段的评委评分未知——如何准确评估网评的实际贡献?
2. 评委是否跨题目出现? 若有跨题评委, 是将其表现合并还是分题评估?
3. "前 55% 进入集中评审" 与数据中约 42% 的实际比例不符——是否存在额外的淘汰机制或数据不完整?
4. 将奖项等级 (一等/二等/三等/未入围) 作为论文质量的代理变量是否合理? 不同题目的奖项分布不同 (如 B 题一等 28 篇, D 题一等 34 篇), 可否跨题比较?
5. 标准分公式在同一评委评阅论文数较少时不稳定——实际数据中各评委评阅了多少篇论文?