

2026 校赛 C 题综合内部报告

阶段 2.3

2026-07-28

1 问题重述

某竞赛采用双阶段评审。网评阶段每篇论文由 4 位评委百分制评分，标准分归一化后按总分排名，前 55% 进入集中评审。集中评审由 3 位评委独立评分，标准分与网评平均标准分求均值得最终成绩。附属数据包含 A-E 五个题目的评审结果。

2 子问题 1：网评与终评相关性分析

2.1 方法

对每篇论文，将 4 位评委的原始分按评委分别计算 $z_{j,i} = (x_{j,i} - \bar{x}_j) / \sigma_j$ 后取均值作为网评标准分。以最终奖项（一等 =3、二等 =2、三等 =1、淘汰 =0）为标签，计算 Spearman 秩相关系数。对入围论文（ $n = 2074$ ）追加 Pearson 线性相关（经正态性检验）。

大样本（ $n = 4876$ ）下 p 值必然显著，按 PF-005 规范以效应量 $|\rho|$ 为主要解读依据： < 0.1 可忽略、0.1–0.3 弱、0.3–0.5 中、 > 0.5 强。

2.2 结果

表 1: 网评标准分与最终奖项的相关性

题目	Spearman ρ	Pearson r (入围)	ROC AUC (一等)
A	0.670	0.404	0.895
B	0.730	0.413	0.909
C	0.625	0.160	0.785
D	0.780	0.583	0.963
E	0.742	0.497	0.896
全题	0.737	0.457	0.893

网评筛选命中率 71.3%（前 55% 论文中获奖比例），假阴性率仅 7.8%。ROC AUC 均 > 0.78 ，对一等奖有卓越区分力。

2.3 结论

网评结果与最终成绩存在强秩相关（ $\rho = 0.737$ ），能有效完成初筛任务。C 题相关性最低（ $\rho = 0.625$ ），与 Q3 中 C 题评委效度（ $\rho = 0.14$ ）最低地发现一致。

3 子问题 2: 评委基本素质指标体系

3.1 四维度框架

从利益相关者视角构建四维度指标体系:

维度一: 信度 (Reliability) —— 评分能否被其他评委复现。以成对 Spearman 相关系数均值量化:

$$R_j^{\text{rel}} = \frac{1}{K-1} \sum_{k \neq j} \rho_{jk} \quad (1)$$

维度二: 效度 (Validity) —— 评分能否识别论文真实质量。以评分与最终奖项的 Spearman ρ 量化, 严格遵循 PF-005 效应量报告规范。

维度三: 公平性 (Fairness) —— 是否存在系统性偏高/偏低。以评分均值偏离全体均值的标准化 z 值的绝对值量化。

维度四: 区分力 (Discrimination) —— 能否有效拉开论文差距。以评分标准差 σ_j 和变异系数 CV 量化。

3.2 统计独立性

维间最大 Spearman $r = 0.32$ (效度 $\times$ 区分力), 无严重冗余。公平性与所有维度 $r < 0.12$, 完全独立。

4 子问题 3: 评委素质数学模型

4.1 熵权法 + TOPSIS

对四维度归一化后, 熵权法确定权重:

$$e_j = -\frac{1}{\ln K} \sum P_{ij} \ln P_{ij}, \quad w_j = \frac{1 - e_j}{\sum (1 - e_j)} \quad (2)$$

TOPSIS 综合评价:

$$S_i = \frac{D_i^-}{D_i^+ + D_i^-} \in [0, 1] \quad (3)$$

以等权 TOPSIS 作稳健性检验: 熵权 vs 等权 Spearman $r = 0.857\text{--}0.964$, 方法稳健。

4.2 权重分布

表 2: 五题熵权分布

题目	信度	效度	公平性	区分力
A	0.156	0.235	0.235	0.374
B	0.224	0.248	0.135	0.393
C	0.177	0.136	0.261	0.426
D	0.246	0.173	0.167	0.413
E	0.152	0.314	0.184	0.351

区分力权重始终最高（均值 0.391），因评委间标准差变异最大。效度在 E 题权重偏高（0.314）、C 题偏低（0.136），反映不同题目中效度维度区分度的结构差异。

4.3 K-means++ 分层

表 3: 各题评委分层结果			
题目	K	Silhouette	分层结构
A	4	0.399	优秀 2/良好 4/合格 5/需关注 3
B	4	0.257	优秀 23/良好 19/合格 5/需关注 8
C	2	0.333	优秀 14/良好 6
D	5	0.267	优秀 22/良好 19/合格 8/需关注 15/待改进 5
E	2	0.318	优秀 18/良好 20

4.4 异常评委验证

阶段 0.4 异常画像标记的 27 位评委在 TOPSIS 排名中得到验证：C11/C12/C13（宽松 + 低离散）在 C 题并列倒数，E28（高分 + 极低离散）E 题垫底，证明了异常检测与 TOPSIS 的交叉有效性。

5子问题 4：不同题目评委表现差异分析

5.1 Kruskal-Wallis 检验

$$H = 12.984, p = 0.0114, \eta^2 = 0.047$$

(4)

整体差异显著但效应量小（ $\eta^2 < 0.06$ ）。Dunn 事后检验（Bonferroni 校正）仅 B-E 差异显著（ $p_{\text{adj}} = 0.011$ ）。

5.2 分维度检验

信度（ $p < 0.001$ ）和效度（ $p < 0.001$ ）五题间差异极显著；但公平性维度五题无显著差异（ $p = 0.59$ ）——评委在偏差控制上具有跨题目一致性。

5.3 结论与局限

统计上可拒绝”五题同分布”的零假设，但评委完全不跨题的设计导致题目效应与评委池效应无法分离。本文将此分析定性为探索性发现，不做因果推断。

6子问题 5：网评成绩利用策略

6.1 权重敏感性

模拟不同网评权重 α 下，组合排名与奖项的 Spearman ρ :

α	0.00	0.10	0.20	0.25	0.30	0.40	0.50
ρ	0.660	0.665	0.658	0.651	0.642	0.619	0.587

当前 $\alpha = 0.25$ 的权重处于合理区间。 $\alpha = 0.10$ 时 ρ 略高，但差异微小 ($\Delta = 0.014$)。

6.2 评委素质加权

以评委 TOPSIS 得分为可信度权重，替代等权均值：

$$\bar{z}_{\text{web}}^{\text{weighted}} = \sum_{j=1}^4 \frac{S_j}{\sum S_k} \cdot z_j \quad (5)$$

素质加权在所有五题中均正向提升 ρ (A:+0.010, B:+0.027, C:+0.063, D:+0.019, E:+0.028)。C 题提升最大 (+0.063)，验证了素质差异越大则加权收益越大的逻辑。

6.3 改进建议

1. 保留当前 1/4 网评权重，不增不减
2. 对 31 位“需关注/待改进”评委的网评评分做降权处理（总评委数 196 的 15.8%）
3. 引入评委素质动态更新机制：每轮赛后根据 Q3 模型更新评委权重

7 综合结论

1. 网评制度总体有效：Spearman $\rho = 0.74$ ，命中率 71%，假阴性率 7.8%
2. 评委素质可用四维度（信度/效度/公平性/区分力）全面度量，维度间统计独立
3. 熵权 + TOPSIS 可客观排序评委，且与等权一致性 > 0.86 ，方法稳健
4. 五题评委表现存在微小差异 ($\eta^2 = 0.047$)，但公平性维度跨题一致
5. 当前网评权重合理，引入素质加权可小幅提升评审精度（C 题收益最大）

8 未闭合问题

1. 集中评审评委评分不可见——网评对终评评分的直接影响无法量化
2. 前 55% 规则与实际 42% 入围比例不符——机制差异来源不明
3. C 题效度仅 0.14——需要从评审组织层面回答“为什么”
4. 评委素质评价仅基于网评数据，不能替代集中评审阶段评委的评价