

统一数据预处理（共用前置管线）
近全零过滤 → CLR 变换 → 标准化（仅训练集估计）

问题一 · 疾病预测

① 构建分类模型
CLR 变换 + L2 逻辑回归（主）
随机森林（对照）

② 诚实评估
分层 5 折交叉验证 + LOOCV
AUC 主指标 + 少数类指标

③ 稳健性检验
小腺瘤（small adenoma）归类方案敏感性
过拟合判定（CV vs LOOCV）

④ 阈值与可解释
Youden 阈值选择
L2 系数 → 微生物方向信号

⑤ 结论
三数据集均达可预测水平
性能差异归因于信号强度/类别平衡

问题二 · 生物标志物

① 稀疏筛选
Lasso 回归初步筛选候选特征

② 稳定性选择
Bootstrap 重抽样 + 入选频率阈值

③ 两路信号验证
Fisher（存在/缺失）+ Wilcoxon（丰度）

④ 多重校正与佐证
BH-FDR 校正 + RF 重要性/VIP 交叉佐证

⑤ 结论：稳定标志物确定
与文献已知标志物比对验证
跨疾病重叠（Jaccard）检查

问题三 · 跨疾病预测

① 评估框架
LODO 留一疾病（测试疾病不可见）

② 策略对比
直接迁移 / 共享标志物 / 聚合 / 输出概率修正

③ 后续模型探索
树模型 → 样本合并 → 密度加权 → 对抗域适应

④ 归因分析
衰减三分法 + 共享方向 + 阈值漂移

⑤ 结论：统一模型不可交付
完整验证过程（六轮实验）
表明瓶颈在数据

总结论：域内疾病可预测、标志物获文献验证；
跨疾病统一模型不可交付——完整验证过程表明瓶颈为数据固有限制