

第二次模拟赛 B 题 S1 子问题：疾病预测模型（内部报告内容段）

报告对话

2026-08-21

表 1: S1 模型符号说明（自足性符号表：正文首次出现处均有内嵌定义）

符号	定义	首次出现
n	某数据集的样本总数（Zeller 121、metahit 110、Chatelier 253）	§2.1
p	物种级特征列数（原始 1331，近全零过滤后 264）	§2.1
x_{ij}	样本 i 第 j 物种相对丰度， $i = 1, \dots, n$, $j = 1, \dots, p$	§2.1
δ	零值乘法替换伪值（检出限 0.65 倍， $\delta = 6.5 \times 10^{-6}$ ）	§2.2
g_i	样本 i 的几何均值	§2.2
$\text{clr}(x_{ij})$	中心化对数比变换值	§2.2
$\mathbf{w}$	Logistic 回归系数向量（长度 p ）	§3.1
b	Logistic 回归偏置项	§3.1
z_i	线性得分 $z_i = \mathbf{w}^\top \text{clr}(\mathbf{x}_i) + b$	§3.1
$\sigma(z)$	sigmoid 函数 $\sigma(z) = 1/(1 + e^{-z})$	§3.1
y_i	样本 i 真实标签（患病 =1 / 健康 =0）	§3.1
λ	L2 正则强度	§3.1
C	正则强度倒数 $C = 1/\lambda$ （取 $C = 1.0$ ）	§3.1
w_c	类别 c 的样本权重（class_weight）	§3.1
K	分层交叉验证折数 $K = 5$	§3.4
跨问/实验代号	指代	首次出现
S2 过滤口径	S2 特征选择子问题的近全零过滤口径（三病并集 264 特征）	§2.2
B2 集成	阶段 1.2 方案辩论 B 类分歧 2（两法 AUC 均 ≥ 0.75 时做 Soft Voting）	§3.5
small_adenoma 四口径	阶段 1.3 人类裁定（Zeller 腺瘤四口径敏感性分析）	§4.2

1 本问要解决什么

本节约一句话：S1 为三个宏基因组数据集各建一个「患病 vs 健康」二分类判别模型并诚实评估其性能，为后续跨疾病分析提供基准。

1.1 任务转述与定位

S1 对应赛题第一问。本问以物种级相对丰度为特征，对三个数据集（结直肠癌、炎症性肠病、肥胖症）各自构造二分类标签（患病 =1 / 健康 =0），训练判别模型，并回答两个问题：（1）各数据集模型预测性能如何；（2）三数据集性能差异从何而来。本问是 S2 特征选择、S3 跨疾病预测的基础：其性能基准与特征口径被后问复用（见 §2.2 过滤口径说明）。

1.2 问题类型与评估口径

按题型决策树判定，S1 为预测类（二分类）问题，命中「分类评估路径」。主指标为 AUC，辅以少数类 F1 与 Recall；ACC 仅作参考。评估口径说明：跨数据集横向比较只比「相对基线的增益」，不比绝对 AUC（批次效应强，见 §5.4）。三数据集样本量分别为 Zeller 121、metahit 110、Chatelier 253，其中 metahit 类别最不平衡（少数类占比 22.7%），详见 §2.1。

表述库映射：1.1-1 问题定位句、1.2-6 识别式定位（“实际上是一个分类问题”）、5.1-48 问题背景引入、5.1-49 问题重述（转述题意）。

2 数据与预处理

本节约一句话：数据为清洗后的三数据集相对丰度，需按统一口径做标签映射、近全零过滤与 CLR 变换，才能进入线性模型。

2.1 数据来源与结构

数据源为共享清洗产出（float32），含数据集名、疾病标签两元数据列与物种级相对丰度特征列。三数据集样本构成如下：Zeller 结直肠癌 $n = 121$ （健康 73、患病 48，少数类为患病，占比 39.7%）；metahit 炎症性肠病 $n = 110$ （健康 85、患病 25，少数类为患病，占比 22.7%）；Chatelier 肥胖症 $n = 253$ （健康 89、患病 164，少数类为健康，占比 35.2%）。metahit 类别最不平衡，其 ACC 会因多数类主导而虚高，故评估以 AUC 与少数类指标为准。**口径声明（禁写句）：**A 类验证（float64 原始数据）仅作参考，正式数字一律以 S1 结果文件（float32）落盘为准，本报告不采用 A 类验证数值。

2.2 标签映射与口径

三数据集标签映射统一为患病 =1 / 健康 =0：结直肠癌 cancer（健康为 n）、炎症性肠病为两种亚型并集、肥胖症 obesity。各数据集少数类比例见 §2.1（Zeller 39.7%、metahit 22.7%、Chatelier 35.2%）。**small_adenoma 四口径（阶段 1.3 人类裁定）：**Zeller 数据集含 26 例 small_adenoma 样本，人类裁定全做四口径敏感性分析——归健康、归病变、剔除、单开一类。四口径结果见 §4.2，默认主口径为口径 (1)（归健康）已落盘，最终主口径从结果择优（性能 + 可解释性）。

2.3 近全零过滤（与 S2 口径统一）

剔除零值占比 > 95% 的特征，从原始 1331 维降至 264 维（剔除 1067 维）。过滤口径与 S2 统一（三病并集同一特征集），保证特征维度在本子问题与后续子问题一致。

2.4 CLR 变换（成分数据前置）

相对丰度为定和成分数据（每行和 ≈ 100 ），进入线性模型前需 CLR 变换解除定和偏相关（H1：成分数据定和偏相关假设，即每行和为定值使特征间产生伪相关）。两步：零值乘法替换 $x_{ij} \leftarrow \max(x_{ij}, \delta)$ （ δ 为检出限 0.65 倍， $\delta = 6.5 \times 10^{-6}$ ） $\rightarrow$ 逐行几何均值中心化 $\text{clr}(x_{ij}) = \ln x_{ij} - \frac{1}{p} \sum_k \ln x_{ik}$ 。CLR 仅主模型 L2 需要，RF 对照用原始丰度。CLR 相对原始丰度的定量增益无实证值（结果文件未落盘该字段），正文不写具体增益。

表述库映射：8.1-58 预处理节总起、8.1-59 数据来源与结构描述、8.2-62 数据剔除/筛选（近全零过滤）、8.3-64 数据变换、8.3-65 变换直观解释、8.2-60 缺失/异常值处理（零值乘法替换）。

3 模型构建

本节约一句话：以 Logistic(L2)+CLR 为主模型、随机森林为对照、单特征最佳阈值 +Dummy 为基线，统一在分层 5 折 CV 下评估，并以 LOOCV 兜底诚实估计。

3.1 主模型：Logistic(L2)+CLR

概率输出分类器，线性得分与 sigmoid 概率（见符号表）。L2 惩罚 $\frac{\lambda}{2}\|\mathbf{w}\|_2^2$ 抗小样本过拟合 ($n \ll p$)。实现 $C = 1.0$ ($\lambda = 1.0$)，并启用 `class_weight='balanced'` 缓解类别不平衡。动机句：小样本高维下线性模型可解释、系数方向可为 S2/S3 铺垫，L2 收缩防过拟合。

3.2 对照模型：随机森林（原始丰度）

RF（500 棵树）直接输入过滤后原始丰度（含高比例零值，免 CLR），作为非线性对照；特征重要性用 permutation importance（复用 S2 口径）。动机句：提供非线性基准，检验线性 CLR 主模型是否因成分数据处理而更优。

3.3 基线（性能下界）

单特征最佳阈值（逐特征扫描阈值取 AUC 最大）+ Dummy 多数类分类器，作为性能下界，防止过度设计。

3.4 评估协议

分层 5 折 CV ($K = 5$, $\text{seed}=42$)，主指标 AUC + ACC + 少数类 F1/Recall。LOOCV 兜底：过拟合判定采用「5 折 CV AUC 与 LOOCV AUC 差距」口径（三数据集差距 0.014/0.012/0.023，均 < 0.025 ，模型稳定）；全量 AUC 恒为 1.0 是 $n \ll p$ 下样本内拟合的必然现象，不作过拟合判断（详见 §4.3）。

3.5 集成（条件触发）

B2 裁定：若主模型 L2(CLR) 与对照 RF 两方法 AUC 均 ≥ 0.75 ，则做 Soft Voting 集成（概率平均）对比单最佳；否则单最佳即交付。B2 触发与集成增益见 §4.4，结论为不做集成。

表述库映射：9.1-68 预测模型选型论证、9.1-69 预测建模流程、2.1-18 对比排除论证（模型比较）、2.3-28 求解器/软件选型。

4 结果

本节约一句话：报告三数据集各模型性能、small_adenoma 四口径敏感性、特征重要性、阈值分析与集成结果；数字取自 S1 结果文件。

4.1 三数据集性能表

主模型（L2+CLR）、对照（RF）、基线（单特征 +Dummy）的 AUC/ACC/少数类 F1/Recall 汇总见表 2。数据源：S1 结果文件（三数据集主模型、对照模型与基线结果；溯源见写作素材关键数字表）。

三数据集主模型 L2(CLR) 的 AUC 分别为 Zeller 0.791、metahit 0.887、Chatelier 0.650。RF 对照在 Zeller 与 metahit 上均优于 L2 (0.845 vs 0.791、0.904 vs 0.887)，在 Chatelier 上略优 (0.660 vs

表 2: 三数据集性能汇总 (5 折 CV, seed=42; 数据源 S1 结果文件)

数据集	模型	AUC	ACC	F1(少数类)	Recall(少数类)
Zeller	L2(CLR)	0.791	0.727	0.640	0.600
Zeller	RF(原始)	0.845	0.785	0.678	0.580
metahit	L2(CLR)	0.887	0.864	0.672	0.640
metahit	RF(原始)	0.904	0.818	0.352	0.240
Chatelier	L2(CLR)	0.650	0.648	0.518	0.528
Chatelier	RF(原始)	0.660	0.644	0.094	0.056
各数据集	单特征基线	0.758/0.815/0.639		—	—
各数据集	Dummy(多数类)	0.500	0.603/0.773/0.648		—

0.650)。metahit 的 RF 少数类 F1/Recall 极低 (0.352/0.240), Chatelier 的 RF 更低 (0.094/0.056), 源于 RF 未加 `class_weight` 且默认阈值 0.5 对不平衡数据次优; AUC 为阈值无关的诚实指标。

4.2 small_adenoma 四口径敏感性

Zeller 腺瘤四口径 (归健康/归病变/剔除/单开一类) 的主模型与对照 AUC 对比见表 3。数据源: S1 结果文件 (Zeller 腺瘤四口径敏感性; 溯源见写作素材关键数字表)。

表 3: Zeller small_adenoma 四口径敏感性 (数据源 S1 结果文件)

口径	L2 AUC	RF AUC	样本数 n
(1) 归健康 (默认主口径)	0.791	0.845	121
(2) 归病变	0.611	0.651	121
(3) 剔除	0.802	0.867	95
(4) 单开一类	0.802	0.867	95

口径 (2) (归病变) 显著劣化 (L2 AUC 由 0.791 降至 0.611, 掉 0.18), 说明 small_adenoma 混入病变会污染正类, 应排除。口径 (3)/(4) (剔除) 略优于口径 (1) (L2 +0.011、RF +0.022), 但 $\Delta\text{AUC} < 0.05$, 差异不显著。默认主口径为 (1) (归健康) 已落盘; 最终主口径由建模/人类从性能与可解释性择优 (口径 (3)/(4) 剔除略优但差异不显著, 维持默认口径 (1))。

4.3 LOOCV 兜底

全量 AUC vs LOOCV AUC 对照见表 4, 用于过拟合诚实估计。数据源: S1 结果文件 (LOOCV 兜底; 溯源见写作素材关键数字表)。

表 4: LOOCV 兜底对照 (数据源 S1 结果文件)

数据集	5 折 CV AUC(L2)	LOOCV AUC	差距	全量 AUC
Zeller	0.791	0.804	-0.014	1.000
metahit	0.887	0.875	+0.012	1.000
Chatelier	0.650	0.627	+0.023	1.000

5 折 CV AUC 与 LOOCV AUC 差距均 < 0.025 , 模型稳定无过拟合。全量 AUC 恒为 1.000 是 $n \ll p$ (264 特征 vs 110-253 样本) 下样本内拟合的必然现象, 非模型缺陷。

4.4 集成结果（条件触发）

B2 条件触发判定：Zeller 与 metahit 两法 AUC 均 ≥ 0.75 ，触发 Soft Voting；Chatelier 的 L2 AUC $0.650 < 0.75$ ，不触发。触发两数据集的集成 AUC 均不优于单最佳（表 5），故不做集成，单最佳（RF）即交付。数据源：S1 结果文件（Soft Voting 集成；溯源见写作素材关键数字表）。

表 5: Soft Voting 集成 vs 单最佳（数据源 S1 结果文件）

数据集	集成 AUC	单最佳 AUC	Δ AUC	是否受益	结论
Zeller	0.838	0.845(RF)	-0.008	否	不做集成
metahit	0.896	0.904(RF)	-0.008	否	不做集成
Chatelier	—	0.660(RF)	—	不触发	单最佳交付

4.5 特征重要性（支撑 S2 铺垫）

主模型 L2 系数（CLR 空间）的 Top 特征按 |系数| 排序，各数据集前几位如下（数据源：S1 结果文件与预处理文件；溯源见写作素材关键数字表）：

- Zeller: *Peptostreptococcus_stomatis* (+0.285)、*Fusobacterium_nucleatum* (+0.245)、*Lachnospiraceae_bacterium_1_4_56FAA* (-0.188) 等；
- metahit: *Parabacteroides_unclassified* (-0.196)、*Alistipes_finegoldii* (-0.187)、*Coprococcus_sp_ART55_1* (-0.175) 等；
- Chatelier: *Pseudoflavonifractor_capillosus* (-0.542)、*Coriobacteriaceae_bacterium_phI* (-0.444)、*Porphyromonas_asaccharolytica* (+0.439) 等。

RF permutation importance 在三数据集上均退化为接近 0（量级 10^{-17} ），无法提供有效排序，原因待建模解释（RF permutation importance 退化，不影响以 L2 系数为特征方向）；特征方向以 L2 系数为准，供 S2/S3 参考。

表述库映射：3.1-30 数值先导 + 表格引出、9.1-70 预测结果评估、3.2-34 指标比较论证。

5 跨疾病差异归因分析

本节约一句话：三数据集绝对性能不可直接横向比，需从样本量、类别平衡、信号强度、批次效应四重来源归因差异。

5.1 归因框架总起

动机句：三数据集样本量、类别不平衡度、信号强度不同且存在批次效应，直接比绝对 AUC 有误导，故按四重来源归因。各数据集样本量、类别比例、基线 AUC 见 §2.1 与 §4.1。

5.2 来源一：样本量

三数据集样本量分别为 Zeller 121、metahit 110、Chatelier 253。AUC 95% 置信区间（按 5 折标准差近似）：Zeller L2 0.791 ± 0.090 ($[0.701, 0.880]$)、metahit L2 0.887 ± 0.062 ($[0.825, 0.949]$)、Chatelier L2 0.650 ± 0.063 ($[0.587, 0.713]$)（置信区间由结果文件精确值计算，个别与表内四舍五入值复算有 0.001 级出入）。Zeller 与 metahit 的置信区间在 $[0.825, 0.880]$ 重叠，二者 AUC 差异

(0.791 vs 0.887) 在统计上不显著，需谨慎解读；Zeller 区间最宽 (± 0.090)，其与 metahit 的差异部分可能落入噪声。Chatelier 区间与 metahit 不重叠，显著低于 metahit。

5.3 来源二：类别平衡

少数类比例：Zeller 39.7%、metahit 22.7%、Chatelier 35.2%。metahit 最不平衡，其 ACC (L2 0.864) 明显高于少数类 Recall (0.640)，反映多数类主导下的 ACC 虚高；Chatelier 的 RF 少数类 Recall 仅 0.056，几乎全预测多数类。类别不平衡是 metahit 与 Chatelier 少数类指标偏低的重要来源。

5.4 来源三：信号强度

单特征基线 AUC (样本内乐观上界，性能地板)：Zeller 0.758、metahit 0.815、Chatelier 0.639。Chatelier 基线最低，接近领域下界 0.65–0.75 (领域基准：肥胖症已知标志物 AUC 0.65–0.75，见领域知识)，说明其特征判别信息最弱；metahit 基线最高，信号最强。

5.5 来源四：批次效应

批次效应使三数据集不可横向比绝对 AUC，只比「相对基线的增益」。各数据集相对基线增益：L2 为 Zeller +0.033、metahit +0.072、Chatelier +0.010；RF 为 Zeller +0.087、metahit +0.088、Chatelier +0.021 (增益由结果文件精确值计算，非表内四舍五入值直接相减，个别与表内复算有 0.001 级出入)。Chatelier 多特征增益极小 (L2 仅 +0.010)，确认其弱信号、接近领域下界。

表述库映射： 3.2-35 趋势演进论证、3.2-36 方案与预期吻合论证、3.2-34 指标比较论证。

6 结论与局限

本节约一句话：总结本问交付与关键结论，声明口径边界与真实局限。

6.1 结论

S1 交付三数据集各自的二分类判别模型与诚实性能评估，并给出跨疾病差异的四重归因结论。主口径 (口径 (1)，small_adenoma 归健康) 下，L2(CLR) AUC 为 Zeller 0.791、metahit 0.887、Chatelier 0.650；RF 对照在 Zeller 与 metahit 上更优 (0.845、0.904)，Chatelier 上略优 (0.660)。集成不优于单最佳，单最佳 (RF) 即交付。跨疾病差异归因：metahit 信号最强 (基线 0.815、增益最大)、Chatelier 信号最弱 (基线 0.639、增益最小、接近领域下界)、metahit 类别最不平衡 (少数类 22.7%)。跨问衔接说明：本问性能基准与特征口径 (近全零过滤 1331→264) 供 S2 特征选择复用，特征方向 (L2 系数 Top 特征) 供 S3 跨疾病预测参考。

6.2 局限

本问存在真实方法局限，需在模型评价处明确标注：小样本下 AUC 方差大 (差异可能落入噪声，如 Zeller 置信区间最宽 ± 0.090)；Chatelier 弱信号接近领域下界 (L2 相对基线增益仅 +0.010)；批次效应限制跨数据集横向比绝对 AUC (只比相对基线增益)；RF 未加 `class_weight` 导致少数类 F1/Recall 极低 (metahit 0.352/0.240、Chatelier 0.094/0.056)，AUC 为阈值无关的诚实指标。表述库映射：6.1-53 总结全文、6.2-54 分问结论、6.3-55 不足与展望、4.2-42 数据/简化局限、4.2-43 方法/计算局限。