

第二次模拟赛 B 题 · 子问题 2：特征选择与生物标志物

（内部报告内容段 draft）

报告对话

2026-08-21

摘要

本文档是 S2（特征选择与生物标志物）的内部报告**内容段**：在骨架段基础上，从结果数据文件只读提取数字并填充全部占位，给出每病稳定标志物清单、两路信号解读、共现分析与跨疾病对比。正文按报告自足性规则行文，假设读者为未参与本子问题建模、但有工程/建模基础的队友。图表仍为占位符，正式图由队友在报告定稿后按规格出图。

1 本问任务与整体思路

本节约一句话：本问从 1331 个高维稀疏物种特征中，为每病筛出稳定、可解释、生物合理的 Top 10–20 生物标志物，并解读其丰度/存在趋势与跨疾病关系，为 S1 分类器提供一致特征子集。

1.1 本问解决什么

本问（S2，特征选择与生物标志物）承接 S1 疾病预测模型，任务是：给定清洗后相对丰度数据（阶段 0.3 清洗产物），对结直肠癌（CRC）、炎症性肠病（IBD）、肥胖症（Obesity）三病**独立**筛选最具判别力的微生物特征子集（潜在生物标志物），并分析其不同疾病状态下的丰度变化趋势、以及不同疾病类型下标志物的重叠与特异性关系。

1.2 方法主线（一句话）

近全零过滤 → CLR 前置 → Lasso + bootstrap 稳定性选择（每病独立）→ 两路信号解释（Fisher 存在/缺失 + Wilcoxon 非零丰度，BH-FDR 校正）→ 入选标志物共现分析（二阶初探）→ VIP 独立佐证（RF 佐证层退化不可用）→ 跨疾病对比。核心思路是「多轮聚合稳定化 + 信号拆分」，对抗小样本（样本数 CRC 121、IBD 110、Obesity 253）、高维稀疏（过滤后特征数 264）下的选择方差与零值主导语义。

1.3 故事线（章节骨架）

1. 本问解决什么（§1）：任务、方法主线、输出定义。
2. 数据与预处理（§2）：输入、近全零过滤、CLR 前置、三病标签口径。
3. 特征选择方法（§3）：稳定性选择框架（Lasso+bootstrap）、数学定义、参数。
4. 稳定标志物结果（§4）：每病 Top 10–20 标志物清单 + 频率 + 诚实标注（全量 vs CV 内）。

5. 两路信号解读 (§5): 存在/缺失信号 vs 非零丰度信号, 主导信号语义 (F2)。
6. 共现分析 (§6): 入选标志物两两 Spearman 相关 + 共现/互斥检验 (二阶初探)。
7. 跨疾病对比 (§7): Jaccard 重叠 + 共同/疾病特异性标志物。
8. 结论与讨论 (§8): 收束 + 与 S1 联动 + 局限。

1.4 文首符号表 (自足性)

符号	定义	首次出现
n	样本数 (CRC 121 / IBD 110 / Obesity 253)	§2
p	特征数 (过滤后 264)	§2
y_i	第 i 个样本标签 (患病 = 1, 健康 = 0)	§3
x_i	第 i 个样本的特征向量 (CLR 后)	§3
β_0	Lasso 逻辑回归截距项	§3
β_j	第 j 个特征回归系数	§3
$\hat{p}_i$	第 i 个样本预测患病概率	§3
λ	L1 正则强度 (越大越稀疏)	§3
B	bootstrap 重抽样轮数 (全量 100 / CV 内 50)	§3
$\hat{\pi}_j$	第 j 特征在 B 轮中被选中频率	§3
τ	稳定特征入选频率阈值 (0.5)	§3
δ	CLR 乘法替换伪计数 (6.5×10^{-6} , 与 S1 一致)	§2
D	CLR 变换中的特征数 (=264)	§3
$\sigma(\cdot)$	sigmoid 函数	§3
α	显著性水平 (0.05)	§3
m	FDR 多重比较校正规模 (1331 全特征)	§3
跨问/实验代号	指代	首次出现
F2 / F3 / F6	S2 A 类验证项 (两路信号/近全零/CLR)	§2、§5
S1	子问题 1: 疾病预测模型 (本问特征子集即其输入)	§1

2 数据与预处理

本节约一句话: 三病独立清洗, 先近全零过滤再 CLR, 标签口径沿用题目/S1 主口径。

2.1 数据输入

本问输入为阶段 0.3 清洗产物 (相对丰度数据, 含数据集名、疾病标签与物种特征列)。每病独立处理, 不跨病混合。三病样本数分别为 CRC 121 (患病 48 / 健康 73)、IBD 110 (患病 25 / 健康 85)、Obesity 253 (患病 164 / 健康 89), 原始特征数 1331。

2.2 近全零过滤

剔除零值占比 > 95% 的特征 (依据 A 类验证 F3——A 类验证为 S2 阶段 1.3 的建模前提核验项, F3 结论为近全零特征几乎不携带判别信息, 留着稀释 L1/RF 信号)。过滤在 ** 三病并集 ** (全 484 样本) 上统一计算零值占比、一次过滤, 特征数由 1331 降至 264 (过滤前 $p_{\text{before}} = 1331$ 、过滤后 $p_{\text{after}} = 264$), 与 S1/S3 口径一致。

2.3 CLR 前置

对保留特征做中心对数比变换 (乘法替换零值 + 几何均值中心化, 伪计数 $\delta = 6.5 \times 10^{-6}$ 与 S1 一致), 消除成分数据定和约束制造的伪相关 (F6)。CLR 变换式见 §3.3。

2.4 标签口径

- CRC: 患病 = cancer; 健康 = n + small_adenoma (small_adenoma 四口径沿 S1 裁定执行——四口径指 S1 阶段对 small_adenoma 归健康/患病的四种候选口径, S1 已选定 归健康, S2 跟随)。
- IBD: 患病 = ibd_ulcerative_colitis / ibd_crohn_disease; 健康 = n。
- Obesity: 患病 = obesity; 健康 = leanness。

3 特征选择方法

本节约一句话: 用 Lasso+bootstrap 稳定性选择做每病主口径, 拆两路信号解释入选标志物, VIP 仅作独立佐证不参与主选择 (RF 佐证层退化不可用)。

3.1 稳定性选择框架 (主方法)

对每病独立执行: 分层 CV 折内 Lasso 稀疏 Logistic + bootstrap 重抽样 (全量轮数 $B = 100$, CV 折内 $B = 50$), 统计每特征被选中 (系数非零) 的出现频率 $\hat{\pi}_j$; 频率 $\geq \tau$ (阈值 $\tau = 0.5$) 入选为稳定特征, 每病取 Top 10-20。Lasso 目标函数:

$$\min_{\beta_0, \beta} -\frac{1}{n} \sum_i [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)] + \lambda \sum_j |\beta_j|, \quad \hat{p}_i = \sigma(\beta_0 + x_i^\top \beta).$$

出现频率 $\hat{\pi}_j = \frac{1}{B} \sum_{b=1}^B \mathbb{1}\{\hat{\beta}_j^{(b)} \neq 0\}$ 。L1 正则强度由逆正则化参数 $C = 0.1$ 控制 (sklearn 1.9 新 API, C 越小正则越强、解越稀疏)。**诚实标注:** 报告并列给出「全量选择 (乐观)」与「CV 内稳定频率 (诚实)」两套结果。

3.2 两路信号检验 (对稳定特征, 非再选)

- (a) 存在/缺失信号: Fisher 精确检验 (2×2 : 存在/缺失 $\times$ 病/健)。
- (b) 非零丰度信号: 非零样本上 Wilcoxon 秩和检验 (CLR 后丰度)。
- 两路均做 BH-FDR 校正 (BH=Benjamini-Hochberg 多重比较校正, $\alpha = 0.05$, **m=1331 全特征规模**, 医疗宁可严格)。

3.3 CLR 变换式

$$\text{clr}(x)_j = \ln x_j - \frac{1}{D} \sum_{k=1}^D \ln x_k.$$

零值先乘法替换伪计数 δ 后重归一化再取对数 (与 S1 一致)。

3.4 佐证层 (独立复现, 不参与主选择)

以 PLS-DA VIP (阈值 $\text{VIP} > 1.5$) 作独立复现佐证, 与 Alpha 稳定特征 (Alpha= 本问主选择路径 Lasso+bootstrap 稳定性选择产出的稳定特征) 的 Top-N 排名一致性核对 (CRC/IBD/Obesity 的 VIP 排名 Spearman 相关 0.54/0.52/0.35)。**RF 佐证层退化不可用:** RF permutation importance

全部退化至 $\sim 10^{-17}$ 量级，不具判别信息，故本报告**不引用 RF 数字**，仅以 VIP 作独立复现佐证（见待裁定项）。VIP 仅用于排名一致性核对，不产出独立 VIP 选择集（见待裁定项 T2：VIP 是否应产出独立选择集，待人类裁定）。

4 稳定标志物结果

本节约一句话：每病产出稳定标志物清单及频率、显著性、方向，并列乐观与诚实两套。

4.1 每病稳定特征清单

在 $\tau = 0.5$ 、 $C = 0.1$ 下，CRC 与 IBD 各入选 4 个稳定特征，Obesity 入选 20 个。CRC/IBD 入选数低于 Top 10-20 目标，源于严格正则（ $C = 0.1$ ）下仅保留高置信特征；Obesity 入选 20 个但信号弱（见 §5）。各病稳定特征及全量/折内频率如下。

CRC（4 个，方向均 up= 患病富集）：

标志物	全量频率 $\hat{\pi}_j$	CV 折内频率	排名
Peptostreptococcus_stomatis	0.99	0.96	1
Fusobacterium_nucleatum	0.94	0.72	2
Porphyromonas_somerae	0.62	0.39	3
Clostridium_hathewayi	0.52	0.30	4

IBD（4 个）：

标志物	全量频率 $\hat{\pi}_j$	CV 折内频率	排名	方向
Alistipes_finegoldii	0.81	0.68	1	down
Bifidobacterium_bifidum	0.75	0.66	2	up
Akkermansia_muciniphila	0.55	0.48	3	down
Eubacterium_ventriosum	0.53	0.32	4	down

Obesity（20 个，0 个 FDR 显著）：Top 为 Ruminococcus_flavifaciens（0.89）、Pseudoflavonifractor_capillosus（0.84）、Rothia_mucilaginosa（0.72）等，全部 Fisher FDR > 0.05 ，弱信号符合预期（R3：S2 结果分析中 Obesity 弱信号的预期结论）。

4.2 标志物表

每病标志物汇总表（特征名、频率、Fisher FDR、方向、是否已知标志物）如下。

CRC：

标志物	频率	Fisher FDR	方向	已知标志物
Peptostreptococcus_stomatis	0.99	1.24×10^{-5}	up	是
Fusobacterium_nucleatum	0.94	3.94×10^{-5}	up	是
Porphyromonas_somerae	0.62	1.72×10^{-2}	up	是
Clostridium_hathewayi	0.52	5.99×10^{-1}	up	否

IBD：

标志物	频率	Fisher FDR	方向	已知标志物
Alistipes_finegoldii	0.81	6.75×10^{-3}	down	否
Bifidobacterium_bifidum	0.75	6.75×10^{-3}	up	是
Akkermansia_muciniphila	0.55	6.75×10^{-3}	down	否
Eubacterium_ventriosum	0.53	3.98×10^{-2}	down	否

Obesity：20 个标志物全部 Fisher FDR > 0.05 ，不列明细，见 §9 图表占位。

4.3 诚实标注

并列全量选择（乐观）与 CV 折内稳定频率（诚实）两套数字。以 CRC 为例，全量频率 0.99/0.94/0.62/0.52 对应折内 0.96/0.72/0.39/0.30——高排名特征折内频率仍高（稳定），低排名特征折内明显回落（选择方差大）；IBD 同理（0.81/0.75/0.55/0.53 对应 0.68/0.66/0.48/0.32）。说明入选特征中靠前者更稳定，靠后者需谨慎解读。

5 两路信号解读

本节约一句话：把每个稳定标志物的差异拆成「在不在」与「多不多」两路信号，判定主导信号并对照已知标志物。

5.1 信号拆分

对入选标志物，用 Fisher 存在/缺失信号与 Wilcoxon 非零丰度信号分别判定显著性，标注主导信号为 presence 或 abundance。三病入选标志物的主导信号几乎全为 **presence**（存在/缺失主导）：CRC/IBD 全部为 presence，Obesity 20 个中 18 个 presence、2 个 abundance（*Bacteroides_ovatus*、*Ruminococcus_bromii*），非零丰度信号普遍不显著。

按全 264 特征口径统计两路显著数（BH-FDR， $m=1331$ ）：

疾病	Fisher 显著数	Wilcoxon 显著数	入选标志物主导信号
CRC	4	1	presence
IBD	6	1	presence
Obesity	0	0	presence 18 / abundance 2（均不显著）

以 CRC 为例，*Peptostreptococcus_stomatis* 的 Fisher FDR 1.24×10^{-5} 极显著而 Wilcoxon FDR 0.113 不显著，说明其判别力主要来自「患病组更常存在」而非「存在时丰度更高」；*Fusobacterium_nucleatum* 的 Wilcoxon 检验在非零样本上 $p = 1$ ，进一步印证存在/缺失主导。

5.2 已知标志物对照

与领域知识库中的已知标志物交叉核对，作方法有效性锚点。CRC 4 个入选标志物中 3 个命中已知标志物（*Peptostreptococcus_stomatis*、*Fusobacterium_nucleatum*、*Porphyromonas_somerae*），*Clostridium_hathewayi* 未命中；IBD 4 个中 1 个命中（*Bifidobacterium_bifidum*，已知属）。CRC 命中率最高，方法有效性锚点 H6（S2 结果分析中已知标志物命中率验证项）强验证。

6 共现分析（协同效应初探）

本节约一句话：以入选标志物为限做两两 Spearman 相关与共现/互斥检验，识别协同/互斥对。

6.1 相关矩阵

非零样本上、CLR 后丰度的两两 Spearman 相关矩阵/热图。

6.2 共现/互斥网络

相关显著对用 Fisher 精确检验（存在/缺失口径）验证同现/互斥是否超出独立期望，输出网络（节点 = 标志物，边 = 显著共现/互斥）。三病显著边数：CRC 4 条（全部共现）、IBD 6 条（3 共现 / 3 互斥）、Obesity 24 条。

CRC 最强共现对为 *Peptostreptococcus_stomatis* ↔ *Fusobacterium_nucleatum* (Spearman 0.76, Fisher $p \approx 8.8 \times 10^{-7}$, OR 12.9; OR= 比值比 odds ratio, 衡量共现/互斥强度)——两者均为 CRC 相关口腔菌, 共现生物合理; 其次 *Peptostreptococcus_stomatis* ↔ *Porphyromonas_somerae* (Spearman 0.83)。IBD 中 *Alistipes_finegoldii* 与 *Bifidobacterium_bifidum* 呈互斥 (OR 0.19), 与二者方向相反 (down/up) 一致。

6.3 边界声明 (必须含)

「小样本下仅对入选标志物做二阶探索, 无法全特征交互建模; 标志物筛选主口径仍为边际信号 (生物标志物研究标准口径)。」

7 跨疾病对比

本节约一句话: 比较三病稳定标志物集合的重叠与特异性, 给出共同标志物与疾病特异性标志物。

7.1 标志物重叠

三病稳定特征集两两 Jaccard 重叠: CRC-IBD 0.0、CRC-Obesity 0.0、IBD-Obesity 0.0。三病稳定特征集完全疾病特异, 无任何重叠。

7.2 共同与特异性标志物

共同标志物列表为空, 各病标志物全部为疾病特异: CRC 4 个、IBD 4 个、Obesity 20 个。这与「*Fusobacterium_nucleatum* 的 CRC 特异性」等已知生物学预期一致——不同疾病由不同微生物驱动, 标志物不跨病共享。

8 结论与讨论

本节约一句话: 收束本问核心交付, 说明与 S1 的联动与已知局限。

8.1 结论收束

在 $\tau = 0.5$ 、 $C = 0.1$ 下, CRC 与 IBD 各得 4 个高置信稳定标志物 (CRC 3/4 命中已知标志物, 方法有效性锚点强验证), Obesity 得 20 个但全部 FDR 不显著 (弱信号)。所有入选标志物主导信号几乎全为存在/缺失 (presence): CRC/IBD 全部 presence, Obesity 18/20 presence + 2 abundance (*Bacteroides_ovatus*、*Ruminococcus_bromii*), 非零丰度信号普遍不显著。三病标志物完全疾病特异, 无共同标志物。CRC 入选标志物间存在强共现簇 (口腔菌协同), IBD 存在方向相反的互斥对。

8.2 与 S1 联动

本问所选稳定特征子集即 S1 分类器输入特征, 形成「特征选择 → 分类建模」一致链路。CRC/IBD 的 4 个高置信特征可直接作为 S1 输入; Obesity 弱信号提示 S1 对 Obesity 的判别主要依赖其他特征或需放宽阈值。

8.3 局限

小样本选择方差（CV 折内频率回落）、零值主导（存在/缺失信号主导）、Obesity 弱信号（可信度分级，预期显式降低）、交互效应仅二阶初探。CRC/IBD 入选数低于 Top 10–20 目标，源于严格正则 $C = 0.1$ 的保守口径（见待裁定项 T1：主口径 $C = 0.1$ 是否应放宽，待人类裁定）。

9 图表占位符与规格

本节约一句话：列出每张正式图的图名、数据源（pkl+ 字段）与论文位置，供出图。

表 1: 图表占位清单（数据源 = outputs/data/S2-results.pkl）

图名	数据源 (pkl 字段)	论文位置
每病稳定特征频率条形图 (Top 稳定标志物)	per_disease.<D>.stable_features.\{feature,frequency,rank\}	\$4.2
每病标志物汇总表	per_disease.<D>.biomarker_table	\$4.2
两路信号统计表 (Fisher/Wilcoxon FDR + 主导信号)	per_disease.<D>.two_path_signals	\$5.1
共现 Spearman 相关热图	per_disease.<D>.cooccurrence.spearman_matrix	\$6.1
共现/互斥网络	per_disease.<D>.cooccurrence.cooccurrence_edges	\$6.2
佐证一致性 (VIP vs Alpha Top-N 排名)	per_disease.<D>.topN_consistency + vip	\$3.4
跨疾病 Jaccard 重叠热图	cross_disease.jaccard_matrix	\$7.1
共同/疾病特异性标志物表	cross_disease.common_biomarkers + disease_specific	\$7.2