

S3 内部报告：跨疾病预测模型

（子问题 3，leave-one-disease-out 泛化评估）

报告对话（S3）

2026-08-21

摘要

内容摘要：本报告回答题面 S3「建立一个跨疾病预测模型，并探讨模型在跨疾病预测上的性能」。核心叙事：本问解决「模型到新疾病上还灵不灵」→ 建立 LODO（留一疾病）诚实评估协议 → 正式构建并对比四种跨疾病建模策略 → 选出最优策略作为交付模型 → 若全部策略性能不达标则触发紧急回退重新选模型 → 从衰减归因 / 深度迁移 / 阈值漂移三视角探讨跨疾病性能 → 结论。**关键结果：**四策略 3 组合 AUC 均值全部低于 0.60（最优策略 A 直接迁移均值 0.5603），触发紧急回退；回退链 R1–R4（紧急回退候选模型族，见 §5）中密度比重加权域适应（R3）达到最优可达均值 0.6068，仍低于可用线 0.65，故本问以「穷尽努力后的完整证据链」交付，未交付可用模型。衰减归因显示主导来源为疾病特异信号（IBD 衰减最大 -0.271 ）与标签语义漂移（Obesity）；深度迁移分析显示共享物种方向一致性接近随机（51.2%，符号检验 $p = 0.536$ ）；C3 阈值漂移量化显示训练/测试患病基线差 $\Delta = +0.332$ ，Youden 阈值落在测试分布 96.0% 分位，灵敏度仅 0.024。

表 1: 符号表（本文自足性速查；每个符号正文首次出现处均有内嵌定义）

符号	定义	首次出现
LODO	留一疾病（leave-one-disease-out）：每次留一种疾病作测试集，其余作训练集，共 3 组合	§2
C1 / C2 / C3	三个 LODO 组合（测试疾病分别为 CRC / IBD / Obesity）	§2
AUC	曲线下面积（主指标，阈值无关）	§3
J	Youden J 统计量（灵敏度 + 特异度 -1 ）， τ^* 为其最优阈值	§3
P_{cal}	Platt 校准概率，参数 A, B （仅训练集估计）	§3.4
silhouette	轮廓系数（ $[-1, 1]$ ，衡量聚类分离度）	§6.1

表 2: 跨问 / 裁定代号表

代号	指代	首次出现
S3 门禁 1 重构	人类裁定（2026-08-21）：四策略对比升级为正式建模 + 紧急回退协议	§1
S1 口径	策略 A 沿用的 S1 已验证模型口径（L2+CLR）	§3.1
S2 生物标志物	子问题 2 的生物标志物识别结论，本问在 §6/§7 交叉核对	§6.2
三分法归因	批次效应 / 疾病特异信号 / 标签语义漂移（互斥归因来源）	§6.1

1 问题与目标

本节约一句话：本问解决「模型到一个没见过的疾病上还灵不灵」，正面回答是「建立跨疾病预测模型」——正式构建并对比四种策略、选出最优者交付，性能不达标则走紧急回退，直到交付可用模型或穷尽候选后以完整证据链报告。

1.1 本问解决什么

题面 S3 要求建立跨疾病预测模型并探讨其性能。这里的核心是「跨疾病」：模型在若干疾病上学到的判别能力，能否迁移到训练阶段从未见过的另一种疾病。本文不把「负结果」当作默认终点，而是按人类裁定（S3 门禁 1 重构）先尽力交付模型，失败证据链是穷尽努力后的最后结论。

1.2 怎么解决（故事线总览）

回答按以下链路推进：

1. 建立 LODO（留一疾病）协议，作为「新疾病不可见」的诚实评估基准（§2）；
2. 正式构建并对比四种跨疾病建模策略（A 直接迁移 / B 共享标志物 / C 分类学聚合 / D 部署校正），选出最优者（§3）；
3. 交付最优策略，报告其性能水平与适用条件（§4）；
4. 若四策略性能均不达标，触发紧急回退重新选模型，记录过程与交付（§5，条件节）；
5. 从衰减归因 / 深度迁移 / 阈值漂移三视角探讨跨疾病性能为什么好或为什么差（§6）；
6. 结论收束（§7）。

1.3 主/次目标声明

本问为单一评估目标（度量跨疾病预测性能），AUC 为唯一主指标，辅指标是 AUC 的分解视图，不构成独立的次目标，因此不写主次目标取舍结论。

2 数据与 LODO 协议

本节约一句话：交代数据来源与预处理口径，并正式定义 LODO 三组合协议——测试疾病在训练阶段完全不可见。

2.1 数据

使用 0.3 清洗后的物种级相对丰度数据（定和成分数据）。预处理与 S1 口径一致、严格防泄漏（S1：子问题 1，单疾病患病预测模型，本问沿用其已验证的 L2+CLR 预处理口径；S2：子问题 2，生物标志物识别，本问在 §6/§7 与其结论交叉核对）：

1. 近全零过滤（零值占比超过阈值剔除，三病并集统一口径，与 S1/S2 一致）——过滤后特征数 264（由原始 1331 个物种特征过滤得到，样本共 484 例）；
2. CLR 变换（成分数据强制，零值乘法替换）——替换常数 6.5×10^{-6} ；
3. StandardScaler（均值/方差仅训练集估计，防泄漏）。

2.2 LODO 协议

本节说明为什么用 LODO：它是「跨疾病」最诚实的评估方式——测试疾病在训练阶段完全不可见（标签与特征均不参与训练），模型学到的是真正可泛化的判别。

三个组合（训练集为其余两种疾病）：

1. **C1**：测试 CRC，训练 IBD + Obesity，测试集正类占比 39.7%；
2. **C2**：测试 IBD，训练 CRC + Obesity，测试集正类占比 22.7%（少数类）；
3. **C3**：测试 Obesity，训练 CRC + IBD，测试集正类占比 64.8%（正类占多数）。

3 四策略构建与对比

本节约一句话：正式构建四种跨疾病建模策略（直接迁移 / 共享标志物 / 分类学聚合 / 部署校正），在同一 LODO 协议下对比 AUC，为选出最优交付模型提供证据。

每个策略的写法统一为「动机句（为什么看这个）→ 构建方式 → 防泄漏边界 → 预期观测」。

3.1 策略 A：直接迁移（基线）

动机：先看最直接的跨疾病做法——把在训练疾病上训练好的模型原样搬到测试疾病，作为全部策略的基线。**构建**：正则化 Logistic 回归（L2 惩罚， $C = 1.0$ （ C ：L2 正则化强度超参数），class_weight balanced）+ CLR 前置 + 近全零过滤物种级特征（264 维），沿用 S1 口径。**评估**：主指标 AUC（阈值无关，最诚实）；辅指标为训练集 Youden J 最优阈值迁移下的 ACC（准确率）/ 灵敏度 / 特异度 / F1（标注测试集类别不平衡）[2]。**防泄漏**：禁止在测试集上重定阈值（会用到新疾病标签）。

3.2 策略 B：跨疾病通用模型（共享标志物特征子集）

动机：若疾病特异信号在拖后腿，则只保留三疾病共享的物种（疾病无关特征）重训「通用患病模型」，看能否恢复性能。**构建**：取三数据集共享物种（基于过滤后特征集按特征名取交集，数量 252）作特征子集，在训练疾病上重训策略 A 同款模型，重跑 LODO。**防泄漏**：特征交集仅使用特征存在性（哪些物种在三数据集都出现），绝不用测试集标签（转导式边界显式声明——转导式边界指特征选择/权重估计等环节不使用测试集标签，仅用特征存在性等无监督信息）。

3.3 策略 C：分类学聚合模型（属级/门级 + CLR）

动机：回应题面注 2「可利用微生物的分类学信息」——把物种级特征聚合到属级/门级，看分类学层级能否带来增益。**构建**：物种级特征按属（g_）/ 门（p_）层级聚合（同属/同门丰度求和，聚合后维度大幅下降：属级 106 维、门级 11 维），CLR 后重训同款模型，重跑 LODO。**预期观测**：聚合是否提升跨疾病性能为实测观测，如实报告（分类学信息已利用，是否有增益不预判）。

3.4 策略 D：部署校正模型（最优策略 + 概率校准 + 阈值迁移）

动机：AUC 与阈值无关、不受校准影响，但可部署指标（ACC/F1/灵敏度）会因训练与测试患病概率基线不同而失准。本策略在最优策略上叠加 Platt 校准，修复可部署指标。**构建**：在策略 A/B/C 中 AUC 最优者（实测为策略 A）上叠加 Platt 缩放 [1]，把原始分数映射到校准概率，再迁移 Youden 阈值。**防泄漏**：校准参数 A, B （ $P_{cal}(y=1 | \mathbf{x}) = 1/(1 + \exp(A f(\mathbf{x}) + B))$ ）仅训练集

估计；实现校验 $A < 0$ （等价 $w > 0$ ，防排序反转）。不改 AUC（单调变换不改变排序），只修复可部署指标。

3.5 策略对比（核心交付）

以下为四策略 3 组合 AUC 对比表。判定（各策略是否达可用线）见 §5——四策略均值全部低于 0.60，触发紧急回退。

表 3: 四策略 3 组合 AUC 对比（核心交付；C 分属级/门级两档，D 以策略 A 为基）

策略	构建方式	C1 AUC	C2 AUC	C3 AUC
A 直接迁移	L2+CLR 物种级 264	0.5674	0.5882	0.5253
B 共享标志物	共享特征子集 252 重训	0.5417	0.6080	0.5218
C 属级聚合	属级 106 维 + CLR	0.3616	0.4861	0.5440
C 门级聚合	门级 11 维 + CLR	0.4141	0.5261	0.5999
D 部署校正	策略 A + Platt 校准	0.5674	0.5882	0.5253

四策略 3 组合 AUC 均值：A 0.5603、B 0.5572、C 属级 0.4639、C 门级 0.5134、D 0.5603（与基策略 A 相同，符合 Platt 单调变换不改排序）。全部低于 0.60，触发紧急回退（§5）。

4 最优策略交付

本节约一句话：从四策略中选定交付模型，报告其构建方式、跨疾病性能水平与适用条件；若回退被触发，则此节交付回退所得模型（见 §5）。

4.1 交付模型选择

选定依据（策略对比表 3 + 可用判定标准）——四策略均值全部低于可用线，故交付模型由紧急回退链决定（§5），最优可达策略为 **R3 密度比重加权域适应**（3 组合 AUC 均值 0.6068）。选定理由与备选取舍：四策略中策略 A 直接迁移均值最高（0.5603），但低于可用线 0.65；回退链中 R3 加权域适应达到最优可达均值 0.6068，仍低于可用线，故本问以「最优可达 + 完整证据链」交付，不宣称可用模型。

4.2 性能水平与适用条件

- 3 组合 AUC 均值：0.6068（R3 加权域适应）；各组合取值：C1 0.5945、C2 0.6489、C3 0.5771。
 - 阈值迁移辅指标（R3，训练集 Youden 阈值迁移）：C1 ACC 0.6446 / 灵敏度 0.2292 / 特异度 0.9178 / F1 0.3385；C2 ACC 0.5727 / 灵敏度 0.6800 / 特异度 0.5412 / F1 0.4198；C3 ACC 0.4150 / 灵敏度 0.1585 / 特异度 0.8876 / F1 0.2600。
 - 适用条件与部署建议：本问未交付可用模型（最优可达 $0.6068 < \text{可用线 } 0.65$ ）。R3 加权域适应在 C2（IBD）上表现相对最好（0.6489），在 C3（Obesity）上仍受阈值漂移拖累（灵敏度 0.1585）。部署建议：若必须部署，优先用于患病基线接近训练分布的疾病，并需在目标疾病上重定阈值。
 - 真实方法局限（保留精确边界）：域适应权重基于域分类器估计（Logistic 区分 train/test），权重裁剪上界 10；R3 提升相对策略 A 为 +0.0465，未达「相对 A 提升 ≥ 0.10 」的可用线。

5 紧急回退记录（触发时）

本节约一句话：四策略 3 组合 AUC 均值均低于可用线，触发紧急回退重新选模型；本节记录触发证据与逐级回退结果，直到交付可用模型或穷尽候选。

5.1 触发判定

触发条件（四策略均值均 < 0.60 ）：实测四策略均值全部低于 0.60，**触发**。可用线定义为「回退候选均值 ≥ 0.65 或相对策略 A 提升 ≥ 0.10 」。

5.2 逐级回退

候选模型族按序尝试，每级同 LODO 协议评估，达可用线即交付：

1. **R1 树模型族**（Random Forest 500 树，物种级过滤后特征）——均值 0.5092，未达可用线；
2. **R2 样本合并通用模型**（2 训练疾病样本合并训练「患病 vs 健康」通用分类器）——均值 0.5603（与策略 A 数学恒等，因 LODO 协议本身已合并 2 训练疾病），未达可用线；
3. **R3 密度比重加权域适应**（importance weighting，域分类器法，转导式边界显式声明）——均值 0.6068，未达可用线（ < 0.65 ，相对 A 提升 $+0.0465 < 0.10$ ）；
4. **R4 对抗式域适应**（DANN，即 Domain-Adversarial Neural Network 域对抗神经网络，梯度反转，最后手段，严格验证集防泄漏）——均值 0.5947，未达可用线。

5.3 穷尽证据链

R1–R4 全部未达可用线，报告最优可达性能 + 失败主因 + 部署建议（完整证据链）：- 最优可达性能：R3 加权域适应 3 组合 AUC 均值 0.6068，低于可用线 0.65；- 失败主因：衰减归因显示主导来源为疾病特异信号（IBD 衰减最大）与标签语义漂移（Obesity），共享物种方向一致性接近随机（§6）；- 部署建议：本问不交付可用模型，以证据链说明「跨疾病泛化在当前数据与协议下受限」，并给出改进方向（§7）。

6 性能探讨

本节约一句话：从衰减归因（三分法）、深度迁移（什么在迁移）、阈值漂移（C3 诊断）三视角解释跨疾病性能为什么是这个水平，为最优策略的可用边界与后续改进提供依据。

6.1 衰减归因：三分法

动机：把每个低 AUC 组合的失败归因到三个**互斥**来源，每个来源配可计算的定量证据，避免笼统说「泛化差」。三分法来源与操作化定义：

1. **批次效应**：训练/测试来自不同研究/平台导致的分布偏移——定量证据 silhouette 系数（数据集标签）= 0.070（A 类验证值，近 0，不主导）；
2. **疾病特异信号**：模型学的是训练疾病特有标志物——定量证据域内 AUC 减跨疾病 AUC 的衰减量（见下表）；

3. 标签语义漂移：新疾病患病概率基线整体偏移、决策边界失准——定量证据训练/测试患病基线差 (§6.3)。

衰减归因表（各疾病域内/跨疾病 AUC、衰减量、主导归因；域内 AUC 为 264 特征 5 折 CV (5-fold cross-validation, 五折交叉验证) 重算，与跨疾病同口径）。**口径声明：**本问预处理含 StandardScaler（均值/方差仅训练集估计），与 S1/S2 的纯 CLR 口径不同，故域内 AUC 与 S1 有差异 ($\Delta -0.010/-0.028/+0.014$, CRC/IBD/Obesity)：

表 4: 衰减归因表（三分法：衰减量 = 跨疾病 AUC - 域内 AUC）

疾病	域内 AUC	跨疾病 AUC	衰减量	主导归因
CRC	0.7811	0.5674	-0.2138	疾病特异信号
IBD	0.8588	0.5882	-0.2706	疾病特异信号（最强）
Obesity	0.6638	0.5253	-0.1384	标签语义漂移

6.2 深度迁移分析：什么在迁移、什么不迁移

动机：回答「哪些共享标志物的丰度变化方向跨疾病一致（可迁移信号）、哪些翻转（疾病特异信号）」，把共享物种分成两类并量化占比，识别真正可迁移的生物学信号。- 方向一致（可迁移）数量与占比：387 个，占 51.2%（共 756 个有效共享物种）；- 方向翻转（疾病特异）数量与占比：369 个，占 48.8%；- 符号检验： $p = 0.5364$ （不显著）——共享物种的「患病 $\uparrow/\downarrow$ 」方向跨疾病接近随机 ($\approx 50/50$)，即共享物种的**存在性**不承载可迁移信号，信号藏在**疾病特异方向**里；- 可对接 S2 生物标志物结论的清单：见写作素材（共享物种清单 252 个，方向一致性逐物种标注，供 S2 生物标志物交叉核对）。

图 1: 共享标志物跨疾病方向一致性示意——数据已就绪（387 一致 / 369 翻转），图待出图后替换

6.3 阈值漂移量化 (C3)

动机：把「AUC 接近随机而可部署指标崩溃」的矛盾展开成完整诊断——训练集与测试集患病概率基线差多少、Youden 阈值迁移后决策边界落在测试集分布何处。- 训练集 vs 测试集患病概率基线差：训练 0.316 vs 测试 0.648，基线差 $\Delta = +0.332$ ；- Youden 阈值迁移后决策边界在测试集分布的位置： $\tau^* = 0.9205$ 落在测试分数分布的 96.0% 分位（96.0% 测试样本被判健康）；- 完整诊断（AUC 与可部署指标为何背离）：测试分布整体左移，训练集拟合的 Youden 阈值迁移后决策边界失准，灵敏度仅 0.024（几乎全判健康）——标签语义漂移主导，AUC 接近随机（0.525）而可部署指标崩溃。Platt 校准为单调变换，不改变决策边界，故无法修复 C3 可部署指标（即使改用 0.5 概率阈值，灵敏度仅 0.165）。

图 2: C3 阈值漂移诊断示意图——数据已就绪（基线差 $\Delta = +0.332$ ，阈值落 96.0% 分位），图待出图后替换

7 结论

本节约一句话：收束本问对「建立跨疾病预测模型」的正面回答——交付模型 + 性能水平 + 适用条件 + 局限与改进方向。

- 交付模型与跨疾病性能：本问未交付可用模型。四策略均值全部低于 0.60（最优策略 A 直接迁移 0.5603），触发紧急回退；回退链 R1–R4 中 R3 密度比重加权域适应达到最优可达均值 0.6068，仍低于可用线 0.65，以「最优可达 + 完整证据链」交付。
- 性能为何是这个水平（衰减/迁移/漂移主因）：衰减归因显示主导来源为疾病特异信号（IBD 衰减最大 -0.271 ）与标签语义漂移（Obesity）；深度迁移分析显示共享物种方向一致性接近随机（51.2%， $p = 0.536$ ），共享物种存在性不承载可迁移信号；C3 阈值漂移量化显示训练/测试患病基线差 $\Delta = +0.332$ ，Youden 阈值落测试分布 96.0% 分位，灵敏度仅 0.024。
- 适用条件与真实局限：若必须部署，优先用于患病基线接近训练分布的疾病，并需在目标疾病上重定阈值；域适应权重基于域分类器估计（裁剪上界 10），R3 相对 A 提升 $+0.0465$ 未达可用线。
- 改进与推广方向：(1) 引入更多疾病/更大样本以缓解疾病特异信号主导；(2) 针对标签语义漂移做目标疾病阈值重定或校准；(3) 探索疾病特异方向信号（而非共享存在性）作为可迁移特征；(4) 与 S2 生物标志物结论交叉核对，识别真正可迁移的生物学信号。

参考文献

- [1] Platt, J. C. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In *Advances in Large Margin Classifiers*, 61–74, 1999.
- [2] Youden, W. J. Index for rating diagnostic tests. *Cancer*, 3(1):32–35, 1950.