

1 论文写作素材（供队友写作）——对应内部报告 iter-02-sub1-disease-prediction.tex

1.1 章节映射

本报告对应终稿第 **第 N 章「疾病预测模型」**。建议终稿结构如下：

- §X.1 建模与求解 ← 本报告 §2 数据 + §3 模型
- §X.2 结果分析 ← 本报告 §4 结果 + §5 归因分析

1.2 故事线（按段给出主题句与写作要点）

1. **【章首段】**本问任务转述 + 输入规模 + 关键约束。要点：三数据集（Zeller 结直肠癌 $n = 121$ 、metahit 炎症性肠病 $n = 110$ 、Chatelier 肥胖症 $n = 253$ ）以物种级相对丰度为特征，构造患病/健康二分类判别模型。表述库参考：5.1-48（业务情境）+ 5.1-49（编号列表）。
2. **【建模段】**为什么用该方法 + 模型结构。要点：主模型 Logistic(L2)+CLR（成分数据定和偏相关需 CLR 解除，L2 抗 $n \ll p$ 过拟合），对照随机森林（原始丰度），基线单特征最佳阈值 +Dummy；统一分层 5 折 CV（ $K = 5$, seed=42）+ LOOCV 兜底。表述库参考：9.1-68（预测模型选型论证）+ 9.1-69（预测建模流程）。
3. **【结果段】**核心数字 + 对比结论。要点：主口径下 L2(CLR) AUC 为 Zeller 0.791、metahit 0.887、Chatelier 0.650；RF 在 Zeller/metahit 更优（0.845/0.904）、Chatelier 略优（0.660）；集成不优于单最佳，单最佳（RF）交付；Chatelier 弱信号接近领域下界。表述库参考：3.1-30（数值先导 + 表格引出）+ 3.2-34（指标比较论证）。

1.3 关键数字表

数字	含义
121 / 110 / 253	三数据集样本数
73/48、85/25、89/164	各数据集健康/患病样本数
39.7%/22.7%/35.2%	各数据集少数类比例
1331→264	近全零过滤前后特征数
6.5×10^{-6}	CLR 零值替换伪值 δ
0.791/0.887/0.650	三数据集 L2(CLR) AUC
0.845/0.904/0.660	三数据集 RF AUC
0.727/0.864/0.648	三数据集 L2 ACC
0.640/0.672/0.518	三数据集 L2 少数类 F1
0.600/0.640/0.528	三数据集 L2 少数类 Recall
0.678/0.352/0.094	三数据集 RF 少数类 F1
0.580/0.240/0.056	三数据集 RF 少数类 Recall
0.758/0.815/0.639	三数据集单特征基线 AUC
0.603/0.773/0.648	三数据集 Dummy 多数类 ACC
0.791/0.611/0.802/0.802	adenoma 四口径 L2 AUC
0.845/0.651/0.867/0.867	adenoma 四口径 RF AUC
121/121/95/95	adenoma 四口径样本数
healthy	默认主口径
0.804/0.875/0.627	三数据集 LOOCV AUC
0.838/0.896	Zeller/metahit 集成 AUC
-0.008	集成 vs 单最佳 Δ AUC
+0.033/ +0.072/ +0.010	三数据集 L2 相对基线增益
+0.087/ +0.088/ +0.021	三数据集 RF 相对基线增益
+0.285/ +0.245/ -0.188	Zeller L2 系数 Top3 (Peptostreptococcus_stomatis / Fusobacterium_nucleatum / Lachnospiraceae_bac
-0.196/ -0.187/ -0.175	metahit L2 系数 Top3 (Parabacteroides_unclassified / Alistipes_finegoldii / Coprococcus_sp_ART55_
-0.542/ -0.444/ +0.439	Chatelier L2 系数 Top3 (Pseudoflavonifractor_capillosus / Coriobacteriaceae_bacterium_pH / Porphy
$\pm 0.090 / \pm 0.062 / \pm 0.063$	三数据集 L2 AUC 95% 置信区间半宽 (Zeller/metahit/Chatelier)

1.4 图表清单

图/表	论文用途	数据源 (pkl 字段)	建议插入位置
S1-roc-curve-explore.pdf	三数据集 ROC 曲线 (L2+RF, OOF 概率) + AUC	<ds>.L2_CLR.oof_prob <ds>.RF_raw.oof_prob + 标签	/ §4.1 结果段
S1-perf-bar-explore.pdf	三数据集性能对比柱状图 (L2/RF AUC)	<ds>.L2_CLR.AUC <ds>.RF_raw.AUC	/ §4.1 结果段
S1-adenoma-sensitivity-explore.pdf	small_adenoma 四口径敏感性 (L2/RF AUC)	adenoma_sensitivity.*.L2_AUC RF_AUC	/ §4.2 结果段
S1-confusion-matrix-explore.pdf	三数据集 L2(CLR) 混淆矩阵热力图	<ds>.L2_CLR.confusion_matrix	§4.1 结果段
S1-feature-importance-explore.pdf	L2 系数 Top10 + RF permutation importance Top10	<ds>.L2_CLR.coefficients <ds>.RF_raw.feature_importances	/ §4.5 特征重要性
S1-threshold-analysis-explore.pdf	阈值-指标曲线 (L2 概率分类器)	<ds>.L2_CLR.oof_prob	§4.1 结果段

图表占位符规格：以上 6 张探索图位于 `outputs/figures/_explore/` (不进论文)，正式图由队友在报告定稿后按 `chart-generator skill` 出图，

数据源为 `S1-results.pkl`（逐图字段见上表），替换本报告 §4 的图表占位符。

1.5 口径与局限（可写句 / 禁写句）

- 可写：主口径（small_adenoma 归健康）下，L2(CLR) AUC 为 Zeller 0.791、metahit 0.887、Chatelier 0.650；RF 在 Zeller 与 metahit 上更优（0.845、0.904），Chatelier 上略优（0.660）。
- 可写：Soft Voting 集成不优于单最佳（ $\Delta\text{AUC} = -0.008$ ），单最佳（RF）即交付。
- 可写：Chatelier 弱信号接近领域下界（L2 相对基线增益仅 +0.010），多特征增益极小。
- 禁止写：不得把三数据集绝对 AUC 直接横向比较（批次效应强，只比相对基线增益）。
- 禁止写：不得把全量 $\text{AUC}=1.000$ 表述为模型过拟合缺陷（ $n \ll p$ 下样本内拟合的必然现象，5 折 CV 与 LOOCV 差距 < 0.025 表明模型稳定）。
- 禁止写：不得把 RF 少数类 F1/Recall 极低（metahit 0.352/0.240、Chatelier 0.094/0.056）表述为 RF 模型失效——RF 未加 `class_weight` 且默认阈值 0.5 对不平衡数据次优，AUC 为阈值无关的诚实指标。
- 禁止写：不得写 CLR 相对原始丰度的定量增益（`pkl` 未落盘该字段，见待裁定项 1）。

1.6 AI 工具使用标注

本子问题涉及 AI 使用记录：[TODO: [AI-4-1] 等编号待阶段 3.3 补充]，供阶段 3.3 AI 使用声明引用。

1.7 待裁定项（反向交接，需建模/人类裁决）

1. **CLR 增益实证值缺失**（A 级，2.4 已裁定）：`pkl` 无 CLR 相对原始丰度的定量增益字段，无法只读提取。裁定：标注「无实证值，正文不写」

具体增益」——报告 §2.4 已按此书写，未写具体增益数字；素材「禁止写」句同步保留（不得写 CLR 定量增益）。

2. **过拟合判定规则失效** (A 级, 2.4 已裁定): 三数据集 `overfit_flag` 均判 True (全量 AUC=1.0 与 LOOCV 差距 0.196/0.125/0.373 均 > 0.1), 但这是 $n \ll p$ 下样本内 AUC 恒为 1.0 的必然现象。裁定: 采用「CV vs LOOCV」口径——报告 §3.4 已按此书写 (5 折 CV 与 LOOCV 差距 0.014/0.012/0.023, 均 < 0.025 , 模型稳定), 并显式说明 `full_AUC=1.0` 背景, 不作过拟合判据。
3. **Chatelier RF 少数类 F1/Recall 极低**: RF 无 `class_weight`, 默认阈值 0.5 对不平衡数据 (少数类 = 健康 35.2%) 次优, 几乎全预测多数类。报告以 AUC 为诚实指标并说明原因, 需建模裁决是否补充 `class_weight` 或调阈值。(B 级)
4. **small_adenoma 主口径选择**: 默认 (1) (归健康) 已落盘; (3)/(4) (剔除) 略优但 $\Delta AUC < 0.05$ 。报告已按默认 (1) 书写, 最终主口径待建模/人类择优。(B 级)
5. **RF permutation importance 退化**: 三数据集 RF permutation importance 均接近 0 (量级 10^{-17}), 无法提供有效特征排序。报告以 L2 系数为特征方向, RF 重要性退化原因待建模解释。(B 级)