

S1 数学推导：疾病预测模型（CLR + Logistic(L2) + class_weight）

MathModel 建模小组

2026-08-21

1 问题形式化

S1 子问题为三个宏基因组数据集（Zeller CRC / metahit IBD / Chatelier Obesity）各自建立「患病 vs 健康」二分类判别模型，并诚实评估其性能、归因三数据集之间的性能差异。本文件给出主模型（Logistic(L2) + CLR 前置 + class_weight）的完整数学推导，含数据预处理（近全零过滤 + CLR 变换）、模型与损失、评估协议、参数表、简化假设、数学自检与假设检验计划。对照模型（Random Forest）与基线（单特征阈值 + Dummy）仅列规格，不展开推导。

1.1 符号表（先定义再使用）

符号	读法	定义
n	「样本数」	某数据集的样本总数（Zeller=121 / metahit=110 / Chatelier=253）
p	「特征数」	物种级特征列数，原始 $p_0 = 1331$ ，过滤后 $p = 264$
x_{ij}	「第 i 个样本第 j 个物种的相对丰度」	原始丰度矩阵 $\mathbf{X} \in \mathbb{R}^{n \times p}$ 的元素， $i = 1, \dots, n$ ， $j = 1, \dots, p$
δ	「德尔塔，零值替换值」	零值乘法替换的伪值 $= 6.5 \times 10^{-6}$ （见 §2.2）
g_i	「第 i 个样本的几何均值」	$g_i = (\prod_{j=1}^p x_{ij})^{1/p}$ ，读作「所有物种丰度连乘后开 p 次方」
$\text{clr}(x_{ij})$	「CLR 变换后的值」	中心化对数比（Centered Log-Ratio），见 §2.2
$\mathbf{w}$	「权重向量」	Logistic 系数向量，长度 p ， w_j 是第 j 个物种的效应
b	「偏置项」	Logistic 截距
z_i	「线性得分」	$z_i = \mathbf{w}^\top \text{clr}(\mathbf{x}_i) + b$ ，读作「权重与 CLR 特征的内积加偏置」
$\sigma(z)$	「sigmoid 函数」	$\sigma(z) = \frac{1}{1+e^{-z}}$ ，把任意实数压到 (0, 1) 当概率
y_i	「第 i 个样本的真实标签」	患病 = 1 / 健康 = 0
λ	「拉姆达，正则强度」	L2 惩罚系数，越大收缩越强
C	「C，正则强度的倒数」	sklearn 参数， $C = 1/\lambda$ ， C 越大正则越弱
w_c	「第 c 类的样本权重」	class_weight 中类别 c 的权重，见 §3.3
K	「K，交叉验证折数」	分层 CV 的折数 = 5
z_j	「第 j 个特征的零值占比」	$z_j = \frac{1}{n} \sum_{i=1}^n \mathbf{1}[x_{ij} = 0]$ ，见 §2.1

2 数据预处理数学

2.1 近全零过滤（零值占比阈值）

定义（零值占比）：对第 j 个物种特征，其零值占比 z_j 定义为该列中取值为 0 的样本比例：

$$z_j = \frac{1}{n} \sum_{i=1}^n \mathbf{1}[x_{ij} = 0], \quad \mathbf{1}[\cdot] \text{ 读作「指示函数，条件成立取 1，否则取 0」.} \quad (1)$$

过滤规则：保留特征 j 当且仅当 $z_j \leq \tau$ ，其中阈值 $\tau = 0.95$ （读作「零值占比不超过 95%」）：

$$\mathcal{J}_{\text{keep}} = \{j \in \{1, \dots, p_0\} : z_j \leq 0.95\}, \quad p = |\mathcal{J}_{\text{keep}}| = 264. \quad (2)$$

- 因为：原始 1331 维中 92.21% 的矩阵元素为 0，其中 1067 个特征 ($z_j > 0.95$) 几乎不含判别信息——它们只在极少数样本中非零，无法稳定估计系数，且会放大 CLR 变换中 δ 替换的噪声。剔除后 $1331 \rightarrow 264$ 维，与 S2 子问题过滤口径统一（三病并集同一 264 特征集），V2 实证不损失判别信息。- ** 直觉类比 **：像问卷里「几乎所有人都不填」的题目，留着只会让统计表变长、结论变糊，删掉反而更干净。

2.2 CLR 变换（成分数据 $\rightarrow$ 可比较的相对量）

动机（为什么需要 CLR）：宏基因组相对丰度是**定和成分数据**——每行丰度之和 ≈ 100 （或归一化后 $= 1$ ）。定和约束使丰度之间「此消彼长」：一个物种丰度上升，必然挤压其他物种的相对占比，从而在原始丰度上产生**伪相关**（即使两物种真实独立，其相对丰度也负相关）。线性模型（Logistic）对特征间的线性相关敏感，直接输入原始丰度会得到被定和约束扭曲的系数。CLR 变换把「加起来等于 100 的成分」翻译成「每个物种相对本样本平均水平的对数比」，解除定和偏相关（PR-006 铁律，A 类验证 F4 实证增益 $+0.10 \sim +0.15$ ）。

第一步：零值乘法替换（因为 92% 零值无法取对数，需先给一个「低于检出限」的伪值）：

$$x_{ij} \leftarrow \max(x_{ij}, \delta), \quad \delta = 0.65 \times 10^{-5} = 6.5 \times 10^{-6}. \quad (3)$$

- 读法：每个丰度值若为 0，替换为 δ ； δ 等于检出限 (10^{-5}) 的 0.65 倍。- 因为： δ 取「检出限的 0.65 倍」是 AL-007 标准乘法替换，既保证可对数化，又远小于任何真实非零丰度（不污染信号）。乘法替换（而非加伪计数 +1）保持「零值远小于非零值」的序关系，且对 δ 的微小扰动不敏感（辩论 §3.1 反驳）。

第二步：逐行几何均值中心化：

$$\text{clr}(x_{ij}) = \ln x_{ij} - \frac{1}{p} \sum_{k=1}^p \ln x_{ik} = \ln \frac{x_{ij}}{g_i}, \quad g_i = \left(\prod_{k=1}^p x_{ik} \right)^{1/p}. \quad (4)$$

- 读法：先对每个丰度取自然对数，再减去该样本所有物种对数丰度的平均值（即减去几何均值 g_i 的对数）。- 因为：定和约束 $\sum_j x_{ij} = \text{const}$ 在原始空间是一条「单纯形」（simplex，读作「单纯形，和为常数的点集」）；取对数后，减去行内均值等价于把每个样本投影到「对数空间过原点的超平面」上，使变换后的向量满足 $\sum_j \text{clr}(x_{ij}) = 0$ ，从而解除定和约束引入的伪相关。- ** 多视角（几何） **：原始丰度点落在 p 维单纯形上（自由度只有 $p-1$ ）；CLR 把它们平移到对数空间的一个 $(p-1)$ 维超平面上，让每个坐标独立变化，不再互相牵制。- ** 直觉类比 **：把「全班 100 分总分里各科分数」换成「各科相对全班平均分的偏离」，才能公平比较不同学生——CLR 就是把「加起来等于 100 的成分」翻译成「相对多少」。

3 主模型：Logistic 回归 + L2 正则 + class_weight

3.1 线性得分与概率

$$z_i = \mathbf{w}^\top \text{clr}(\mathbf{x}_i) + b, \quad P(y_i = 1 \mid \mathbf{x}_i) = \sigma(z_i) = \frac{1}{1 + e^{-z_i}}. \quad (5)$$

- 读法：样本 i 患病的概率 = sigmoid（权重与 CLR 特征的内积 + 偏置）。- 因为：sigmoid 把线性得分 $z_i \in (-\infty, +\infty)$ 单调映射到 $(0, 1)$ ，天然输出概率，支持阈值分析与 AUC 计算；且 sigmoid

是「对数几率」的逆—— $\ln \frac{P}{1-P} = z_i$ ，即系数 w_j 可解释为「第 j 个物种 CLR 值每增加 1 单位，患病对数几率增加 w_j 」，为 S2/S3 的微生物方向解释铺垫。

3.2 损失函数（负对数似然 + L2 惩罚）

$$\mathcal{L}(\mathbf{w}, b) = - \sum_{i=1}^n \left[y_i \ln \sigma(z_i) + (1 - y_i) \ln (1 - \sigma(z_i)) \right] + \frac{\lambda}{2} \|\mathbf{w}\|_2^2. \quad (6)$$

- 读法：损失 = 所有样本的交叉熵之和 + 正则强度 λ 乘以权重向量二范数平方的一半。- 因为：第一项是交叉熵（衡量预测概率与真实标签的差距，是二分类负对数似然）；第二项 $\frac{\lambda}{2} \|\mathbf{w}\|_2^2$ 是 L2 惩罚，把权重向 0 收缩，防止 $n \ll p$ （110 ~ 253 样本 vs 264 特征）下的过拟合（PR-011 协方差收缩）。- ** 直觉类比 **：L2 像「给每个系数套一根橡皮筋往 0 拉」，样本越少、特征越多，橡皮筋越紧，防止模型死记硬背噪声。- ** sklearn 对应 **：‘LogisticRegression(penalty=’l2’, C=1.0)’，其中 $C = 1/\lambda$ （ $C = 1.0$ 即 $\lambda = 1.0$ ，为默认起点，可调参）。

3.3 class_weight=’balanced’（类别不平衡处理）

$$w_c = \frac{n}{n_{\text{classes}} \times n_c}, \quad c \in \{0, 1\}. \quad (7)$$

- 读法：类别 c 的权重 = 总样本数 ÷（类别数 × 类别 c 的样本数）。- 因为：少数类样本数 n_c 小 $\Rightarrow$ 权重 w_c 大 $\Rightarrow$ 损失中少数类样本被放大，迫使模型更关注少数类（针对 metahit 少数类 Recall=0.400 的 F5 问题）。- 代入：metahit 患病类 $w_1 = 110/(2 \times 25) = 2.2$ ，健康类 $w_0 = 110/(2 \times 85) = 0.647$ ——患病样本权重是健康的 3.4 倍。- ** 直觉类比 **：像考试里「错一道难题扣分更多」，逼模型别只顾多数类拿高分。

4 对照模型与基线（规格）

模型	输入	规格
Random Forest（对照）	原始丰度（含零值，免 CLR，同样过 264 维过滤）	‘RandomForestClassifier(n_estimators=500, max_depth=None, min_samples_leaf=1, random_state=42)’，permutation importance
单特征最佳阈值（基线）	原始丰度（264 维）	逐特征扫描阈值取 AUC 最大
Dummy 多数类（基线）	—	‘DummyClassifier(strategy=’most_frequent’)

- 因为：RF 用原始丰度（树模型对零值与单调变换不敏感，无需 CLR），作为非线性对照；单特征阈值与 Dummy 建立性能下界，防过度设计（F1 已建立）。

5 评估协议

5.1 AUC（主指标，阈值无关）

AUC（Area Under the ROC Curve，读作「ROC 曲线下面积」）定义为：随机取一个正样本与一个负样本，正样本得分高于负样本得分的概率。其 Mann-Whitney 形式：

$$\text{AUC} = \frac{1}{n^+ n^-} \sum_{i: y_i=1} \sum_{j: y_j=0} \left[\mathbf{1}[s_i > s_j] + \frac{1}{2} \mathbf{1}[s_i = s_j] \right], \quad (8)$$

其中 $s_i = \sigma(z_i)$ 为样本 i 的预测概率得分, n^+ 、 n^- 分别为正、负样本数。

- 因为: AUC 不依赖分类阈值, 且不受类别不平衡与标签方向影响, 是跨数据集可比的最诚实指标 (F5 实证: metahit ACC= 0.809 虚高而 Recall= 0.400, AUC 才反映真实判别力)。- ** 直觉类比 ** : AUC 像「随机抽一个病人和一个健康人, 模型把病人排在前面的概率」——0.5 是瞎猜, 1.0 是完美。

5.2 F1 与 Recall (少数类)

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}, \quad \text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}, \quad F_1 = \frac{2 \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (9)$$

- 读法: Recall (召回率) = 真阳性 $\div$ (真阳性 + 假阴性); Precision (精确率) = 真阳性 $\div$ (真阳性 + 假阳性); F_1 是两者的调和平均。- 因为: 少数类 (患病或健康, 视数据集方向) 是临床关注对象, 漏检代价高, 故以少数类 Recall 与 F_1 为辅指标, ACC 仅参考。

5.3 分层 5 折交叉验证

$$\widehat{\text{AUC}}_{\text{CV}} = \frac{1}{K} \sum_{k=1}^K \text{AUC}^{(k)}, \quad K = 5, \text{ seed} = 42. \quad (10)$$

- 因为: 小样本 ($n = 110 \sim 253$) 下单一训练/测试切分方差大; 分层 5 折保证每折类别比例与全量一致, $K = 5$ 为小样本常规折数 (LOOCV 兜底已覆盖更极端情形)。

5.4 LOOCV 过拟合判定

$$\Delta_{\text{overfit}} = \text{AUC}_{\text{full}} - \text{AUC}_{\text{LOOCV}}, \quad \text{判过拟合当 } \Delta_{\text{overfit}} > 0.1. \quad (11)$$

- 读法: 全量训练 AUC 减去留一法 (Leave-One-Out) AUC 的差距, 超过 0.1 判为过拟合。- 因为: 全量 AUC 是「在训练数据上自评」的乐观上界; LOOCV 每次留一个样本做测试, 是 n 次几乎无偏的诚实估计。两者差距大说明模型记住了训练噪声而非真实信号。

6 参数物理意义与取值范围汇总

参数	物理意义	取值范围
x_{ij}	物种相对丰度	$[0, 100]$ (定和 ≈ 100)
δ	零值乘法替换伪值	6.5×10^{-6} (固定, AL-007)
τ	近全零过滤阈值	0.95 (固定, 人类裁定)
p	过滤后特征维数	264 ($p_0 = 1331$ 过滤后)
w_j	第 j 物种 CLR 系数	$\mathbb{R}$ (L2 收缩后 $\ \mathbf{w}\ _2$ 有界)
b	截距	$\mathbb{R}$
λ	L2 正则强度	> 0 , 默认 1.0 ($C = 1/\lambda$)
C	正则强度倒数	$\{0.01, 0.1, 1, 10, 100\}$ (调参候选)
w_c	类别权重	> 0 , balanced 时 $w_c = n/(2n_c)$
K	CV 折数	5 (固定)
Δ_{overfit}	过拟合判定阈值	0.1 (固定)

7 简化假设与合理性论证

假设	内容	合理性
H1 成分数据	1331 维相对丰度是定和成分数据，线性模型前必须 CLR	F4 实证 CLR 增益 $+0.10 \sim +0.15$ ，三数据集一致稳健
H2 零值处理	92.21% 零值视为「低于检出限」真实稀疏，乘法替换 δ	AL-007 标准做法； δ 扰动不翻转结论
H2b 近全零过滤	$z_j > 0.95$ 特征剔除 (1331 $\rightarrow$ 264)	V2 实证不损失判别信息，与 S2 口径统一
H3 标签口径	small_adenoma 四口径敏感性分析	人类裁定全做择优，不预设单一口径
H4 独立同分布	三数据集各自独立建模，不跨数据集混合	批次效应强 (F8)，混合会引入伪信号
H5 内部验证	无外部数据，泛化靠 CV+LOOCV 诚实估计	全量 AUC 仅作乐观上界

8 数学自检

1. **回归方程自变量不含因变量**：Logistic 回归的自变量是 $\text{clr}(\mathbf{x}_i)$ （由原始丰度经 CLR 变换得到），不含 y_i 本身或其代数变换； y_i 仅出现在损失函数 (6) 的交叉熵项中作为监督信号。无「用因变量预测因变量」的循环。
2. **量纲一致**：CLR 变换后特征无量纲（对数比）；线性得分 z_i 无量纲；sigmoid 输出概率无量纲；损失 (6) 第一项为交叉熵（无量纲），第二项 $\frac{\lambda}{2} \|\mathbf{w}\|_2^2$ 无量纲（ λ 与 $\mathbf{w}$ 均无量纲）。AUC/F1/Recall 均为无量纲比例。全链路量纲自治。
3. **含 $\ln$ 变换的原始 $\rightarrow$ 变换 $\rightarrow$ 注意点表**：

原始量	变换	注意点
$x_{ij} = 0$ （零丰度）	$\max(x_{ij}, \delta)$ 替换为 δ	必须先替换再取对数，否则 $\ln 0$ 无定义
$x_{ij} > 0$ （非零丰度）	$\ln x_{ij}$	丰度 < 1 时对数为负，属正常（相对量）
行内对数均值	$\frac{1}{p} \sum_k \ln x_{ik}$	中心化后 $\sum_j \text{clr}(x_{ij}) = 0$ ，每行和恒为 0
$\text{clr}(x_{ij})$	直接进 Logistic	系数 w_j 解释为「对数几率变化」，非原始丰度效应

4. **CLR 中心化正确性**：(4) 中 $\sum_j \text{clr}(x_{ij}) = \sum_j \ln x_{ij} - p \cdot \frac{1}{p} \sum_k \ln x_{ik} = 0$ ，恒成立，解除定和约束。
5. **class_weight 归一性**：(7) 中 $\sum_c n_c w_c = n$ （权重按样本数加权后总和等于总样本数），损失放大少数类但不改变总体尺度。

9 直觉解释（无公式）

疾病预测模型要回答：给一份肠道菌群样本，判断这个人有没有病。菌群数据有个麻烦——每个样本里几百上千种细菌的丰度加起来是固定的（像一张 100 分的卷子），所以一种细菌多了，别的必然显得少，这种「此消彼长」会骗过线性模型。我们先把几乎从不出现的细菌删掉（问卷里没人填的题），再把每种细菌的丰度换成「它比这个样本平均水平高多少还是低多少」（像把各科分数换成相对全班平均分的偏离），这样不同样本之间才公平可比。

然后让一个线性模型学「哪些细菌偏高偏低对应生病」，同时给每个系数套一根橡皮筋往零拉，防止样本太少时模型死记硬背噪声；再给少数类（病人）加权，逼模型别只顾多数类（健康人）拿高分。最后用「随机抽一个病人和一个健康人，模型把病人排前面的概率」这个指标来打分，因为它不受「病人本来就少」的影响，跨三个数据集才公平可比。

10 假设检验计划

核心假设	检验方法	结果/状态
H1 成分数据需 CLR	对比 CLR 前后线性模型 AUC (F4)	已证: A 类验证增益 +0.146/ +0.109/ +0.099
H2b 近全零过滤	过滤前后 AUC 对比 (1331 vs 264 维)	待验证: 实现后重跑对比 (V2 已初证不损失)
H3 四口径	small_adenoma 四口径各跑主模型 + 对照, 对比 AUC	待验证: 敏感性分析 (2.1 实现后择优)
H4 独立建模	三数据集分别建模, 不混合	已证: 设计保证 (F8 批次效应强)
H5 无过拟合	全量 AUC vs LOOCV AUC 差距 ≤ 0.1	待验证: 2.1 实现后判定
B3 class_weight	class_weight 前后 Recall 对比	待验证: B 类验证 (head-to-head)
B4 离群样本	剔除 14 样本重训 Zeller 对比 AUC	待验证: B 类验证 (敏感性)

11 方案讲解收束 (math-explainer 6 条)

- **解决什么:** 为三个宏基因组数据集各建一个「患病 vs 健康」二分类模型并诚实评估, 回答「模型预测疾病表现如何、为何三数据集表现不同」。
- **怎么做:** 小样本高维成分数据 $\rightarrow$ 近全零过滤 (1331 $\rightarrow$ 264) $\rightarrow$ CLR 解除定和偏相关 $\rightarrow$ Logistic(L2)+class_weight 为主、RF 对照、简单基线兜底、AUC 主指标 + F1/Recall(少数类) 诚实评估、按四重来源归因跨疾病差异。
- **为什么:** 成分数据需 CLR 解除定和偏相关 (F4 实证); L2 收缩抗小样本过拟合 (PR-011); AUC 不受类别不平衡与方向影响, 是跨数据集可比的最诚实指标 (F5 实证)。

防跳跃 (可能需展开的概念点): CLR 为什么解除定和偏相关 (几何均值中心化的数学含义, 即单纯形到对数超平面的投影); L2/Ridge 收缩的 λ 选择 (C 调参的内层 CV 防泄漏); LOOCV 为何是最小诚实估计 (留一法几乎无偏); 成分数据零值的乘法替换公式 (AL-007 的 $\delta = 0.65 \times$ 检出限); permutation importance 与 Gini importance 的区别。如需后续展开可追问。