

S2 数学推导：特征选择与生物标志物（近全零过滤 + CLR + Lasso 稳定性选择 + 两路信号 + 共现分析）

MathModel 建模小组

2026-08-21

1 问题形式化

S2 子问题为三个宏基因组数据集（Zeller CRC / metahit IBD / Chatelier Obesity）各自从 $p_0 = 1331$ 个高维稀疏物种特征中，筛出每病**稳定、可解释、生物合理的** Top 10~20 生物标志物，并解读其丰度/存在趋势与跨疾病关系。本文件给出完整数学推导：数据预处理（近全零过滤 + CLR）、主方法（Lasso 稀疏 Logistic + bootstrap 稳定性选择）、两路信号检验（Fisher 精确检验 + Wilcoxon 秩和 + BH-FDR）、共现分析（协同效应初探）、佐证层（RF permutation importance + PLS-DA VIP），以及数学自检、假设检验计划与防泄漏说明。

1.1 符号表（先定义再使用）

符号	读法	定义
n	「样本数」	某数据集的样本总数（Zeller=121 / metahit=110 / Chatelier=253）
p_0	「原始特征数」	物种级特征列数 = 1331
p	「过滤后特征数」	近全零过滤后 = 264
x_{ij}	「第 i 个样本第 j 个物种的相对丰度」	原始丰度矩阵 $\mathbf{X} \in \mathbb{R}^{n \times p}$ 的元素
y_i	「第 i 个样本的真实标签」	患病 = 1 / 健康 = 0
z_j	「第 j 个特征的零值占比」	$z_j = \frac{1}{n} \sum_{i=1}^n \mathbf{1}[x_{ij} = 0]$
δ	「德尔塔，零值替换值」	零值乘法替换伪值 = 6.5×10^{-6} （与 S1 一致）
g_i	「第 i 个样本的几何均值」	$g_i = (\prod_{j=1}^p x_{ij})^{1/p}$
$\text{clr}(x_{ij})$	「CLR 变换后的值」	中心化对数比，见 §2.2
β_0	「beta 零，截距」	Lasso 稀疏 Logistic 的截距项
β_j	「beta 下标 j 」	第 j 个特征的回归系数
λ	「拉姆达，L1 正则强度」	越大越稀疏
C	「C，正则强度的倒数」	sklearn 参数， $C = 1/\lambda$
$\sigma(z)$	「sigmoid 函数」	$\sigma(z) = \frac{1}{1+e^{-z}}$ ，把实数压到 (0, 1)
$\hat{p}_i$	「p 帽下标 i 」	第 i 个样本的预测患病概率 $\hat{p}_i = \sigma(\beta_0 + \mathbf{x}_i^\top \beta)$
B	「B，bootstrap 轮数」	分层重抽样轮数 = 50 ~ 100
$\hat{\pi}_j$	「pi 帽下标 j 」	第 j 个特征在 B 轮中被选中的频率
τ	「套，稳定阈值」	稳定特征入选频率阈值 = 0.5（范围 0.5 ~ 0.6）
$\mathbf{1}[\cdot]$	「指示函数」	条件成立取 1，否则取 0
$\binom{n}{k}$	「n 选 k」	组合数，从 n 个中选 k 个的方案数
m	「m，多重比较规模」	BH-FDR 校正的特征总数 = 1331（全特征规模）
α	「阿尔法，显著性水平」	FDR 控制水平 = 0.05
U	「U，秩和统计量」	Wilcoxon 秩和检验统计量
R_1	「R 下标 1，病组秩和」	病组样本在合并排序中的秩之和
ρ	「柔，Spearman 相关系数」	两特征非零丰度的秩相关
VIP_j	「VIP 下标 j 」	第 j 个特征的 PLS-DA 变量投影重要性

2 数据预处理数学

2.1 近全零过滤（零值占比阈值）

定义（零值占比）：对第 j 个物种特征，其零值占比 z_j 定义为该列中取值为 0 的样本比例：

$$z_j = \frac{1}{n} \sum_{i=1}^n \mathbf{1}[x_{ij} = 0], \quad \mathbf{1}[\cdot] \text{ 读作「指示函数，条件成立取 1，否则取 0」}. \quad (1)$$

过滤规则：保留特征 j 当且仅当 $z_j \leq 0.95$ （读作「零值占比不超过 95%」）：

$$\mathcal{J}_{\text{keep}} = \{j \in \{1, \dots, p_0\} : z_j \leq 0.95\}, \quad p = |\mathcal{J}_{\text{keep}}| = 264. \quad (2)$$

- 因为：原始 1331 维中 1067 个特征（ $z_j > 0.95$ ）几乎不含判别信息——它们只在极少数样本中非零，无法稳定估计系数，且会稀释 L1/RF 的信号（F3 实证：这些特征 Wilcoxon 选中率 ≈ 0 ）。剔除后 $1331 \rightarrow 264$ 维，降 80% 维度几乎不损失信息，与 S1 过滤口径统一（三病并集同一 264 特征集）。- ** 直觉类比 **：像问卷里「几乎所有人都不填」的题目，留着只会让统计表变长、结论变糊，删掉反而更干净。

2.2 CLR 变换（成分数据 $\rightarrow$ 可比较的相对量）

动机（为什么需要 CLR）：宏基因组相对丰度是**定和成分数据**——每行丰度之和 ≈ 100 。定和约束使丰度之间「此消彼长」，在原始丰度上产生**伪相关**。Lasso 是线性模型，对特征间线性相关敏感，直接输入原始丰度会得到被定和约束扭曲的系数。CLR 变换把「加起来等于 100 的成分」翻译成「每个物种相对本样本平均水平的对数比」，解除定和偏相关（F6 实证：CLR 使 23~34% 特征对相关方向翻转，不 CLR 则 Lasso 建立在伪相关上）。

第一步：零值乘法替换（因为 92% 零值无法取对数，需先给一个「低于检出限」的伪值）：

$$x_{ij} \leftarrow \max(x_{ij}, \delta), \quad \delta = 0.65 \times 10^{-5} = 6.5 \times 10^{-6}. \quad (3)$$

- 读法：每个丰度值若为 0，替换为 δ ； δ 等于检出限（ 10^{-5} ）的 0.65 倍。- 因为： δ 取「检出限的 0.65 倍」是 AL-007 标准乘法替换，既保证可对数化，又远小于任何真实非零丰度（不污染信号）。乘法替换（而非加伪计数 +1）保持「零值远小于非零值」的序关系，且对 δ 的微小扰动不敏感。- ** 与 S1 口径一致（ $\delta = 6.5 \times 10^{-6}$ ），避免口径分裂 **。

第二步：逐行几何均值中心化：

$$\text{clr}(x_{ij}) = \ln x_{ij} - \frac{1}{p} \sum_{k=1}^p \ln x_{ik} = \ln \frac{x_{ij}}{g_i}, \quad g_i = \left(\prod_{k=1}^p x_{ik} \right)^{1/p}. \quad (4)$$

- 读法：先对每个丰度取自然对数，再减去该样本所有物种对数丰度的平均值（即减去几何均值 g_i 的对数）。- 因为：定和约束 $\sum_j x_{ij} = \text{const}$ 在原始空间是一条「单纯形」（simplex，读作「单纯形，和为常数的点集」）；取对数后减去行内均值等价于把每个样本投影到「对数空间过原点的超平面」上，使变换后的向量满足 $\sum_j \text{clr}(x_{ij}) = 0$ ，从而解除定和约束引入的伪相关。- ** 多视角（几何） **：原始丰度点落在 p 维单纯形上（自由度只有 $p-1$ ）；CLR 把它们平移到对数空间的一个 $(p-1)$ 维超平面上，让每个坐标独立变化，不再互相牵制。- ** 直觉类比 **：把「全班 100 分总分里各科分数」换成「各科相对全班平均分的偏离」，才能公平比较不同学生——CLR 就是把「加起来等于 100 的成分」翻译成「相对多少」。

3 主方法：Lasso 稀疏 Logistic + bootstrap 稳定性选择

3.1 Lasso 稀疏 Logistic 目标函数

对每个疾病，在训练折上最小化：

$$\min_{\beta_0, \beta} \underbrace{-\frac{1}{n} \sum_{i=1}^n \left[y_i \ln \hat{p}_i + (1 - y_i) \ln(1 - \hat{p}_i) \right]}_{\text{负对数似然 (拟合误差)}} + \underbrace{\lambda \sum_{j=1}^p |\beta_j|}_{\text{L1 惩罚 (稀疏化)}}, \quad \hat{p}_i = \sigma(\beta_0 + \mathbf{x}_i^\top \beta). \quad (5)$$

- 读法：损失 = 所有样本的交叉熵均值 + 正则强度 λ 乘以系数绝对值之和。- 因为：第一项是交叉熵（二分类负对数似然，衡量预测概率与真实标签的差距）；第二项 $\lambda \sum_j |\beta_j|$ 是 L1 惩罚， λ 越大，越多的 β_j 被压成**恰好为 0**——这就是「自动选特征」的代数来源（少而精）。- **多视角（代数）**：L1 惩罚的绝对值在 $\beta_j = 0$ 处不可导，其「尖角」使最优解倾向于落在坐标轴上（很多系数恰好为 0），等价于「自动把不重要特征系数压成 0」；而 L2 惩罚（S1 用）是光滑的，只收缩不置零。- **直觉类比**：L1 惩罚像「预算约束」——每保留一个非零系数都要「交税」，模型只肯为真正有用的特征「花钱」，其余系数被压成 0。- **sklearn 对应**：‘LogisticRegression(penalty=’l1’, solver=’liblinear’ 或’saga’, C=...)’，其中 $C = 1/\lambda$ （ C 越大正则越弱）。V6 用 $C = 0.1$ ，正式实现给 C 范围（如 0.01 ~ 1.0）。

3.2 bootstrap 出现频率

第 j 个特征在 B 轮 bootstrap 中的出现频率：

$$\hat{\pi}_j = \frac{1}{B} \sum_{b=1}^B \mathbf{1}\{\hat{\beta}_j^{(b)} \neq 0\}, \quad \hat{\beta}_j^{(b)} \text{ 是第 } b \text{ 轮 bootstrap 重抽样上拟合的 Lasso 系数}. \quad (6)$$

稳定特征集：

$$\hat{S}_\tau = \{j : \hat{\pi}_j \geq \tau\}, \quad \tau = 0.5 \text{ (范围 } 0.5 \sim 0.6\text{)}. \quad (7)$$

- 读法：第 j 个特征在 B 轮重抽样中被 Lasso 选中（系数非零）的比例 $\hat{\pi}_j$ ； $\hat{\pi}_j$ 达到阈值 τ 的特征进入稳定特征集 $\hat{S}_\tau$ 。- 因为：小样本（ $n = 110 \sim 253$ ）对 $p = 264$ 特征，单次 Lasso 选择几乎不可复现（选择方差巨大）；bootstrap 聚合频率用重抽样估计「选择结果的不确定性」，把「一次选择的方差」显式量化——频率低 = 方差大 = 不可信。- 因为（ τ 从 0.8 下调到 0.5~0.6）：频率 ≥ 0.8 只有 2 特征/病（F7），选不出 Top 10~20；频率分布连续长尾，0.5 ~ 0.6 是稳定簇与噪声分界。- **直觉类比**：像选「靠谱员工」——不看一次面试（单次 Lasso），看多次面试（bootstrap）里每次都表现好的人（高频率）。一次发挥好可能是运气，每次都稳才是实力。

3.3 分层 CV 折内选择（防泄漏形式化）

核心原则：特征选择（过滤、CLR、Lasso）必须在**训练折内**做，不得在全量数据上先选特征再交叉验证。

设分层 K 折交叉验证将数据划分为 K 个折 $\mathcal{F}_1, \dots, \mathcal{F}_K$ （每折类别比例与全量一致）。对第 k 折：

$$\mathcal{D}_{\text{train}}^{(k)} = \bigcup_{l \neq k} \mathcal{F}_l, \quad \mathcal{D}_{\text{test}}^{(k)} = \mathcal{F}_k. \quad (8)$$

特征选择 $\hat{S}^{(k)}$ 仅在 $\mathcal{D}_{\text{train}}^{(k)}$ 上计算（过滤阈值、CLR 几何均值、Lasso 系数均来自训练折），测试折 $\mathcal{D}_{\text{test}}^{(k)}$ 只用于评估，不参与任何选择步骤。

- 因为：若「先在全量数据上选特征，再对选出的特征做 CV」，测试折的信息已通过特征选择步骤**泄漏**进模型，会系统性高估性能（选出的特征「碰巧」在测试折上表现好）。折内选择保证测试折对模型完全「不可见」。
- ** 诚实标注 **：报告同时给「全量选择结果（乐观）」与「CV 内稳定频率（诚实）」两套数字——全量选择是「在训练数据上自评」的乐观上界，CV 内频率才是可泛化的诚实估计。

4 两路信号检验（对稳定特征做，非再选）

对入选的稳定特征做差异丰度检验，**拆两路信号**（F2 实证：零值占比差与 AUC 相关 $0.86 \sim 0.89$ ，显著高于非零丰度差 $0.63 \sim 0.67$ ，故「差异」主要来自「在不在」而非「多不多」）：

4.1 (a) 存在/缺失信号：Fisher 精确检验（超几何）

对稳定特征构建 2×2 列联表：

	患病	健康	行和
存在（非零）	a	b	$a + b$
缺失（零）	c	d	$c + d$
列和	$a + c$	$b + d$	n

在「存在与否与疾病无关」的原假设下，观测到该表的概率服从超几何分布：

$$P = \frac{\binom{a+b}{a} \binom{c+d}{c}}{\binom{n}{a+c}}, \quad \text{Fisher 精确检验的 } p \text{ 值} = \sum_{\text{更极端的表}} P. \quad (9)$$

- 读法：固定四个边缘和（行和、列和）不变，观测到「患病组恰好有 a 个存在」的概率由超几何分布给出； p 值 = 所有「比当前表更极端」的表概率之和。
- 因为：92% 的物种在大多数样本里「根本没出现」，所以「在不在」才是主要信号（F2）；Fisher 精确检验不依赖大样本近似，对小样本（ $n = 110 \sim 253$ ）与稀疏列联表（存在/缺失高度不平衡）精确有效。
- ** 直觉类比 **：像问「这个店有没有卖某商品」——先问「在不在」，再问「卖得多不多」，是两个不同问题。

4.2 (b) 非零丰度信号：Wilcoxon 秩和检验

对稳定特征，在**非零样本**上比较病组与健组的 CLR 丰度分布。将两组样本合并排序取秩，检验统计量 U 基于秩和：

$$U = \min(U_1, U_2), \quad U_1 = n_1 n_2 + \frac{n_1(n_1 + 1)}{2} - R_1, \quad U_2 = n_1 n_2 - U_1. \quad (10)$$

其中 n_1, n_2 为两组样本数， R_1 为病组秩和。 U 越小，两组分布差异越大。

- 读法：把两组样本的丰度混在一起从小到大排队，看「病组的人是不是都挤在队尾（或队头）」——挤得越极端， U 越小，差异越显著。
- 因为：CLR 丰度不满足正态性（零值主导、长尾），用

秩而非原始值做检验，对分布形状稳健，不依赖正态假设。- ** 直觉类比 **：像比较「两个班的身高」——不直接比平均身高（可能被几个极端值带偏），而是把所有人混排后看「A 班的人是不是都排在前面」。

4.3 BH-FDR 多重比较校正 ($m = 1331$ 全特征规模)

对 m 个特征同时检验 ($m = 1331$ 全特征规模, 2026-08-21 人类裁定: 医疗宁可严格不可虚报——检验仅对过滤后 264 特征执行, 但多重比较按全 1331 计数, 取最严格口径), 将 p 值升序排列 $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)}$, 找最大的 k 使:

$$p_{(k)} \leq \frac{k}{m} \alpha, \quad \alpha = 0.05. \quad (11)$$

拒绝 $H_{(1)}, \dots, H_{(k)}$ (即前 k 个最小 p 值对应的特征判为显著)。

- 读法: 把 m 个 p 值从小到大排, 从最小的开始逐个检查「第 k 小的 p 值是否不超过 $\frac{k}{m} \times 0.05$ 」, 找到满足条件的最大 k , 前 k 个判显著。- 因为: 同时检验 1331 个特征, 纯靠运气也会有几十个「碰巧显著」; BH-FDR 控制「误报显著」的比例 (假发现率), 防止「检验太多必然有几个假阳性」。相比 Bonferroni ($p \leq \alpha/m$), BH-FDR 在控制假阳性的同时保留更多真阳性, 是生物标志物筛选的标准口径。- ** 直觉类比 **：像「同时考 1331 门课, 总有几门碰巧及格」——FDR 不是要求每门都严格, 而是控制「及格的人里混进多少碰运气的」。

5 共现分析 (协同效应初探, 2026-08-21 人类裁定新增)

动机: Lasso 是线性可加模型, 只建模每个微生物的**独立边际效应**, 显式建模不了「微生物间协同/共现效应」(如 A、B 菌同时出现才致病)。小样本 (110 ~ 253) 下全特征两两交互 ($\binom{1331}{2} \approx 88$ 万对) 不可行, 故以入选稳定标志物 (10~20 个) 为限做**二阶初探**, 把「没做交互」从潜在扣分点转为「做了初探并声明边界」。

5.1 两两 Spearman 相关 (非零样本上, CLR 后丰度)

对每病入选的稳定标志物两两计算 Spearman 秩相关系数:

$$\rho_{jk} = 1 - \frac{6 \sum_{i=1}^{n'} d_i^2}{n'(n'^2 - 1)}, \quad d_i = \text{rank}(x_{ij}) - \text{rank}(x_{ik}), \quad (12)$$

其中 n' 为两特征均非零的样本数, d_i 为第 i 个样本上两特征秩之差。 $\rho_{jk} > 0$ 表共现 (正相关), $\rho_{jk} < 0$ 表互斥 (负相关)。

- 读法: 把两个物种在每个样本的丰度分别换成「排名」, 再算排名的相关; 正相关 = 一起出现, 负相关 = 互相排斥。- 因为: 丰度非正态、零值主导, 用秩相关 (Spearman) 而非 Pearson 线性相关, 对单调关系与离群值稳健。

5.2 共现/互斥检验 (Fisher 精确检验, 存在/缺失口径)

对相关显著的标志物对, 用 Fisher 精确检验验证「同现/互斥是否超出独立期望」。对标志物对 (j, k) 构建 2×2 列联表 (两者均存在 / 仅 j 存在 / 仅 k 存在 / 均缺失), 在「两物种存在与否相互独立」的原假设下, 观测表概率服从超几何分布 (同 (9)), p 值 = 更极端表概率之和。显著共现 ($p < \alpha$ 且同现多于期望) 记为「cooccur」边, 显著互斥记为「exclude」边, 输出共现网络 (节点 = 标志物, 边 = 显著共现/互斥, 标方向)。

5.3 边界声明（报告必须含）

「小样本下仅对入选标志物做二阶探索，无法全特征交互建模；标志物筛选主口径仍为边际信号（生物标志物研究标准口径）。」——共现分析是**协同效应的初探证据**，放讨论节，不改变主选择口径。

6 佐证层（独立复现，不参与主选择）

6.1 RF permutation importance（免 CLR）

树模型直接跑原始丰度（免 CLR, F6 豁免），多轮取平均。第 j 个特征的 permutation importance:

$$PI_j = AUC_{\text{orig}} - \frac{1}{R} \sum_{r=1}^R AUC_{\text{perm},j}^{(r)}, \quad (13)$$

其中 AUC_{orig} 为原始数据上的 AUC， $AUC_{\text{perm},j}^{(r)}$ 为第 r 次随机打乱第 j 列后重算的 AUC， R 为打乱轮数。PI _{j} 越大，第 j 个特征越重要。

- 读法：把第 j 个物种的丰度随机打乱（破坏它与标签的关联），看模型性能掉多少——掉得越多，这个物种越重要。- 因为：permutation importance 直接度量「打乱该特征后性能损失」，比 Gini 杂质重要性更少受高基数/连续特征偏好的影响（Gini 重要性有偏，偏好高基数特征）。

6.2 PLS-DA VIP（阈值上调 > 1.5）

第 j 个特征的变量投影重要性（Variable Importance in Projection）:

$$VIP_j = \sqrt{p \cdot \frac{\sum_{a=1}^A SS_a \cdot (w_{ja}/\|w_a\|)^2}{\sum_{a=1}^A SS_a}}, \quad SS_a = \sum_{i=1}^n (t_{ia})^2, \quad (14)$$

其中 A 为 PLS 成分数， w_{ja} 为第 a 个成分中第 j 个特征的权重， t_{ia} 为第 i 个样本在第 a 个成分上的得分。VIP _{j} > 1 通常视为重要，本问**上调阈值至 > 1.5**（F8 实证：VIP > 1 选中 40~55%，失去筛选意义）。

- 读法：VIP 衡量第 j 个特征对「解释标签方差」的累计贡献，> 1 是常用阈值，本问因特征过多上调到 > 1.5 收紧筛选。- 因为：VIP > 1 在 264 维上选中 40~55% 特征，几乎等于没筛；上调到 > 1.5（或按分位数）才恢复筛选意义。

6.3 佐证一致性

RF 与 VIP 的 Top-N 排名与 Alpha 稳定特征（Lasso bootstrap）的 **Top-N 排名一致性** 作为稳健性佐证（Spearman 秩相关或交集比例）。三者独立复现同一批标志物，说明选择结果不是单一方法的偶然。

7 参数物理意义与取值范围汇总

参数	物理意义	取值范围
x_{ij}	物种相对丰度	$[0, 100]$ (定和 ≈ 100)
δ	零值乘法替换伪值	6.5×10^{-6} (固定, 与 S1 一致)
z_j 阈值	近全零过滤阈值	0.95 (固定, 人类裁定)
p	过滤后特征维数	264 ($p_0 = 1331$ 过滤后)
λ	L1 正则强度	> 0 , $C = 1/\lambda$, $C \in \{0.01, \dots, 1.0\}$
B	bootstrap 轮数	50 ~ 100 (建议)
τ	稳定特征频率阈值	0.5 (范围 0.5 ~ 0.6, B 类验证定)
m	BH-FDR 多重比较规模	1331 (全特征, 人类裁定)
α	FDR 显著性水平	0.05 (固定)
VIP 阈值	PLS-DA 重要性阈值	1.5 (或分位数, B 类验证定)
K	分层 CV 折数	5 (固定)

8 简化假设与合理性论证

假设	内容	合理性
H1 成分数据	1331 维相对丰度是定和成分数据, 线性模型前必须 CLR	F6 实证 CLR 使 23~34% 特征对相关方向翻转
H2 近全零过滤	$z_j > 0.95$ 特征剔除 (1331 $\rightarrow$ 264)	F3 实证这些特征 Wilcoxon 选中率 ≈ 0 , 不损失判别信息
H3 两路信号	判别信号以「存在/缺失」为主、「丰度高低」为辅	F2 实证零值占比差 $\text{corr}(\text{AUC})$ 0.86 ~ 0.89 > 非零丰度差 0.63 ~ 0.67
H4 低冗余	特征间冗余度低, Lasso 共线组内任选不严重	F4 实证高相关边仅 21~30 条/300 特征, 最大簇规模 4
H5 频率可分	bootstrap 频率能区分「稳定特征」与「噪声长尾」	F7 实证频率分布连续长尾, 0.5 ~ 0.6 是分界
H6 已知锚点	已知标志物 (<i>Fusobacterium nucleatum</i> 等) 是方法有效性锚点	F5 实证 CRC 稳定特征含 <i>Fusobacterium_nucleatum</i> (频率 0.82)
H7 独立建模	三数据集各自独立执行, 不跨病混合	批次效应强, 混合会引入伪信号
H8 边际主口径	标志物筛选主口径为边际信号, 交互仅二阶初探	小样本下全特征交互 (88 万对) 不可行

9 数学自洽

- 回归方程自变量不含因变量:** Lasso 稀疏 Logistic 的自变量是 $\text{clr}(\mathbf{x}_i)$ (由原始丰度经 CLR 变换得到), 不含 y_i 本身或其代数变换; y_i 仅出现在损失函数 (5) 的交叉熵项中作为监督信号。无「用因变量预测因变量」的循环。
- 量纲一致:** CLR 变换后特征无量纲 (对数比); 线性得分 $\beta_0 + \mathbf{x}_i^T \beta$ 无量纲; sigmoid 输出概率无量纲; 损失 (5) 第一项为交叉熵 (无量纲), 第二项 $\lambda \sum_j |\beta_j|$ 无量纲 (λ 与 β 均无量纲)。Fisher p 值、Wilcoxon U 、FDR、Spearman ρ 、VIP 均为无量纲统计量。全链路量纲自治。
- 含 $\ln$ 变换的原始 $\rightarrow$ 变换 $\rightarrow$ 注意点表:**

原始量	变换	注意点
$x_{ij} = 0$ (零丰度)	$\max(x_{ij}, \delta)$ 替换为 δ	必须先替换再取对数, 否则 $\ln 0$ 无定义
$x_{ij} > 0$ (非零丰度)	$\ln x_{ij}$	丰度 < 1 时对数为负, 属正常 (相对量)
行内对数均值	$\frac{1}{p} \sum_k \ln x_{ik}$	中心化后 $\sum_j \text{clr}(x_{ij}) = 0$, 每行和恒为 0
$\text{clr}(x_{ij})$	直接进 Lasso	系数 β_j 解释为「对数几率变化」, 非原始丰度效应

- CLR 中心化正确性:** (4) 中 $\sum_j \text{clr}(x_{ij}) = \sum_j \ln x_{ij} - p \cdot \frac{1}{p} \sum_k \ln x_{ik} = 0$, 恒成立, 解除定和约束。

5. **超几何概率归一性**: (9) 中 $\sum_a \frac{\binom{a+b}{a} \binom{c+d}{c}}{\binom{n}{a+c}} = 1$ (Vandermonde 恒等式), 所有可能表的概率之和为 1, p 值定义合法。
6. **Wilcoxon U 对称性**: (10) 中 $U_1 + U_2 = n_1 n_2$, $U = \min(U_1, U_2)$ 对两组对称, 检验无方向偏置。
7. **防泄漏**: 特征选择 (过滤/CLR/Lasso) 均在训练折内 (§3.3), 测试折不参与任何选择步骤, 无信息泄漏。

10 直觉解释 (无公式)

特征选择要回答: 从一千多种肠道细菌里, 找出「哪些细菌最能区分病人和健康人」。菌群数据有两个麻烦——一是绝大多数细菌在绝大多数样本里「根本没出现」(一千多种里只有两百多种常见), 二是每种细菌的丰度加起来是固定的 (像一张 100 分的卷子), 一种多了别的必然显得少。我们先把几乎从不出现的细菌删掉 (问卷里没人填的题), 再把每种细菌的丰度换成「它比这个样本平均水平高多少还是低多少」(像把各科分数换成相对全班平均分的偏离), 这样不同样本之间才公平可比。

然后让一个「会自己挑重点」的模型 (Lasso) 学「哪些细菌偏高偏低对应生病」, 它每保留一个细菌都要「交税」, 所以只肯为真正有用的细菌花钱。但小样本下挑一次不可靠, 于是我们「面试很多次」(bootstrap 重抽样), 只留下「每次都表现好」的细菌 (高频率), 这就是稳定标志物。最后分两个问题问每个标志物: 「这个细菌在不在」(存在/缺失) 和「在的话多不多」(丰度), 因为数据显示「在不在」才是主要信号。同时检验一千多个细菌, 纯靠运气也会有几个「碰巧显著」, 所以用 FDR 控制「误报」的比例, 宁可严格、不可虚报。

11 假设检验计划

核心假设	检验方法	结果/状态
H1 成分数据需 CLR	对比 CLR 前后特征对相关方向 (F6)	已证: 23~34% 特征对方向翻转
H2 近全零过滤	过滤前后判别信息对比 (1331 vs 264 维)	已证: V2 近全零特征 Wilcoxon 选中率 ≈ 0
H3 两路信号	零值占比差 vs 非零丰度差与 AUC 相关 (F2)	已证: $0.86 \sim 0.89 > 0.63 \sim 0.67$
H4 低冗余	高相关边计数 + 最大簇规模 (F4)	已证: 21~30 条/300 特征, 最大簇 4
H5 频率可分	频率分布拐点 (F7)	已证: 连续长尾, $0.5 \sim 0.6$ 分界
H6 已知锚点	稳定特征含已知标志物 (F5)	已证: <i>Fusobacterium_nucleatum</i> 频率 0.82
H7 独立建模	三数据集分别建模	已证: 设计保证
H8 边际主口径	共现分析初探 + 边界声明	待验证: 2.1 实现后输出共现网络
B1 τ 敏感性	$\tau = 0.4/0.5/0.6/0.7$ 入选数曲线	待验证: B 类验证回填精确 τ
B2 VIP 阈值	VIP 分布分位数	待验证: B 类验证回填精确阈值
B3 佐证一致性	RF/VIP 与 Lasso 的 Top-N 排名一致性	待验证: 2.1 实现后计算

12 方案讲解收束 (math-explainer 6 条)

- **解决什么**: 从 1331 个高维稀疏物种特征中, 筛出每病稳定、可解释、生物合理的 Top 10~20 生物标志物, 并解读其丰度/存在趋势与跨疾病关系。- **怎么做**: 近全零过滤 (1331 $\rightarrow$ 264) $\rightarrow$ CLR 解除定和偏相关 $\rightarrow$ Lasso+bootstrap 稳定性选择 ($\tau = 0.5$) $\rightarrow$ Fisher+Wilcoxon 两路信号 + BH-FDR ($m = 1331$) $\rightarrow$ 共现分析初探 $\rightarrow$ RF/VIP 独立复现佐证。- **为什么**: 高维稀疏小样本下, 特

征选择结果本身方差巨大且零值主导语义，必须用「多轮聚合稳定化 + 信号拆分」去伪存真，否则「最影响」标志物很可能是过拟合的假象。

防跳跃（可能需展开的概念点）：BH-FDR 与 Bonferroni 的区别（为什么 1331 次比较用 FDR 而非更严格的 Bonferroni）；CLR 的伪计数处理（乘法替换 vs 加法替换，不同 δ 对结果的影响）；分层 CV 折内选择 vs 全量选择的泄漏差异（为什么「先全量选特征再 CV」会高估性能）；Lasso 的 $\lambda(C)$ 选择（bootstrap 内每折的 C 如何定， λ 对入选频率的影响）；RF 重要性有偏的机制（为什么 permutation importance 比 Gini 更优）。如需后续展开可追问。