

S3 数学推导——跨疾病预测模型（leave-one-disease-out 泛化评估）

MathModel AI（建模对话 S3）

2026-08-21

摘要

本文件是 S3（跨疾病预测模型）的数学推导，完整化 `approach-S3-confirmed.md` §4 数学框架。核心内容：leave-one-disease-out（LODO）协议形式化、四策略模型公式（A 直接迁移 / B 共享特征子集 / C 分类学聚合 / D Platt 校准）、Youden J 阈值迁移、AUC 与衰减量评估、紧急回退协议形式化（R1-R4）、三分法归因操作化，以及贯穿全程的防泄漏约束表达。本文件是 2.1 代码实现的规格依据，遵循 `math-explainer` 讲解质量约束全量 6 条。

1 符号表

符号	含义（读法）	取值/分布
$\mathcal{D} = \{d_1, d_2, d_3\}$	三种疾病集合：CRC（Zeller）、IBD（metahit）、Obesity（Chatelier）	3 个元素
$\mathcal{S}_d$	疾病 d 的样本集 $\{(\mathbf{x}_i, y_i)\}_{i=1}^{n_d}$	$n_{\text{CRC}} = 121, n_{\text{IBD}} = 110, n_{\text{Obesity}} = 253$
$\mathbf{x}_i$	第 i 个样本的物种级相对丰度向量（成分数据）	$\mathbf{x}_i \in \mathbb{R}^p, p = 264$ （近全零过滤后）
y_i	第 i 个样本的二分类标签（患病 = 1, 健康 = 0）	$y_i \in \{0, 1\}$
$\mathcal{T}_k, \mathcal{E}_k$	第 k 组合的训练集 / 测试集	$\mathcal{T}_k \cap \mathcal{E}_k = \emptyset$
$\text{clr}(\cdot)$	中心对数比变换（读作「CLR 变换」）	$\mathbb{R}^p \rightarrow \mathbb{R}^p$
$g(\mathbf{x})$	成分 $\mathbf{x}$ 的几何均值	$g(\mathbf{x}) = \left(\prod_j x_j\right)^{1/p}$
δ	CLR 零值乘法替换常数	$\delta = 6.5 \times 10^{-6}$
$\mathbf{w}, b$	Logistic 权重向量 / 截距	$\mathbf{w} \in \mathbb{R}^p, b \in \mathbb{R}$
$\sigma(\cdot)$	sigmoid 函数（读作「逻辑斯蒂函数」）	$\sigma(t) = 1/(1 + e^{-t})$
$f(\mathbf{x})$	模型原始分数（logit）	$f(\mathbf{x}) = \mathbf{w}^\top \mathbf{z} + b$
τ, τ^*	决策阈值 / Youden J 最优阈值	$\tau \in \mathbb{R}$
A, B	Platt 校准的尺度 / 平移参数	$A < 0, B \in \mathbb{R}$
TPR, FPR, TNR	真阳性率 / 假阳性率 / 真阴性率	$[0, 1]$
Δ_d	疾病 d 的跨疾病衰减量	$\Delta_d \leq 0$

2 LODO 协议形式化

2.1 协议定义

定义（leave-one-disease-out，读作「留一疾病」，记作 LODO）： 设三种疾病构成集合 $\mathcal{D} = \{d_1, d_2, d_3\}$ ，其中 $d_1 = \text{CRC}$ 、 $d_2 = \text{IBD}$ 、 $d_3 = \text{Obesity}$ 。对每个被留出的疾病 d_k ，构造一个「训练-测试」划分：

$$\mathcal{T}_k = \bigcup_{d \neq d_k} \mathcal{S}_d, \quad \mathcal{E}_k = \mathcal{S}_{d_k}, \quad k = 1, 2, 3$$

即每次留一种疾病作测试集，其余两种疾病作训练集，共 3 个组合。三个组合如下：

组合	训练集（2 疾病）	测试集（1 疾病）	测试集正类占比
C1	IBD + Obesity	CRC	40%（48 患病 / 73 健康）
C2	CRC + Obesity	IBD	23%（25 患病 / 85 健康，少数类）
C3	CRC + IBD	Obesity	65%（164 患病 / 89 健康，正类多数）

2.2 硬约束（防泄漏语义）

测试疾病在训练阶段完全不可见：对组合 k ，训练过程（特征选择、CLR 变换参数、Standard-Scaler 均值/方差、模型权重、阈值、校准参数）只能接触 $\mathcal{T}_k$ 的样本， $\mathcal{E}_k$ 的**标签与特征**均不参与任何训练步骤。这是「跨疾病」的诚实语义——模型面对的是一个它从未见过的疾病。

直觉解释（类比）：好比一个医生只见过「A 病和 B 病患者 vs 正常人」，现在要他判断「C 病患者是不是病人」。他学到的「像病人」的直觉能复用多少，就决定跨疾病预测的成败。

3 数据预处理与 CLR 变换

3.1 近全零过滤

物种级相对丰度矩阵高度稀疏（零值占比 92.21%）。对每个物种特征 j ，若其零值占比超过 95%，则剔除该特征（三病并集统一口径，与 S1/S2 一致）：

$$\mathcal{F}_{\text{keep}} = \left\{ j : \frac{1}{n} \sum_{i=1}^n \mathbf{1}[x_{ij} = 0] \leq 0.95 \right\}, \quad p = |\mathcal{F}_{\text{keep}}| = 264$$

其中 $\mathbf{1}[\cdot]$ 是指示函数（条件成立取 1，否则取 0）， $n = 484$ 为总样本数。过滤后 $p = 1331 \rightarrow 264$ 。

3.2 CLR 变换（成分数据强制）

相对丰度是**成分数据**（每行丰度和 ≈ 100 ，定和约束），直接进入欧式空间模型会引入伪相关。CLR 变换把成分映射到无约束的实数空间：

$$\text{clr}(\mathbf{x})_j = \ln \left(\frac{x_j}{g(\mathbf{x})} \right), \quad g(\mathbf{x}) = \left(\prod_{j=1}^p x_j \right)^{1/p}$$

其中 $g(\mathbf{x})$ 是几何均值（所有物种丰度连乘后开 p 次方）。CLR 的几何意义：把每个物种丰度除以「全体物种的典型水平」，再取对数，得到该物种相对「平均水平」的偏离。

3.3 零值处理（乘法替换）

零值（微生物未检出）不能直接取对数。采用乘法替换（AL-007 口径）：

$$x_{ij} \leftarrow \delta = 0.65 \times \text{检出限} = 6.5 \times 10^{-6}, \quad \text{当 } x_{ij} = 0$$

为什么用乘法替换而非加伪计数：乘法替换保持成分数据的定和结构（替换后仍可归一化），且 δ 取检出限的 0.65 倍是成分数据分析的惯例（低于检出限的合理下界估计）。

3.4 标准化（仅训练集估计）

CLR 后对每个特征做 StandardScaler（减均值、除标准差），但均值与标准差只在训练集 $\mathcal{T}_k$ 上估计，再应用到测试集 $\mathcal{E}_k$ ：

$$z_{ij} = \frac{\text{clr}(\mathbf{x}_i)_j - \hat{\mu}_j^{(\mathcal{T}_k)}}{\hat{\sigma}_j^{(\mathcal{T}_k)}}$$

其中 $\hat{\mu}_j^{(\mathcal{T}_k)}$, $\hat{\sigma}_j^{(\mathcal{T}_k)}$ 是训练集上的样本均值/标准差。这是防泄漏的第一道约束（见 §11）。

4 策略 A：直接迁移（Logistic L2 + CLR）

4.1 模型结构

策略 A 沿用 S1 已验证口径，是策略对比的**基线**。对每个 LODO 组合 k ，在训练集 $\mathcal{T}_k$ 上拟合正则化 Logistic 回归：

$$P(y = 1 \mid \mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{z} + b) = \frac{1}{1 + \exp(-(\mathbf{w}^\top \mathbf{z} + b))}$$

其中 $\mathbf{z} = \text{clr}(\mathbf{x})$ 经标准化后的特征向量， $\mathbf{w}$ 是权重向量， b 是截距。原始分数（logit）记作 $f(\mathbf{x}) = \mathbf{w}^\top \mathbf{z} + b$ 。

4.2 优化目标（L2 正则化 + 类别权重）

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i \in \mathcal{T}_k} w_i [-y_i \ln \sigma(f(\mathbf{x}_i)) - (1 - y_i) \ln(1 - \sigma(f(\mathbf{x}_i)))]$$

其中 $C = 1.0$ 是正则化强度（ C 越大惩罚越弱）， w_i 是类别权重（`class_weight='balanced'`，反比于类别频率），用于处理测试集类别不平衡（C2 少数类 23%、C3 正类多数 65%）。 $\|\mathbf{w}\|_2^2$ 是 L2 惩罚项，抑制高维小样本下的过拟合。

为什么用 L2 而非 L1： $p = 264$ 特征、训练集仅约 200 样本，L2 惩罚对所有特征施加连续收缩（不稀疏化），在特征高度相关（物种丰度共线）时比 L1 更稳定；L1 会随机丢弃共线特征中的一部分，导致结果对数据扰动敏感。

5 策略 B：共享特征子集（跨疾病通用模型）

5.1 共享特征集定义

设 $\mathcal{F}_d$ 为疾病 d 在近全零过滤后保留的特征集合。三疾病的共享特征集为：

$$\mathcal{F}_{\text{shared}} = \mathcal{F}_{\text{CRC}} \cap \mathcal{F}_{\text{IBD}} \cap \mathcal{F}_{\text{Obesity}}$$

策略 B 在 $\mathcal{F}_{\text{shared}}$ 上重训策略 A 同款模型（Logistic L2 + CLR），重跑 LODO。A 类验证在 1331 全集上测得共享物种 344 个（三向 Jaccard 0.569）；正式实现基于过滤后 264 特征集重算交集，数量可能略减。

5.2 转导式边界显式声明 (B5 裁定)

特征交集筛选只使用特征存在性 (哪些物种在三数据集中都出现), 绝不用测试集标签。这与 R3 重加权的转导式边界保持同一口径: 可以用测试集的特征 (存在性), 但绝不用测试集的标签。

5.3 策略 B 的判定逻辑

- 若共享子集 AUC 显著高于全特征 (策略 A) → 全特征里的疾病特异噪声在拖后腿, 通用模型可用。
- 若共享子集 AUC 仍近随机 → 共享物种的**存在性**不承载可迁移信号 (信号藏在**方向**里), 记录并计入回退评估。

6 策略 C: 分类学聚合 (属级/门级 + CLR)

6.1 聚合定义

利用分类学层级信息 (题面注 2), 把物种级特征聚合到属级 (g ____) 或门级 (p ____)。对某个属 g , 其聚合丰度为该属下所有物种丰度之和:

$$x_g = \sum_{j: \text{species } j \in \text{genus } g} x_j$$

聚合后维度大幅下降 (物种 264 → 属级/门级更少), 再对聚合后的成分做 CLR, 重训 Logistic L2, 重跑 LODO。

6.2 定位 (如实报告不提升)

A 类验证 A4 已实测: 物种 0.556 → 属 0.539 → 门 0.528 (聚合不提升反略降)。策略 C 仍按正式策略完整跑 3 组合, **如实报告聚合不提升**——这是对题面注 2「可利用分类学信息」的显式交付: 分类学信息已利用, 实证无增益。

为什么聚合可能不提升: 聚合是「求和」操作, 会抹平物种级的方向信息 (同一属下既有「患病 ↑」又有「患病 ↓」的物种, 求和后方向抵消), 而跨疾病信号恰恰藏在物种级方向里 (见 §10 三分法归因)。

7 策略 D: Platt 校准 (部署校正模型)

7.1 校准映射

策略 D 在策略 A/B/C 中 AUC 最优者上叠加 Platt 缩放, 把原始分数 $f(\mathbf{x})$ 映射到校准概率:

$$P_{\text{cal}}(y = 1 \mid \mathbf{x}) = \frac{1}{1 + \exp(A \cdot f(\mathbf{x}) + B)}$$

其中 A, B 是两个标量参数, 只在**训练集**上用 Logistic 回归拟合 (把训练集的原始分数 $f(\mathbf{x})$ 当作唯一特征、真实标签当作目标)。 A 控制分数尺度的缩放, B 控制概率基线的平移。

7.2 为什么不改 AUC (单调性)

当 $A < 0$ 时, P_{cal} 是 f 的**严格单调递增**函数, 因此不改变样本的排序:

$$f(\mathbf{x}_1) > f(\mathbf{x}_2) \iff P_{\text{cal}}(\mathbf{x}_1) > P_{\text{cal}}(\mathbf{x}_2)$$

ROC 曲线只依赖排序，故 AUC 完全不变。Platt 校准修复的是「分数到概率的映射」——当训练集与测试集的患病概率基线不同（标签语义漂移）时，原始分数的阈值迁移会失准，校准后概率的阈值迁移更可靠。

7.3 $A < 0$ 校验（B6 裁定）

实现时显式校验 $A < 0$ ：若拟合得 $A \geq 0$ （排序反转异常），触发警告并检查训练过程。 $A < 0$ 约束是「校准不改 AUC」成立的前提。

直觉解释（类比）：好比温度计刻度不准——Platt 校准是「重新标定刻度」，让「分数 0.7」在两个数据集上都对应「70% 患病概率」，但不会改变「谁比谁更可能患病」的排序。

8 阈值迁移：Youden J

8.1 Youden J 统计量

定义（Youden J，读作「约登 J」）：对决策阈值 τ ，定义真阳性率与假阳性率：

$$\text{TPR}(\tau) = P(f(\mathbf{x}) \geq \tau \mid y = 1), \quad \text{FPR}(\tau) = P(f(\mathbf{x}) \geq \tau \mid y = 0)$$

Youden J 统计量为灵敏度与特异度之和减 1：

$$J(\tau) = \text{TPR}(\tau) + \text{TNR}(\tau) - 1 = \text{TPR}(\tau) - \text{FPR}(\tau)$$

其中 $\text{TNR}(\tau) = 1 - \text{FPR}(\tau)$ 是真阴性率。Youden J 最优阈值为使 J 最大的阈值：

$$\tau^* = \arg \max_{\tau} J(\tau)$$

几何上， τ^* 是 ROC 曲线上距离对角线（45° 线）最远的点。

8.2 阈值迁移规则（禁测试集重定）

τ^* 只在训练集 $\mathcal{T}_k$ 上估计，然后原样搬到测试集 $\mathcal{E}_k$ ，报告该阈值下的 ACC / 灵敏度 / 特异度 / F1。**禁止在测试集上重定阈值**——那会用到新疾病标签，造成评估泄漏，违背 LODO 的「新疾病不可见」语义。

直觉解释：Youden J 好比「既要抓得住病人、又要冤枉健康人」的平衡点；把训练集上找到的这个平衡点搬到新疾病，看它还灵不灵——不灵（如 C3 灵敏度 0.006）就说明「患病概率的决策边界跨疾病不一致」。

9 评估指标：AUC 与衰减量

9.1 AUC 定义

定义（AUC，读作「曲线下面积」）：ROC 曲线（横轴 FPR、纵轴 TPR）下方的面积，等价于「随机抽一个患者比随机抽一个健康人得分更高的概率」：

$$\text{AUC} = \int_0^1 \text{TPR}(\text{FPR}^{-1}(t)) dt = P(f(\mathbf{x}_+) > f(\mathbf{x}_-))$$

其中 $\mathbf{x}_+$ 是随机正样本, $\mathbf{x}_-$ 是随机负样本。取值范围 $[0, 1]$, 0.5 表示与抛硬币无异 (随机), 1.0 表示完美区分。

为什么选 AUC 作主指标: AUC 与阈值无关——不需要决定「多高算患病」就能衡量区分能力, 因此不依赖阈值迁移假设, 是最诚实的跨疾病泛化度量。解读基准: 0.80–0.90 良好、0.70–0.80 尚可、0.60–0.70 差、 < 0.60 接近随机。

9.2 衰减量 (跨疾病 — 域内)

对疾病 d , 定义跨疾病衰减量为:

$$\Delta_d = \text{AUC}_{\text{cross}}(d) - \text{AUC}_{\text{domain}}(d)$$

其中 $\text{AUC}_{\text{cross}}(d)$ 是疾病 d 作测试集时的跨疾病 AUC, $\text{AUC}_{\text{domain}}(d)$ 是疾病 d 的域内 AUC (同疾病内训练测试)。 $\Delta_d \leq 0$ 表示跨疾病性能不高于域内。A 类验证参考值: CRC 衰减 -0.232 、IBD 衰减 -0.358 (最大)、Obesity 衰减 -0.084 。

10 紧急回退协议形式化 (2026-08-21 人类裁定)

10.1 触发条件

设策略 $s \in \{A, B, C, D\}$ 的 3 组合 AUC 均值为 $\overline{\text{AUC}}_s$ 。触发条件:

$$\overline{\text{AUC}}_s < 0.60, \quad \forall s \in \{A, B, C, D\}$$

即四策略的 3 组合 AUC 均值**全部**低于 0.60 (接近随机线) 时, 触发紧急回退。

10.2 回退候选 (R1–R4)

层级	候选模型族	思路	防泄漏约束
R1	树模型 (RF / XGBoost)	对零值/非线性鲁棒	特征选择在训练折内; 超参仅训练集
R2	样本合并通用模型	学「通用生病信号」	测试疾病样本完全不可见
R3	importance weighting	密度比加权匹配测试分布	转导式边界 (用测试特征、不用测试标签)
R4	对抗式域适应 (DANN)	最后手段	严格验证集防泄漏

10.2.1 R3: importance weighting (密度比加权)

给训练样本加权, 使加权后的训练分布逼近测试分布。权重为密度比:

$$w(\mathbf{x}) = \frac{p_{\text{test}}(\mathbf{x})}{p_{\text{train}}(\mathbf{x})}$$

其中 p_{test} , p_{train} 分别是测试/训练特征分布密度。密度比用 KLIEP 或 uLSIF 估计（代理值，见 proxy-replacement-checklist-S3.md #3），并做权重裁剪（上界）防方差爆炸。加权后的经验风险：

$$\min_{\mathbf{w}, b} \sum_{i \in \mathcal{T}_k} w(\mathbf{x}_i) \ell(y_i, f(\mathbf{x}_i))$$

转导式边界： $w(\mathbf{x})$ 用到测试集特征（估计 p_{test} ），但**绝不用测试集标签**。

10.2.2 R4：对抗式域适应（DANN 思想）

在特征提取器后加一个域判别器，通过梯度反转层（gradient reversal layer）让特征提取器学「域不变」特征。小样本过拟合风险最高，仅在 R1–R3 全败且时间允许时尝试。

10.3 可用线判定

回退候选 r 判定为「可用」当且仅当满足其一：

$$\overline{\text{AUC}}_r \geq 0.65 \quad \text{或} \quad \overline{\text{AUC}}_r - \overline{\text{AUC}}_A \geq 0.10$$

即 3 组合 AUC 均值 ≥ 0.65 （超过 Obesity 域内地板 0.644，即「跨疾病不劣于最弱疾病的域内表现」），或相对策略 A 基线提升 ≥ 0.10 。

10.4 穷尽出口

R1–R4 全部不达标 $\rightarrow$ 报告最优策略 + 完整失败证据链（策略对比表 + 衰减归因 + 迁移模式 + 阈值漂移）。此时负结果才是经过回退流程验证后的最终结论，而非默认起点。

11 三分法归因操作化

11.1 三个互斥来源

对每个低 AUC 组合，把失败归因到三个**互斥**来源，每个来源配一个可计算的定量证据：

来源	操作化定义	定量证据（A 类验证）
批次效应	训练/测试来自不同研究/平台导致的分布偏移	silhouette 系数 = 0.070（近 0，不主导）
疾病特异信号	模型学的是训练疾病特有标志物	衰减量 Δ_d ，IBD 最大 -0.358
标签语义漂移	新疾病患病概率基线整体偏移	C3 训练阈值迁移灵敏度 0.006

11.2 silhouette 系数（批次效应证据）

定义（silhouette 系数，读作「轮廓系数」）： 对样本 i ，设 $a(i)$ 为它到同簇其他样本的平均距离， $b(i)$ 为它到最近异簇样本的平均距离，则：

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

取值 $[-1, 1]$ ，越接近 1 表示簇越清晰分离，越接近 0 表示簇重叠。数据集标签 silhouette 0.070 说明三数据集在低维空间**不清晰分簇**，即批次效应不主导全局结构。

11.3 疾病特异信号（衰减量证据）

用 Δ_d 量化：域内 AUC 强但跨疾病塌缩（IBD 域内 0.885 $\rightarrow$ 跨疾病 0.527，衰减 -0.358 ），说明模型学的是训练疾病特有标志物，对新疾病不适用。

11.4 标签语义漂移（基线差证据）

定义训练集与测试集的患病概率基线差：

$$\Delta_{\text{baseline}} = \hat{P}_{\text{test}}(y = 1) - \hat{P}_{\text{train}}(y = 1)$$

C3 组合中，训练阈值迁移后灵敏度仅 0.006（几乎全判健康），说明测试集患病概率基线整体偏移，决策边界失准。

直觉解释：三分法好比医生误诊的三个可能原因——「仪器不同」（批次效应）、「这病和那病根本不是一回事」（疾病特异信号）、「判断标准整体偏了」（标签语义漂移）。实验证明主要是后两个，不是仪器问题。

12 防泄漏形式化

12.1 约束表达

设 θ 为任意从数据估计的参数（特征选择、CLR 参数、StandardScaler 均值/方差、模型权重、Youden 阈值、Platt 参数、密度比）。防泄漏约束统一表达为：

$$\theta = \theta(\mathcal{T}_k), \quad \text{即 } \theta \text{ 只能是训练集 } \mathcal{T}_k \text{ 的函数}$$

对每个 LODO 组合 k ，以下参数**仅从训练集估计**：

参数	估计来源	泄漏风险（若违反）
近全零过滤阈值	训练集（三病并集口径）	用测试集零值占比会泄漏测试分布
CLR 零值替换 δ	固定常数（S1 口径）	无（非数据估计）
StandardScaler 均值/方差	训练集	用测试集统计量泄漏测试分布
Logistic 权重 $\mathbf{w}, b$	训练集	用测试标签直接泄漏
Youden 阈值 τ^*	训练集	用测试标签重定阈值 = 评估泄漏
Platt 参数 A, B	训练集	用测试标签校准 = 泄漏
密度比 $w(\mathbf{x})$	训练 + 测试特征（转导式）	用测试标签 = 泄漏

12.2 转导式边界的精确表述

R3 的密度比 $w(\mathbf{x})$ 是唯一「半监督」项：它可以用测试集**特征**（估计 p_{test} ），但**绝不能用测试集标签**。形式化：

$$w(\mathbf{x}) = w(\mathbf{x}; \{\mathbf{x}_i\}_{i \in \mathcal{T}_k \cup \mathcal{E}_k}), \quad \text{不含 } \{y_i\}_{i \in \mathcal{E}_k}$$

13 数学自检

13.1 回归方程自变量是否含因变量或代数变换

检查项	结论
自变量 $\mathbf{z}$ 是否含因变量 y ?	否。 $\mathbf{z} = \text{clr}(\mathbf{x})$ 只含物种丰度，不含标签
CLR 变换是否引入 y ?	否。CLR 是特征空间内的几何变换，与标签无关
Platt 校准是否用 y 作自变量?	否。 $f(\mathbf{x})$ 是模型分数， y 只作拟合目标

13.2 量纲一致性

项	变换前	变换后
$\mathbf{x}$	相对丰度（百分比，定和）	$\text{clr}(\mathbf{x})$ （无量纲对数比）
$f(\mathbf{x})$	—	无量纲 logit
P_{cal}	—	概率 $[0, 1]$
τ^*	—	与 f 同量纲（无量纲）

所有项在 logit/概率尺度上量纲一致，通过量纲检查。

13.3 含 $\ln$ /比值变换列原始 $\rightarrow$ 变换 $\rightarrow$ 注意点表

变量	原始	变换	注意点
物种丰度 x_j	百分比 $[0, 100]$	$\ln(x_j/g(\mathbf{x}))$	零值须先乘法替换 δ ，不能直接 $\ln 0$
几何均值 $g(\mathbf{x})$	百分比	$(\prod x_j)^{1/p}$	含零值时须先替换，否则 $g = 0$
模型分数 f	logit	Platt sigmoid	$A < 0$ 保证单调，否则排序反转

14 方案讲解质量自检（math-explainer 6 条）

1. **先定义再使用**：LODO / CLR / AUC / Youden J / Platt 校准 / silhouette 系数 / 三分法归因 / 标签语义漂移 / 密度比均首次出现给定义与读法。
2. **每步有「因为」**：主指标选 AUC（阈值无关最诚实）、L2 而非 L1（共线特征下更稳定）、聚合不提升（求和抹平方向信息）、Platt 不改 AUC（单调变换保排序）均显式给理由。
3. **多视角**：几何（AUC=ROC 下面积、Youden J=45° 线最远点、CLR= 对数比偏离）、生物学（疾病特异信号 = 共享物种方向翻转）、统计（silhouette 近 0= 不清晰分簇）三视角。
4. **核心洞察收束**：见 §15。
5. **直觉解释**：§2 医生类比、§7 温度计刻度类比、§8 Youden J 平衡点类比、§10 医生误诊三原因类比。
6. **防跳跃**：需展开概念点见 §16。

15 假设检验计划

假设	检验方法	预期结果
H2 失败主因是疾病特异信号 + 标签漂移	衰减量 Δ_d 排序 + silhouette 0.070	IBD 衰减最大、silhouette 近 0
H3 共享物种方向承载疾病特异信号	方向一致性分析 + 符号检验/置换检验	方向翻转占比显著
H4 Platt 校准修复可部署指标	校准前后 ACC/F1/灵敏度对比	校准后辅指标提升、AUC 不变
H5 属级聚合不提升	物种/属/门 AUC 对比	0.556→0.539→0.528 略降
H6 回退候选存在可用模型	R1-R4 各 AUC 均值 vs 可用线	达 0.65 或提升 0.10 即交付

方向一致性分析（深度迁移）：对共享物种，计算每个物种在训练疾病与测试疾病中的「患病 vs 健康」丰度变化方向，分「方向一致（可迁移）」与「方向翻转（疾病特异）」两类，配符号检验/置换检验（不裸报描述统计）。

16 核心洞察收束

本问解决什么、怎么做、为什么：S3 解决「模型到新疾病上还灵不灵」——正面回答是「建立跨疾病预测模型」：正式构建并对比四种策略（A 直接迁移 / B 共享特征 / C 分类学聚合 / D Platt 校准），选出最优者交付；若四策略 AUC 均值全部 < 0.60 ，触发紧急回退（R1 树模型 → R2 样本合并 → R3 密度比加权 → R4 对抗式域适应），达可用线（ ≥ 0.65 或提升 ≥ 0.10 ）即交付，穷尽后以完整证据链报告。归因分析（三分法）是「为什么差」的解释层，不是替代「建立模型」的答案。

17 可能需展开的概念点（供后续追问）

- AUC 的几何含义与 ROC 曲线构造（FPR/TPR 如何随阈值扫描）。
- CLR 变换的数学定义与零值乘法替换（AL-007）的完整推导。
- Youden J 阈值的求解（ROC 上 45° 线最远点的数值实现）。
- Platt 缩放与温度缩放（temperature scaling）的区别。
- importance weighting 的密度比估计（KLIEP/uLSIF）与转导式边界。
- 方向一致性分析的符号检验/置换检验方法。